

Faculté Polytechnique



Symbolic Regression for Interpretable Modeling of Building Thermal Dynamics

Travail de Fin d'Études
présenté en vue de l'obtention du grade de Master Ingénieur civil électricien
à finalité spécialisée en Electrical Energy and Smart Grids

Réalisé par DETRAIT Romain
Août 2026



Sous la direction de
Professeur VALLÉE François (Promoteur)
Docteur FAVARO Pietro (Co-promoteur)
Docteur TOUBEAU Jean-François (Rapporteur)
Professeure FELDHEIM Véronique (Rapporteur)



Résumé

Cette étude explore une approche de modélisation interprétable de la dynamique thermique des bâtiments, basée sur la régression symbolique, afin d'optimiser efficacement les systèmes HVAC dans un contexte marqué par la transition énergétique et l'électrification rapide. Face à la croissance continue de la superficie bâtie mondiale et à la montée en puissance des pompes à chaleur, les bâtiments deviennent des acteurs majeurs du système électrique. Cette évolution soulève des défis techniques et économiques, notamment en matière de flexibilité et d'interactions avec les marchés de l'électricité à court terme (ex. marché day-ahead avec granularité de 15 minutes).

Dans ce travail, l'objectif spécifique est de développer des modèles dynamiques légers, robustes et surtout interprétables, capables de prédire la température intérieure d'une maison résidentielle unifamiliale à deux étages, modélisée comme une seule zone thermique. Ces modèles utilisent comme variables d'entrée la température extérieure, la température intérieure instantanée et la puissance thermique HVAC, avec pour sortie la température intérieure prédite 15 minutes après. Ils sont ensuite intégrés dans une optimisation des coûts liée aux signaux tarifaires du marché day-ahead (15 min) et validés ex-post avec l'outil EnergyPlus.

L'étude s'appuie sur deux jeux de données distincts : une « Année Classique », caractérisée par des consignes stables, et une « Année Dynamique », favorisant une excitation riche des dynamiques thermiques. Plusieurs modèles ont été développés : modèle persistant, modèles physiques simplifiés 1R1C, régressions linéaires et quadratiques, ainsi que des modèles issus de la régression symbolique (RS) linéaire et non linéaire, implémentés avec l'outil PySR.

Les résultats montrent que la régression symbolique, particulièrement dans sa version non linéaire cubique entraînée sur l'année dynamique, parvient à concilier interprétabilité et précision, en assurant une meilleure stabilité temporelle lors de simulations récursives et en réduisant significativement l'erreur sur les puissances HVAC. En optimisation ex-post, le modèle linéaire issu de la RS année dynamique permet quant à lui d'obtenir les coûts énergétiques les plus bas sur les journées testées. Les résultats obtenus avec la régression symbolique surpassent les performances des modèles classiques développés dans cette étude, tels que la régression linéaire, la régression quadratique et le modèle persistant, en termes de stabilité temporelle, de précision sur la puissance HVAC et de qualité des trajectoires générées dans un contexte d'optimisation intégrée aux signaux tarifaires du marché.

L'étude met en lumière le potentiel prometteur de la régression symbolique, tout en soulignant sa nature essentiellement statistique et la nécessité d'explorations futures incluant une recherche plus développée de la RS, ainsi que d'autres méthodes d'apprentissage plus « boîtes noires » comme le support vector machine ou random forest pour une comparaison complète.

Le code associé à ce travail est accessible publiquement sur GitHub : https://github.com/Rom12trait/TFE_symbolic_regression_building.git

Remerciements

Je tiens à remercier Pietro Favaro et François Vallée pour leur aide et contribution tout au long de ce travail de fin d'étude.

Table des matières

1	Introduction	1
1.1	L'électricité dans le secteur du bâtiment	1
1.2	Impacts sur le réseau électrique	3
1.2.1	Impact de l'électrification sur la demande et congestion réseau	3
1.2.2	Régulation de la tension et limites thermiques	4
1.2.3	Infrastructure	4
1.3	Solutions et opportunités de l'électrification	5
1.3.1	Gestion intelligente	5
1.3.2	Productions et stockages décentralisés	5
1.4	Marché de l'électricité	6
1.4.1	Facture électrique et leviers de flexibilité	6
1.4.2	Les acteurs du marché	6
1.4.3	Les marchés de gros et le couplage quart d'heure	8
1.4.4	Valorisation de la flexibilité résidentielle : opportunités et risques	8
1.4.5	Inscription du projet dans le cadre de la planification day-ahead	9
1.5	Contexte, motivation et objectifs	9
1.5.1	Modèles de dynamique thermique : positionnement méthodologique	9
1.5.2	Motivation et positionnement du travail	10
1.5.3	Objectifs du TFE	10
2	Etat de l'art	11
2.1	Le contrôle prédictif pour l'optimisation énergétique	11
2.2	Interprétabilité des modèles thermiques	11
2.3	Classification des approches de modélisation thermique	12
2.3.1	Modèles physique <i>white box</i>	12
2.3.2	Modèles data-driven <i>black box</i>	14
2.3.3	Modèles hybrides <i>gray box</i>	17
2.4	Synthèse comparative	19
2.5	Transition vers la régression symbolique	19
2.6	Outils existants et applications à la thermique du bâtiment	21
3	Optimisation	22
3.1	Modélisation thermique et formulation dynamique	22
3.2	Formulation mathématique du problème d'optimisation	23
3.2.1	Variables et indices	23
3.2.2	Fonction objectif	23
3.3	Contraintes du système	23
3.3.1	Dynamique thermique de l'enveloppe	23
3.3.2	Limites technologiques	24
3.3.3	Bornes de confort souples	24
3.4	Résolution et validation	24

4	Régression symbolique	25
4.1	Principe général de la régression symbolique	25
4.2	Différentes catégories de régression symbolique	26
4.3	La régression symbolique pour la découverte d'équations en science	27
4.4	Algorithme génétique	27
4.4.1	Représentation et opérateurs évolutifs	27
4.4.2	Démarche basique d'un algorithme génétique	28
4.4.3	Fonction objectif et compromis précision-complexité	28
4.5	Améliorations	28
4.5.1	Boucle intégrée « évoluer-simplifier-optimiser »	29
4.5.2	Métrique de parsimonie adaptative	29
4.5.3	Autres fonctionnalités avancées pour l'identification scientifique	29
5	Cas d'étude	30
5.1	Données	30
5.1.1	Données météorologiques	30
5.1.2	Modèle d'habitation	31
5.1.3	Séries temporelles	31
5.1.4	Scénarios année classique et année dynamique	32
5.2	Benchmarks	33
5.2.1	Modèle 1R1C	33
5.2.2	Benchmark : modèle persistant	35
5.2.3	Régression linéaire	35
5.2.4	Régression quadratique brute et restreinte	36
5.2.5	Régression symbolique (PySR)	36
5.3	Résultats statistiques	37
5.4	Résultats d'optimisation et ex-post	40
5.4.1	Impact de l'historique d'entraînement : supériorité de l'année dynamique	40
5.4.2	Analyse de la régression quadratique restreinte	41
5.4.3	Performances de la régression symbolique non-linéaire	43
5.4.4	Analyse dynamique des profils thermiques, électriques et financiers du modèle régression symbolique cubique	44
	Conclusion	49
	Bibliographie	55
	A Annexe	56
	Annexe	56
A.1	Etat de l'art	56
A.2	Hyperparamètres de la régression symbolique avec PySR	57
A.2.1	Définition de l'espace de recherche structurel	57
A.2.2	Pilotage de la complexité et de la parcimonie	58
A.2.3	Paramètres d'exécution de l'algorithme génétique	58
A.2.4	Paramètres de la recherche évolutionnaire	58
A.3	Dataset	59
A.4	Résultats	60
A.5	Autorisation de diffusion	65
	Liste d'acronymes	66

Chapitre 1

Introduction

Ce TFE porte sur "La régression symbolique pour une modélisation interprétable de la dynamique thermique du bâtiment". Il s'intéresse à l'utilisation de la régression symbolique pour modéliser la dynamique thermique d'un bâtiment et pouvoir utiliser ce modèle interprétable pour implémenter une optimisation coûts basée sur le marché de l'électricité pour contrôler les systèmes HVAC. Ce modèle sera comparé à d'autres modèles de la littérature comme la régression linéaire, la régression quadratique et le modèle RC aggrégé.

Ce chapitre vise à mettre en contexte le sujet du TFE en introduisant l'électrification du secteur des bâtiments et l'utilisation croissante des systèmes HVAC, les impacts sur le réseau et le positionnement du bâtiment dans le marché de l'électricité pour conclure avec les objectifs du TFE.

1.1 L'électricité dans le secteur du bâtiment

Le secteur des bâtiments résidentiels et tertiaires s'établit aujourd'hui comme l'un des plus grands consommateurs d'énergie à l'échelle mondiale, englobant les flux liés à la construction, à l'éclairage, aux équipements et, de manière prépondérante, au chauffage et à la climatisation.

Sous l'effet combiné de la croissance démographique et du développement économique, la superficie mondiale des bâtiments connaît une hausse continue. Les projections de l'Agence Internationale de l'Énergie AIE anticipent une augmentation de 15 % de cette surface d'ici 2030 [1], voir figure 1.1, ce qui représente une extension équivalente au parc immobilier actuel de l'Amérique du Nord. Cette expansion structurelle s'accompagne d'une transition énergétique majeure au sein du secteur, dictée par le durcissement des codes énergétiques et des normes de performance minimales. L'amélioration de l'efficacité de l'enveloppe et le recours aux technologies bas-carbone s'accroissent, visant à renforcer l'indépendance énergétique, réduire les factures des usagers et limiter les besoins d'investissements lourds sur les infrastructures de réseau. Cela se traduit par une baisse de la consommation énergétique par unité de surface des bâtiments (intensité énergétique sur figure 1.1).

À l'échelle macroscopique, l'exploitation des bâtiments représente environ 30 % de la consommation énergétique totale mondiale et génère 26 % des émissions de gaz à effet de serre liées à l'énergie [1]. Dans l'Union Européenne, cette part s'élève à 40 % de la demande énergétique globale. Pour atteindre la neutralité carbone, la stratégie repose sur un pivotement massif des combustibles fossiles directs vers les vecteurs électriques renouvelables, objectif formalisé à l'origine par le scénario *Net Zero Emissions by 2030*¹ (NZE) de l'AIE [2].

Dans ce scénario initial, représenté par la figure 1.2, la consommation énergétique globale des bâtiments devait diminuer d'environ 25 % et l'utilisation des combustibles fossiles de plus de 40 % d'ici 2030, tout en éliminant la biomasse traditionnelle au profit de l'accès universel à l'énergie. Au cours de la dernière décennie, la demande énergétique des bâtiments a crû à un taux annuel moyen d'environ 1 %. En 2022, l'électricité représentait déjà 35 % du mix de combustibles du secteur, contre 30 % en 2010,

1. Scénario de l'AIE pour limiter le réchauffement climatique à 1,5°C d'ici la fin du siècle. Le déploiement massif de technologies à faibles émissions (énergies renouvelables, nucléaire, etc.), une forte électrification des transports et de l'industrie, ainsi qu'une amélioration significative de l'efficacité énergétique sont considérés. Ce scénario implique des réductions rapides (au moins 90%) des émissions dès la décennie actuelle, la fin de l'utilisation des énergies fossiles dans la production d'électricité et le développement de puits de carbone pour éliminer les émissions restantes.




FIGURE 1.1 – Superficie mondiale et intensité énergétique des bâtiments de 2010 à 2022 et prédiction pour 2023 suivant le scénario Net Zero Scenario [1].

s'établissant comme le vecteur énergétique hégémonique des prochaines décennies. Cette décennie est cruciale pour la mise en œuvre des mesures nécessaires à la réalisation des objectifs.




FIGURE 1.2 – Consommation d'énergie dans les bâtiments par type de combustible dans le Net Zero Scenario, 2010-2030, [2].

Toutefois, au vu des tendances réelles enregistrées entre 2020 et 2023, ces jalons intermédiaires se révèlent aujourd'hui intraitables à l'horizon 2030. Face au risque de franchissement du seuil critique de réchauffement de 1.5 °C, l'AIE a publié une mise à jour structurelle majeure réalignant les trajectoires de décarbonation et fixant définitivement le cap de neutralité absolue à l'horizon **2050** [3].

Dans cette configuration, les systèmes de chauffage, ventilation et climatisation (CVC/HVAC) constituent le poste de consommation le plus critique du bâtiment. Sous l'effet des vagues de chaleur successives, la climatisation a enregistré la plus forte hausse de la demande parmi tous les usages, affichant une augmentation annuelle supérieure à 3 % [3]. Cette croissance continue des charges met sous tension les prévisions de décarbonation et justifie l'urgence de développer des stratégies de gestion

optimisée. Face à la nécessité de remplacer les combustibles fossiles, la **pompe à chaleur (PAC)** s'impose comme la technologie clé. Présentant une efficacité thermodynamique 3 à 4 fois supérieure aux chaudières thermiques traditionnelles [4], le déploiement massif des PAC détient le potentiel de réduire les émissions mondiales de CO₂ d'au moins 500 millions de tonnes d'ici 2030, soit l'équivalent des émissions annuelles de toutes les voitures en circulation en Europe.

Par conséquent, l'optimisation énergétique de ces équipements devient une priorité dans la conception et l'exploitation des systèmes HVAC modernes. De nombreuses études indiquent qu'une régulation prédictive avancée de ces systèmes permet de réduire sensiblement leur consommation d'énergie et les émissions de gaz à effet de serre associées, avec des économies d'énergie moyennes estimées entre 13 % et 28 % [5]. Cette orientation est fermement soutenue par la politique de l'Union Européenne en matière de performance énergétique (EPBD), récemment révisée, qui stipule que les grands bâtiments devront être équipés de systèmes d'automatisation et de contrôle d'ici 2025, si cela est économiquement et techniquement possible [6].

1.2 Impacts sur le réseau électrique

La transition énergétique et l'électrification croissante des usages ne sont pas sans conséquences pour le réseau électrique. Historiquement, les systèmes électriques alimentant les secteurs résidentiel, commercial et industriel étaient conçus pour suivre une demande relativement prévisible, avec une production centralisée dimensionnée pour satisfaire les pointes de consommation. Cette approche reposait sur une capacité de production pilotable excédentaire, souvent sous-utilisée, activée uniquement lors des périodes de forte demande.

Mais l'intégration massive de productions renouvelables variables, combinée à l'électrification du chauffage et de la mobilité, modifie profondément ce paradigme. La variabilité et l'intermittence des sources renouvelables introduisent de nouvelles contraintes sur l'équilibre offre-demande, tandis que la réduction de l'inertie du système (i.e., moins de machines tournantes) complique la régulation de la fréquence. Par ailleurs, les réseaux de distribution, historiquement conçus pour une alimentation unidirectionnelle depuis des sources centralisées vers les charges, doivent désormais faire face à des flux bidirectionnels et fortement variables.

1.2.1 Impact de l'électrification sur la demande et congestion réseau

L'électrification croissante des secteurs du bâtiment et du transport provoque une augmentation significative de la demande en électricité. Des usages autrefois alimentés par des combustibles fossiles, notamment le chauffage, reposent désormais sur des systèmes électriques tels que les pompes à chaleur, qui, bien qu'elles soient 3 à 4 fois plus efficaces que leurs alternatives fossiles [4], génèrent une charge électrique supplémentaire importante.

Cette évolution modifie également la répartition saisonnière de la demande. Là où les réseaux étaient historiquement caractérisés par des pics estivaux, la demande hivernale tend à augmenter fortement, nécessitant de revoir les stratégies de planification en termes de capacité et de gestion saisonnière.

Un des impacts majeurs de cette électrification est l'accentuation des pics de consommation liés à la puissance instantanée élevée des pompes à chaleur, particulièrement lors des vagues de froid. La concentration géographique de ces systèmes conduit à des pointes de demande locales qui engendrent plusieurs problématiques, telles que :

- Une demande accrue de puissance sur le réseau global.
- Une sollicitation poussée des infrastructures de distribution, causant surtensions, surcharge des lignes et transformateurs.
- Des phénomènes de chutes de tension locales (*sous-tension*) aux points de raccordement.

Contrairement aux réseaux de transport nationaux, les infrastructures de distribution basse et moyenne tension manquent souvent de redondance et risquent des congestions². La saturation répétée des lignes peut donc provoquer des risques de surchauffe et d'endommagement prématuré des équipements.

Bien que la consommation globale annuelle puisse rester maîtrisable, la multiplication de ces congestions locales impose des coûts importants en renforcement d'infrastructures, justifiant la recherche

2. La demande en puissance sur une ligne est supérieure à sa capacité

urgente de solutions alternatives fondées sur la flexibilité de la demande pour soulager ces verrous techno-économiques.

1.2.2 Régulation de la tension et limites thermiques

Les pompes à chaleur (PAC) utilisent généralement des compresseurs entraînés par des moteurs électriques à induction, susceptibles d'engendrer des courants de démarrage élevés ainsi qu'une consommation importante de puissance active et réactive. Dans les réseaux de distribution basse tension (BT), ces appels de courant accrus provoquent des chutes de tension significatives aux points de raccordement des utilisateurs.

Les gestionnaires de réseau de distribution (GRD) sont légalement tenus de maintenir la tension dans des limites réglementaires strictes. En Europe, la norme EN 50160 impose une tolérance de $\pm 10\%$ autour de la tension nominale, tandis que les standards américains (ANSI) restreignent cette marge à $\pm 5\%$. L'accumulation stochastique de chutes de tension modérées, causée par l'adoption généralisée et simultanée des PAC et des véhicules électriques, peut rapidement conduire à des dépassements de ces seuils [7]. Ce défi est exacerbé par la corrélation météorologique locale : l'apparition simultanée de températures froides induit un fonctionnement synchrone des PAC à l'échelle d'un même quartier, saturant localement le plan de tension.

Ces phénomènes s'illustrent à l'aide d'un modèle simplifié de ligne de distribution, voir figure 1.3, modélisé par une impédance série $R + jX$ alimentant une charge telle qu'une pompe à chaleur. La chute de tension stationnaire ΔV s'approxime par la relation :

$$\Delta V \simeq \frac{R \cdot P + X \cdot Q}{V} \quad (1.1)$$

où P et Q représentent respectivement les puissances active et réactive consommées, et V désigne la tension nominale au nœud. Dans les réseaux basse tension, la puissance active P est généralement beaucoup plus élevée que la puissance réactive Q ($P \gg Q$). Couplé au fait que ces réseaux présentent une forte composante résistive, cela mène à un rapport R/X élevé, typiquement compris entre 1 et 3 selon la section des conducteurs [8]. L'effet dominant sur la chute de tension est fourni par le terme résistif $R \times P$. Ainsi, l'appel thermique important lié à P , notamment en période hivernale, accentue fortement la dégradation du plan de tension, tandis que le rôle de la réactance (X) et de la puissance réactive (Q) est relativement moindre dans ce contexte.

En parallèle, l'échauffement par effet Joule ($I^2 R$) impose des contraintes thermiques strictes sur les lignes et les transformateurs. Même sans violation des limites de tension, ces barrières thermiques brident l'exploitation du réseau lors des pointes de demande hivernales synchrones. Le dépassement de ces seuils accélère le vieillissement prématuré des isolants ou déclenche les protections d'urgence, érigeant la congestion thermique et la chute de tension comme les deux verrous majeurs de l'électrification hétérogène des zones résidentielles.




FIGURE 1.3 – Ligne RX avec charge (ex. pompe à chaleur).

1.2.3 Infrastructure

Au-delà des congestions thermiques globales, un défi supplémentaire réside dans la non-uniformité spatiale de l'électrification. La pénétration des PAC, PV et des véhicules électriques s'effectue de manière hétérogène, créant des clusters de forte charge à l'échelle de certains quartiers [9]. Cette concentration locale engendre des risques de surcharge rapide sur les transformateurs de distribution secondaire et sur les lignes basse et moyenne tension.

Les mises à niveau physiques du réseau (remplacement des transformateurs, renforcement de la section des lignes) s'avèrent extrêmement coûteuses, complexes à planifier et lentes à réaliser. L'incertitude quant à l'évolution locale de la demande accentue le risque d'investissements soit excessifs, soit insuffisants.

Face à ces contraintes, la planification moderne des réseaux exige de dépasser l'approche purement infrastructurelle câblée au profit de stratégies de gestion active capables de limiter l'augmentation des pics de charge et de maximiser l'utilisation des actifs existants.

1.3 Solutions et opportunités de l'électrification

Bien que l'électrification massive introduise des contraintes opérationnelles sévères sur les réseaux de distribution, elle offre simultanément des opportunités uniques de flexibilité grâce au déploiement de technologies de contrôle avancées et d'incitations économiques.

1.3.1 Gestion intelligente

Au-delà de l'efficacité thermodynamique intrinsèque des pompes à chaleur, l'électrification des bâtiments permet d'améliorer la résilience des réseaux à travers la gestion active de la demande (*Demand Side Management* - DSM). Les systèmes de gestion de l'énergie domestique (*Home Energy Management Systems* - HEMS) permettent d'exploiter la capacité de stockage thermique passive de l'enveloppe du bâtiment.

Cette stratégie consiste à préchauffer ou pré-refroidir les espaces de manière dynamique lors des heures creuses ou des périodes d'abondance d'énergie renouvelable, pour ensuite effacer la consommation de la PAC durant les pointes de demande du réseau. Cette interaction dynamique permet non seulement de soulager les congestions locales et de prévenir les risques de sous-tension, mais offre également au bâtiment un rôle actif dans le maintien de l'équilibre offre-demande global, réduisant ainsi le besoin de renforcements des infrastructures coûteux.

1.3.2 Productions et stockages décentralisés

L'installation conjointe de systèmes photovoltaïques (PV) et d'unités de stockage décentralisées à proximité des charges constitue une solution mature pour réduire l'impact réseau de l'électrification. L'association d'une PAC et d'une production solaire résidentielle présente une synergie hautement performante. L'électricité photovoltaïque excédentaire, plutôt que d'être injectée sur un réseau saturé à bas coût, peut être valorisée sur site sous forme de stockage avec batterie, par exemple, maximisant ainsi le taux d'autoconsommation du logement.

Des études empiriques démontrent l'efficacité de ce couplage [10] : l'intégration d'un système combiné PAC-PV-Batterie permet d'atteindre des taux d'autoconsommation de l'ordre de 43 %, la part solaire directe dans l'alimentation du chauffage s'élevant à 36 %. De plus, la prise en compte de la flexibilité et de la gestion intelligente permet de faire passer le facteur de performance saisonnier (SPF) combiné de 4.2 à 6.7 [11], optimisant ainsi l'efficacité globale de l'installation.

À long terme, ces charges électrifiées flexibles agissent comme des capacités de réserve³ pour le réseau. À court terme, elles ouvrent la voie à des stratégies d'arbitrage financier, permettant à l'utilisateur de réagir dynamiquement aux fluctuations des prix de marché du jour pour le lendemain (*Day-Ahead*).

En conclusion, les limites opérationnelles des réseaux de distribution face à l'électrification des bâtiments rendent indispensable l'abandon d'une approche purement passive ou purement infrastructurelle. Il devient essentiel de s'orienter vers des solutions de pilotage intelligent des charges. La mise en œuvre de telles stratégies de commande prédictive (*Model Predictive Control* - MPC), capables de concilier les contraintes du marché de l'électricité et le comportement thermique dynamique du bâtiment, renforce la nécessité de disposer de modèles prédictifs à la fois fiables, légers et interprétables. Cette exigence fondamentale constitue la base des développements et des analyses menés tout au long de ce travail.

3. Puissance supplémentaire que le système électrique peut mobiliser rapidement pour faire face aux variations imprévues de la demande ou de la production d'électricité. Ces réserves garantissent la stabilité et la fiabilité du réseau en assurant un équilibre instantané entre offre et demande.

1.4 Marché de l'électricité

L'électrification croissante des habitations déplace les enjeux énergétiques d'un cadre purement technique (tenue en tension, congestions physiques) vers un espace fortement dicté par des signaux économiques et tarifaires. La valorisation de la flexibilité thermique des bâtiments dépend directement de leur capacité à interagir avec les mécanismes de libéralisation des marchés de l'électricité, que ce soit au travers des prix horaires, des marchés infra-journaliers (*Intraday*) ou des services d'équilibrage.

1.4.1 Facture électrique et leviers de flexibilité

La facture d'électricité d'un consommateur final se compose principalement de trois éléments : le coût de l'énergie, les tarifs d'utilisation des réseaux et les taxes. Plus précisément, comme illustré dans la figure 1.4, en Flandres, la part énergétique représente environ 41% du coût total, les coûts liés aux réseaux représentent 28%, les taxes/surcharges 25% et la TVA 6% [12].

Seules les deux premières composantes offrent un levier d'action pour la flexibilité. En effet, le prix de l'énergie évolue selon les conditions du marché, notamment sur le marché day-ahead, tandis que certains tarifs réseau tendent vers des structures dynamiques, comme des tarifs horaires ou tri-horaires. À l'inverse, les taxes sont fixes et indépendantes du comportement de consommation.

L'intérêt d'un pilotage prédictif intelligent repose donc sur la capacité à moduler la demande, en la décalant hors des heures de pointe tarifaires ou des périodes critiques pour les infrastructures, afin d'optimiser la facture et la gestion du réseau.




FIGURE 1.4 – Répartition des composantes du coût résidentiel de l'électricité en Flandres (2026) [12].

L'écosystème électrique belge implique de nombreux acteurs régulés (le gestionnaire de réseau de transport Elia, les gestionnaires de réseaux de distribution ORES et Fluvius, ainsi que les instances de régulation CWaPE et CREG) ainsi que des entités concurrentielles (producteurs, fournisseurs et responsables d'équilibre, les BRP). La structuration de ces flux énergétiques et financiers est décrite plus en détail en sous-section 1.4.2. Dans ce cadre, le rôle du bâtiment s'exprime sur deux niveaux complémentaires : d'une part, l'arbitrage tarifaire individuel pour réduire la facture directe, d'autre part la participation collective via l'agrégation, permettant d'exploiter la flexibilité à plus grande échelle.

1.4.2 Les acteurs du marché

Le marché de l'électricité belge est structuré autour d'un ensemble d'acteurs interdépendants, jouant des rôles complémentaires comme illustré à la figure 1.5.

Producteurs – Ils possèdent et exploitent les installations de production électrique (centrales thermiques, nucléaires, hydroélectriques, éoliennes, photovoltaïques, etc.). Ces entreprises sont soumises à la libre

concurrence, et les consommateurs finaux n'ont pas de contact direct avec elles.

Gestionnaires de réseau de transport – En Belgique, Elia assure cette mission. Il possède, maintient et développe le réseau à très haute tension, garantissant l'acheminement de l'électricité en grandes quantités à travers le pays et les échange transfrontaliers.




FIGURE 1.5 – Acteurs et rôles dans un marché d'électricité libéralisé [13].

Gestionnaire du réseau de distribution (GRD) – Responsables de la distribution d'électricité à basse ou moyenne tension aux consommateurs finaux (ménages, PME) et de la gestion du réseau local, incluant le relevé de compteurs et l'éclairage public. Chaque région dispose de son GRD avec un monopole régional (ex. ORES en Wallonie, Fluvius en Flandre).

Parties responsables de l'équilibre (BRP) – Ces acteurs équilibrent en permanence les injections et soutirages électriques sur le réseau. Ils peuvent être producteurs, fournisseurs ou agrégateurs. Elia supervise l'équilibre du réseau mais ne gère pas les marchés eux-mêmes.

Fournisseurs – Ils achètent l'électricité sur les marchés de gros et la revendent aux consommateurs finaux. Cette activité est ouverte à la concurrence, avec des acteurs tels que Engie Electrabel, Luminus, Eneco ou Ecopower.

Agrégateurs/gestionnaires de flexibilité – Mettent en commun des portefeuilles de petits producteurs ou consommateurs flexibles, leur donnant accès aux marchés de l'équilibre ou d'ajustement, souvent en assumant également le rôle de BRP.

Contrôleurs/régulateurs – Organismes indépendants chargés de veiller à la bonne application des règles, la concurrence loyale et la protection des consommateurs. En Belgique, la CWaPE opère en Wallonie, la CREG au niveau fédéral.

Consommateurs finaux/prosommateurs – Les ménages et entreprises classiques consomment l’électricité fournie par les fournisseurs. Les prosommateurs, eux, produisent aussi de l’électricité (ex. photovoltaïque résidentiel) et injectent leur surplus dans le réseau.

Opérateurs de marchés – Responsables de la tenue des plateformes de mise en relation des acteurs, la gestion des règlements et la surveillance des échanges. On distingue plusieurs types de marchés :

Le marché d’ajustement permet la compensation des déséquilibres en temps réel via des offres à la hausse ou à la baisse.

Le marché de capacité garantit la disponibilité des moyens de production lors des pics, via la vente de capacités (kW), non d’énergie (kWh).

Le marché de détail correspond à la vente d’électricité aux consommateurs finaux, encadrée réglementairement, mais le prix final inclut des coûts et marges propres.

Les marchés de gros sont des espaces d’échange entre producteurs, fournisseurs, traders et opérateurs d’effacement, dont les principaux sont le Day-Ahead (aujourd’hui à tranche de 15 minutes) et l’IntraDay.

1.4.3 Les marchés de gros et le couplage quart d’heure

Pour un contrôle prédictif orienté vers la planification à court terme, le **marché de gros de l’électricité** constitue le segment le plus pertinent. C’est sur ce marché que les producteurs, les traders et les fournisseurs échangent l’énergie pour le lendemain (*Day-Ahead*) ou au cours de la journée même (*Intraday*).

Une évolution réglementaire majeure et hautement structurante pour la flexibilité est intervenue en septembre 2025 : le couplage unique journalier européen (*Single Day-Ahead Coupling* - SDAC) est passé à une granularité temporelle de **15 minutes** sur les frontières belges, remplaçant l’ancienne résolution horaire [14]. Cet alignement au quart d’heure harmonise le marché journalier avec les marchés d’ajustement et de règlement des déséquilibres. Pour la gestion énergétique des bâtiments, cette granularité accrue représente une opportunité majeure : elle permet une planification et une attribution beaucoup plus fines face à l’intermittence du photovoltaïque ou de l’éolien, et justifie mathématiquement l’utilisation d’un pas de temps de 15 min au sein de nos algorithmes d’optimisation et d’identification.

1.4.4 Valorisation de la flexibilité résidentielle : opportunités et risques

Bien que la consommation instantanée d’un logement individuel soit négligeable à l’échelle du réseau national, l’inertie thermique intrinsèque du bâtiment confère aux pompes à chaleur (PAC) un potentiel de stockage passif considérable. Ce levier permet de réaliser du décalage de charge (*load shifting*) sans altérer le confort des occupants. Deux voies complémentaires permettent de valoriser cette flexibilité :

L’approche individuelle par tarifs dynamiques : Les fournisseurs proposent des contrats indexés directement sur les fluctuations du marché *Day-Ahead*. En Belgique, le déploiement de ces structures incitatives (telles que le tarif d’impact tri-horaire) s’accélère. Des études empiriques démontrent que le passage d’un tarif fixe à un tarif dynamique permet à une pompe à chaleur résidentielle de générer des économies annuelles substantielles, estimées entre 540 et 1240 € sous réserve d’une gestion intelligente de l’enveloppe [15]. Pour les prosommateurs combinant une PAC et des panneaux photovoltaïques locaux, l’arbitrage prédictif réduit la facture annuelle de 10 % à 30 % [16].

En Belgique, les tarifs dynamiques sont déjà disponibles en Flandre depuis 2021 et ont commencé à apparaître en Wallonie en 2025. Par ailleurs, les gestionnaires de réseau de distribution, tels qu’ORES, introduisent progressivement des structures tarifaires plus différenciées, comme le tarif impact ou tri-horaire, illustrant une tendance vers une tarification davantage liée à l’état du système électrique.

Cependant, le déploiement massif de cette stratégie individuelle présente un risque technique critique, appelé « **effet avalanche** ». Si une multitude de bâtiments réagissent de manière synchrone et simultanée à un signal de prix bas (notamment lors de plages horaires caractérisées par des prix d’électricité négatifs),

cette concentration crée instantanément de nouveaux pics de charge artificielle résiduelle sur le réseau de distribution, déplaçant et aggravant la congestion au lieu de la résoudre [17].

L’approche collective par communauté d’énergie et agrégation : Pour pallier ce risque et peser de manière crédible sur les marchés de gros, les bâtiments peuvent être regroupés. À l’échelle locale, les communautés d’énergie partagent des actifs de production (PV) et de stockage (batteries) pour optimiser l’autoconsommation collective au sein d’un micro-réseau. Sous la supervision d’un community manager, ces communautés privilégient principalement des échanges locaux d’énergie, assimilables à un fonctionnement de type microgrid. L’objectif est d’optimiser l’autoconsommation collective, de réduire les flux avec le réseau principal et d’améliorer l’efficacité énergétique globale. À cette échelle, un bâtiment unique peut d’ailleurs être vu comme une forme minimale de communauté d’énergie.

À plus grande échelle, les **agrégateurs** unifient des portefeuilles de consommateurs répartis sur le territoire. L’agrégateur agit comme un BRP sur les marchés : il observe les signaux du marché, anticipe les prévisions météo, planifie la stratégie globale à l’horizon *Day-Ahead*, puis transmet des consignes de puissance lissées aux bâtiments participants et répartit la valeur créée entre les différents acteurs, tout en respectant les contraintes de confort. Cette approche collective permet de transformer un ensemble de charges résidentielles diffuses en une ressource énergétique virtuelle stable, capable de soumettre des offres d’effacement sur les marchés de gros tout en résolvant les congestions locales des GRD.

1.4.5 Inscription du projet dans le cadre de la planification day-ahead

C’est précisément dans ce contexte de transition et de tarification dynamique au quart d’heure que s’inscrit ce travail de fin d’études. Le développement de modèles mathématiques capables de capturer la dynamique thermique réelle d’un bâtiment constitue le prérequis indispensable pour formuler des stratégies d’optimisation prédictive robustes sur l’HVAC. En isolant des modèles légers et interprétables via la régression symbolique, ce projet vise à doter les algorithmes de planification *Day-Ahead* d’un outil de prédiction fiable, apte à maximiser les gains financiers d’arbitrage tout en respectant la physique de l’enveloppe et les limites de confort.

1.5 Contexte, motivation et objectifs

Dans un contexte de transition énergétique, le secteur du bâtiment joue un rôle central dans le système énergétique : il représente une part majeure de la consommation mondiale d’énergie et ses besoins continuent de croître sous l’effet de l’électrification des usages, notamment avec le déploiement massif des pompes à chaleur. Cette évolution modifie profondément les profils de consommation électrique et introduit de nouvelles contraintes sur les réseaux de distribution. Elle s’accompagne toutefois d’opportunités majeures telles que l’amélioration de l’efficacité énergétique, l’activation de flexibilités de consommation et une participation accrue des bâtiments à l’équilibre du système électrique.

Parallèlement, l’évolution du marché de l’électricité, marquée par l’introduction de tarifs dynamiques, le développement du marché day-ahead et l’émergence de communautés énergétiques, redéfinit le rôle des bâtiments, qui ne sont plus de simples consommateurs passifs mais deviennent des acteurs à part entière du système énergétique. Dans ce contexte, la capacité à anticiper et à piloter le comportement thermique des bâtiments constitue un levier essentiel, que ce soit pour réduire les coûts énergétiques, valoriser la flexibilité, optimiser l’autoconsommation ou contribuer à la stabilité du réseau.

Quelle que soit la stratégie adoptée, une condition demeure indispensable : disposer de modèles interprétables et fiables capables de représenter la dynamique thermique du bâtiment et son interaction avec les systèmes énergétiques, en particulier les systèmes HVAC. Ces modèles constituent la base des outils d’aide à la décision, de prévision et d’optimisation, et leur qualité conditionne directement la performance des stratégies de pilotage mises en œuvre.

1.5.1 Modèles de dynamique thermique : positionnement méthodologique

Les approches de modélisation thermique des bâtiments peuvent être classées en trois grandes familles : les modèles *white box*, *black box* et *gray box*. Ceux-ci seront explorés plus en détail dans le chapitre État de l’art.

Les modèles *white box*, fondés sur les lois physiques (conduction, convection, rayonnement), offrent une forte interprétabilité et une cohérence physique élevée. Toutefois, ils nécessitent une connaissance détaillée du bâtiment (géométrie, matériaux, systèmes), sont coûteux à paramétrer et peuvent être difficiles à déployer dans des contextes réels à grande échelle, notamment lorsque les propriétés du bâtiment évoluent dans le temps.

À l’opposé, les modèles *black box*, tels que les réseaux de neurones ou autres méthodes de machine learning, permettent d’obtenir de bonnes performances prédictives à partir de données mesurées, avec des exigences limitées en termes de connaissances physiques. En revanche, leur manque d’interprétabilité et de garanties physiques limite leur acceptabilité pour des applications d’aide à la décision ou de planification énergétique, où la compréhension du modèle et la confiance de l’utilisateur sont essentielles.

Les modèles *gray box*, en particulier les modèles RC ajustés, représentent un compromis pertinent entre ces deux approches. Ils combinent une structure physique simplifiée avec une calibration à partir de données, offrant ainsi un bon équilibre entre interprétabilité, précision et complexité. Néanmoins, leur structure reste fixée a priori, ce qui peut restreindre leur capacité d’adaptation à des bâtiments ou des conditions d’exploitation variés.

1.5.2 Motivation et positionnement du travail

Dans ce contexte s’inscrit donc la problématique du TFE : identifier des modèles interprétables pour la dynamique thermique des bâtiments en utilisant la régression symbolique.

La régression symbolique apparaît comme une approche particulièrement prometteuse pour répondre à cet objectif. Contrairement aux modèles *gray box* classiques, elle ne nécessite pas de fixer explicitement la structure du modèle à l’avance. Elle permet d’identifier automatiquement, à partir de données, des équations mathématiques analytiques entre input et output décrivant le comportement thermique du bâtiment. Ces équations sont interprétables, exploitables dans des cadres d’optimisation et potentiellement analysables du point de vue physique.

De plus, bien que la régression symbolique ait été largement étudiée dans d’autres domaines scientifiques, son application à la modélisation dynamique thermique des bâtiments reste encore peu explorée dans la littérature, en particulier dans un cadre orienté planification énergétique et marchés de l’électricité. Ce travail vise donc aussi à évaluer le potentiel de cette méthode dans ce sujet.

1.5.3 Objectifs du TFE

Ce travail se structure autour de deux objectifs principaux. Le premier objectif consiste à développer des modèles dynamiques linéaires et non-linéaires du comportement thermique d’un bâtiment résidentiel unifamilial (2 étages, grenier, garage, chauffage HVAC) à l’aide de la régression symbolique. Ces modèles seront évalués et comparés à des approches de référence largement utilisées, telles que la régression linéaire, les modèles RC ajustés, le benchmark : modèle persistant et la régression quadratique. Les performances seront analysées à l’aide de métriques classiques (erreur quadratique moyenne, capacité de généralisation, complexité du modèle), tout en mettant un accent particulier sur l’interprétabilité et l’exploitabilité des équations obtenues.

Le deuxième objectif vise à intégrer le modèle identifié dans un problème d’optimisation énergétique orienté day-ahead (et non en contrôle prédictif à temps réel, MPC), en tenant compte des tarifs horaires issus du marché day-ahead (après le clearing du marché à 14h, pour un horizon de décision allant jusqu’au lendemain). Ces résultats seront validés par ex-post sur EnergyPlus.

Néanmoins, les méthodes et modèles développés dans ce travail s’inspirent fortement des approches MPC existantes et peuvent constituer une base pertinente pour de futures extensions vers des stratégies de contrôle plus réactives.

Enfin, avant d’introduire en détail la régression symbolique, il est nécessaire de présenter un état de l’art des méthodes de modélisation thermique des bâtiments et des stratégies de contrôle des pompes à chaleur. Le chapitre suivant propose ainsi une revue structurée des approches existantes, permettant de situer ce travail dans le contexte scientifique et technique actuel et de justifier les choix méthodologiques retenus.

Chapitre 2

Etat de l'art

Le contrôle optimal des systèmes thermiques dans les bâtiments, notamment des pompes à chaleur, constitue aujourd'hui l'un des enjeux majeurs dans le contexte du secteur de l'électricité. Il nécessite des stratégies robustes adaptées aux contraintes opérationnelles. Cela implique l'utilisation de modèles pertinents (boîte noire, blanche ou grise) pour représenter le comportement thermique et énergétique des bâtiments, réduire les coûts énergétiques, exploiter la flexibilité disponible et assurer le confort des occupants. Ce chapitre présente ces différents modèles en termes de fonctionnement, interprétabilité, complexité et permettra d'introduire la régression symbolique.

2.1 Le contrôle prédictif pour l'optimisation énergétique

Les contrôles classiques à base de règles (RBC) sont simples et robustes, mais n'exploitent pas pleinement les informations disponibles telles que les prévisions météo, d'occupation ou la dynamique thermique du bâtiment. En revanche, le contrôle prédictif (MPC) utilise un modèle dynamique du bâtiment pour résoudre un problème d'optimisation sur un horizon de prédiction, ce qui le rend adapté au contrôle quasi temps réel.

Bien que ce travail se concentre sur la prévision de la demande pour le jour suivant (single day ahead) plutôt que sur un contrôle en temps réel, la littérature sur le MPC constitue une source d'inspiration très pertinente. Elle insiste sur deux points essentiels pour l'optimisation thermique : La nécessité d'un modèle dynamique fiable capable de représenter l'inertie thermique du bâtiment et l'impact de la précision des prédictions sur la performance énergétique.

2.2 Interprétabilité des modèles thermiques

L'interprétabilité est une notion clé en modélisation thermique, particulièrement lorsque les modèles sont destinés à être exploités dans la commande et l'optimisation des systèmes énergétiques des bâtiments. Elle peut se définir comme la capacité d'un modèle à être compris et expliqué par des utilisateurs humains, facilitant ainsi la confiance, l'analyse et la prise de décision. En pratique, l'interprétabilité implique trois dimensions principales :

- **Simplicité formelle** : Des équations ou structures modulaires compréhensibles facilement, souvent avec peu de paramètres significatifs.
- **Signification physique** : La possibilité d'associer chaque paramètre ou variable à une grandeur physique concrète (résistance thermique, capacité, flux, etc.).
- **Clarté fonctionnelle** : La compréhension du rôle de chaque variable d'entrée sur les résultats, permettant d'expliquer les comportements observés.

Cette notion fait tout particulièrement débat dans la littérature entre modèles « boîte blanche », naturellement interprétables grâce à leurs fondements physiques, et modèles « boîte noire » issus des méthodes statistiques ou d'apprentissage intégral, souvent plus performants mais moins accessibles sur le plan conceptuel. Les modèles « boîte grise » et les approches de régression symbolique cherchent à concilier ces deux exigences. La compréhension claire de ce concept est indispensable avant d'aborder la classification et l'analyse des méthodes de modélisation thermique.

2.3 Classification des approches de modélisation thermique

Nous en venons maintenant aux différents types de modèles. Ceux-ci sont généralement distingués en trois catégories : modèle *white box*, *black box* et *gray box*.

2.3.1 Modèles physique *white box*

Une récente étude menée par Vera-Piazzini et al. (2024) révèle que 62% des articles traitant de la modélisation énergétique des bâtiments dans un échantillon de plus de 200 publications privilégient les méthodes *white box* [18]. Ce constat souligne la prédominance et la confiance accordée à ces approches dans le domaine.

Principe général

Les modèles *white box* reposent sur la physique fondamentale, notamment les lois de conservation de la masse et de l'énergie ainsi que celles de Newton. Ils dérivent des équations pour modéliser la conduction, convection, rayonnement, échanges d'air, etc [19].

Données requises

Ces modèles nécessitent des informations détaillées provenant souvent de plans techniques, audits ou bases de données dédiées : données géométriques (forme du bâtiment, pièces, volumes, ouvertures, ratio fenêtre/mur), données non géométriques (propriétés physiques des matériaux, calendriers d'occupation, systèmes HVAC, prix de l'énergie, consommation), et données climatiques (température, humidité, irradiation solaire, vent), souvent issues de stations météo ou plateformes en ligne comme CBE Climatool, ASHRAE, ou des années météorologiques typiques (TMY). Des outils tels que OpenStudio, SketchUp, et AutoCAD facilitent la modélisation.

Par conséquent, cette dépendance sur des informations physiques détaillées va grandement impacter la précision des résultats obtenus. Collecter des données précises et de haute qualité s'avère crucial pour des résultats consistants et il est même essentiel de mettre à jour régulièrement ces données pour refléter les changements de l'environnement [20].

Avantages et inconvénients

Ces modèles sont très interprétables : chaque paramètre correspond à un élément physique réel, ce qui facilite la compréhension et l'extrapolation. Cependant, ils sont coûteux en calcul et complexes à concevoir, requérant une géométrie précise et une expertise technique poussée. Ils ne conviennent pas toujours aux études rapides ou à grande échelle. Il est indispensable de maîtriser la physique du bâtiment, les normes en vigueur (ISO 13790, EN ISO 52016, etc.), la géométrie et les propriétés des matériaux, ainsi que les outils de modélisation et de simulation. [19].

Modèles résistance/capacité aggrégé (lumped RC)

Les modèles lumped RC s'inspirent des analogies avec les réseaux électriques où les capacités thermiques représentent les masses (murs, sols, volumes d'air) et les résistances thermiques modélisent les transferts de chaleur (conduction, convection, rayonnement). Les nœuds du réseau correspondent à des températures représentatives de zones ou d'éléments du bâtiment.

La division du bâtiment en zones thermiques améliore la précision mais complexifie le modèle et son identification. Dans cette modélisation, les températures zonales sont considérées comme des sorties, tandis que la température extérieure, le rayonnement solaire, la puissance de chauffage, etc. sont sélectionnés comme entrées.

Les hypothèses importantes et courantes de ce modèle incluent un air homogène dans chaque zone, des coefficients de transfert de chaleur constants, un taux de ventilation naturelle constant, une conduction unidimensionnelle dans les composants et une répartition uniforme des puissances de chauffage.

La dynamique thermique s'exprime par un système d'équations différentielles ordinaires, dont l'ordre dépend du nombre de capacités thermiques utilisées (ex : 1R1C, 2R1C, 3R2C) [21]. Par exemple, l'équilibre énergétique nodal s'écrit :

$$C_n \frac{dT_n}{dt} = \sum_i \frac{T_i - T_n}{R_{n,i}} + \sum_j w_j Q_j \quad (2.1)$$

où C_n est la capacité thermique, R_i les résistances thermiques aux éléments voisins i , T les températures, Q_j est l'apport thermique direct j qui entre dans le nœud n (par exemple, le rayonnement solaire) et w_j est un facteur de pondération/poids (par exemple, l'ouverture solaire) qui évalue l'apport thermique Q_j [22].

La figure A.1 illustre un modèle type 2R2C et ses équations d'état. Une fois établies, ces équations sont résolues analytiquement dans certains cas ou au moyen d'un solveur.

Ces modèles offrent un bon compromis entre interprétabilité et coût de calcul. Leur structure mathématique simple permet des simulations rapides, ce qui les rend adaptés à la modélisation de nombreux bâtiments ou à des simulations sur de longues périodes. Les paramètres physiques (R et C) ayant une signification concrète, le modèle reste interprétable et traçable. Si le bâtiment est bien caractérisé (géométrie, matériaux, surfaces, volumes...), le modèle peut être assez robuste.

Cependant, l'approximation "lumped" suppose que la température à l'intérieur d'un élément (mur, volume) est homogène — ce qui n'est pas vrai si des gradients spatiaux importants existent. C'est particulièrement vrai si le nombre de "lumps" (capacités) est faible. Des études montrent que l'erreur peut devenir significative, notamment quand le nombre de "nœuds" est trop bas ou que la variation spatiale du flux de chaleur est importante. La fidélité de ce modèle est impactée par l'ordre choisi et peut entraîner un manque de précision [23].

Méthodes numériques distribués

Contrairement aux modèles lumped RC, les modèles distribués reposent sur des équations aux dérivées partielles (PDE), des méthodes spectrales [24] ou des simulations de dynamique des fluides numérique (CFD) [25]. Ils modélisent la distribution spatiale des températures et flux thermiques dans les parois et zones, capturant ainsi des phénomènes locaux complexes comme les gradients thermiques ou les interactions air-surface.

Ces modèles offrent une grande précision, utile pour analyser des phénomènes détaillés (hétérogénéité des matériaux, zones distinctes dans une même pièce, etc.) et simuler diverses configurations (isolation, systèmes thermiques ajoutés) [24].

Cependant, leur coût computationnel élevé limite leur usage à grande échelle ou pour des simulations rapides. De plus, une connaissance précise de la géométrie, des matériaux et des conditions limites est indispensable.

Outils de simulation *white box* : EnergyPlus

Parmi les nombreux outils basés sur des modèles *white box*, EnergyPlus est une référence open source largement utilisée [26]. Ce logiciel sera employé dans ce travail pour générer les données historiques alimentant la régression symbolique et pour obtenir les résultats ex-post.

EnergyPlus simule la consommation énergétique des bâtiments (chauffage, climatisation, charges électriques, etc.) avec des fonctionnalités avancées : calculs simultanés, intervalles de temps flexibles sous une heure, modélisation détaillée des transferts de chaleur et masse, modèles sophistiqués de fenestration, modélisation composant par composant de l'HVAC, et stratégies prédéfinies de contrôle HVAC et éclairage [27].

Le modèle repose sur des bilans de chaleur et masse par zone thermique, avec des hypothèses majeures : l'air dans chaque zone est supposé bien mélangé à température uniforme, et les surfaces des pièces ont des températures et rayonnements uniformes, avec une conduction thermique unidimensionnelle [26].

Pour chaque zone, EnergyPlus équilibre les flux entrants et sortants liés à la conduction, convection air-surface, rayonnement, apports internes, gains solaires, infiltration, ventilation, et système HVAC. La simulation intègre le bilan énergétique et d'humidité par zone [28].

Selon la finesse de la modélisation (nombre de zones, description HVAC, ventilation, inertie thermique), EnergyPlus peut servir de modèle *white box* très détaillé.

La figure 2.1 illustre le schéma général : entrée avec fichiers EPW (météo) et IDF (bâtiment) ; sortie en formats CSV ou HTML [27].




FIGURE 2.1 – Schéma générale des simulations EnergyPlus [27].

Comme illustré sur la figure 2.1, le logiciel prend en entrée des fichiers EPW pour le climat et idf pour la modélisation du bâtiment. En sortie, il fournit des fichiers de données csv ou html.

Applications

Plusieurs études récentes viennent illustrer les avancées majeures réalisées autour des modèles *white box* pour la modélisation thermique des bâtiments.

Tol et Madessa [21] ont développé un modèle dynamique *white box* intégrant explicitement un système de chauffage. Leur approche détaille l'interaction thermodynamique entre l'enveloppe et l'équipement, permettant une meilleure représentation des transferts énergétiques couplés et une base solide pour les stratégies de contrôle.

Wang et al. [22] ont proposé une simplification structurale des modèles RC traditionnels pour une analyse dynamique thermique. Leur méthode vise à réduire la complexité du modèle tout en conservant la précision nécessaire aux études prédictives, offrant ainsi un bon équilibre entre rapidité de calcul et fidélité physique.

Berger et al. [24] ont comparé trois méthodes numériques appliquées à la simulation des bâtiments : différences finies, approximation par réseau RC, et méthode spectrale. Cette étude a mis en lumière les compromis entre précision, coût informatique et applicabilité pratique de ces approches, soulignant la pertinence continue des modèles RC dans un large éventail de cas.

Balali et al. [25] ont réalisé une revue exhaustive sur la modélisation et le contrôle énergétique des systèmes de chauffage et refroidissement, combinant modèles à base de données (*data-driven*) et hybrides. Ils montrent comment les approches *white box* peuvent être efficacement intégrées à des techniques statistiques pour augmenter la robustesse des prédictions.

Enfin, Crawley et al. [26] présentent EnergyPlus, un simulateur de nouvelle génération reposant sur un modèle *white box* détaillé. EnergyPlus est aujourd'hui la référence pour la génération de données historiques de haute qualité, la validation et la calibration de modèles thermiques, et constitue un outil incontournable dans l'étude et la gestion énergétique des bâtiments modernes.

Ces travaux illustrent la richesse et la diversité des applications des modèles *white box*, mettant en valeur leur rôle fondamental dans la compréhension physique des phénomènes thermiques et leur intégration dans les outils de simulation et contrôle.

2.3.2 Modèles data-driven *black box*

Contrairement aux modèles *white box* fondés sur la modélisation physique, les modèles *black box* apprennent directement la relation entre entrées (météo, consignes, apports internes, etc.) et sorties (consommation, températures) à partir des données, sans modéliser la physique interne. Ils s'appuient sur des techniques de machine learning appliquées aux séries temporelles énergétiques.

Principe général

La méthodologie des modèles *black box* est standard en machine learning, schématisé à la figure A.2. Elle comprend plusieurs étapes clés, nécessaires pour construire un modèle robuste et performant de prédiction énergétique :

1. **Collecte des données** : acquisition de données variées sur les bâtiments et sur les conditions météorologiques.
2. **Prétraitement des données** : nettoyage, transformation, mise à l'échelle (rescaling), standardisation et/ou normalisation des données pour assurer une qualité homogène et une bonne performance des algorithmes d'apprentissage.
3. **Sélection des caractéristiques (feature selection)** : identification des variables les plus pertinentes à utiliser dans le modèle. Cette étape est cruciale car elle influence fortement la précision et la généralisabilité du modèle. Une mauvaise sélection peut dégrader les performances. Cette phase fait l'objet d'une littérature abondante et reste un challenge majeur pour les chercheurs [29].
4. **Partitionnement des données et validation** : séparation des données en jeux d'apprentissage (train) et de test, souvent selon un ratio typique 70%/30%, complétée par des techniques de validation croisée (ex. K-fold) pour évaluer la capacité de généralisation du modèle.
5. **Entraînement du modèle** : choix, optimisation et ajustement des paramètres d'un algorithme d'apprentissage automatique sur le jeu d'entraînement.
6. **Prédiction et évaluation** : application du modèle entraîné sur le jeu test pour estimer la consommation énergétique, suivie d'une évaluation des performances selon des métriques adaptées (erreur quadratique, erreur absolue, etc.).
7. **Amélioration itérative** : les résultats d'évaluation peuvent servir à affiner le choix des caractéristiques, l'algorithme, ou le prétraitement dans un cycle itératif.

Ce processus, bien que standard, illustre la nature entièrement data-driven des approches *black box*, sans recours explicite à la modélisation physique, ce qui peut limiter leur interprétabilité et la confiance dans leurs prédictions hors des domaines d'apprentissage.

Nature et qualité des données

La qualité des données est un facteur clé pour la réussite des modèles *black box*, mais il est important de noter qu'ils n'exploitent pas systématiquement les mêmes types de données que les modèles *white box*. Comme mentionné précédemment, les modèles *white box* reposent sur une modélisation basée sur la physique du bâtiment et nécessitent des données détaillées et structurées. À l'inverse, les modèles *black box* s'appuient principalement sur des données historiques mesurées sous forme de séries temporelles, telles que la température intérieure, la température extérieure, la consommation électrique et les consignes de chauffage ou refroidissement. Ils peuvent également intégrer d'autres sources de données comme les capteurs ou données opérationnelles, souvent sans recourir à une description physique explicite du bâtiment. Ces modèles s'appuient uniquement sur des techniques statistiques et d'apprentissage automatique pour découvrir des relations entre les entrées et les sorties, sans a priori physique.

Cette différence structurelle implique que les modèles *black box* exploitent une diversité de données qui peuvent parfois être moins détaillées sur la structure physique, mais plus riches en observations effectives. Toutefois, quel que soit le type de données utilisé, la qualité reste essentielle : des données incomplètes, bruitées, incohérentes ou peu représentatives risquent de conduire à des modèles mal calibrés, limitant leur capacité de généralisation au-delà des conditions observées [30].

Pour qu'un modèle *black box* soit fiable, les données doivent respecter plusieurs critères de qualité : **Exhaustivité** : toutes les variables nécessaires doivent être mesurées sur la période étudiée, sans lacunes importantes.

Faible bruit : les données doivent être exemptes d'erreurs de mesure importantes qui pourraient induire le modèle en erreur.

Cohérence et précision : les mesures doivent être homogènes dans le temps et cohérentes entre elles (ex : température intérieure cohérente avec la puissance de chauffage mesurée).

Variabilité représentative : les données doivent couvrir différents régimes de fonctionnement du bâtiment (jours chauds, froids, occupation variable, charges HVAC différentes).

Par exemple, l'absence de mesures de consommation pendant plusieurs jours, ou des données HVAC incohérentes, pourraient entraîner une mauvaise estimation des relations entre température extérieure et consommation énergétique.

C'est pour cela que la vérification de la qualité des données et la sélection de variables pertinentes sont des étapes préliminaires essentielles avant d'entraîner un modèle. Une fois ces étapes réalisées, on peut s'assurer que le modèle dispose d'informations fiables pour apprendre et généraliser correctement.

Avantages et inconvénients

Ces modèles sont simples à mettre en œuvre et rapides. Au contraire des méthodes *White box*, ils ne nécessitent pas une expertise en physique, les seuls pré-requis étant en data-science. Ils conviennent bien à la prévision énergétique, à l'analyse comparative ou à la détection de dérives.

Leur principal inconvénient est leur manque d'interprétabilité : ils prédisent sans expliquer. Le fonctionnement interne du modèle reste opaque (« on sait qu'il prédit bien, mais on ignore pourquoi »). Cela complique son utilisation pour la prise de décision ou pour le contrôle. De plus, leur robustesse hors des conditions d'apprentissage est faible, dépendant fortement de la qualité des données et ils perdent rapidement en précision dès que les conditions changent (par ex. rénovation ou changement des usages). La qualité des données est donc essentielle.

Enfin, des défis persistent pour des applications à grande échelle en raison de la complexité de la classification et de la préparation des données pour la simulation, d'après [31].

Support vector machine

Les SVM sont des modèles black box plus sophistiqués, adaptés à la classification et la régression non linéaire. Il est couramment appliqué avec différentes fonctions (kernel) pour mapper les variables d'entrée d'origine dans un espace de caractéristiques à haute dimension, ce qui introduit la non-linéarité dans la solution, et identifie les hyperplans optimaux dans ces espaces afin de classer ou de prédire des points de données [20].

Ils sont efficaces en haute dimension, utilisent un sous-ensemble de données (vecteurs de support) pour réduire les besoins en mémoire, et excellent pour modéliser des systèmes énergétiques complexes grâce à leur capacité à gérer la non-linéarité [32].

Dans la gestion énergétique des bâtiments, ils servent à prédire la consommation, identifier des anomalies et classer les états opérationnels, apportant ainsi des outils puissants pour l'optimisation et la prise de décision [27]. En fournissant des modèles précis et affinés des comportements énergétiques, les SVM contribuent de manière significative à l'amélioration des mesures d'efficacité énergétique et à l'optimisation des processus opérationnels, consolidant ainsi leur rôle d'outils indispensables dans la boîte à outils stratégique des professionnels de la gestion énergétique [27].

Applications

Selon la revue de Vera-Piazzini et al. [18], 11 % des articles sur la modélisation énergétique des bâtiments utilisent l'approche black box (parmi 200 publications de 2017 à 2022).

Parmi la littérature récente, les méthodes black box les plus courantes incluent : les réseaux neuronaux artificiels (ANN) [33] et modèles récurrents (RNN), les machines à vecteurs de support (SVM) [33], les méthodes ensemblistes comme Random Forest (RF) [27] et les algorithmes génétiques (GA) utilisés pour la sélection de caractéristiques ou l'optimisation [34]. Une présentation générale de ces méthodes est offerte dans [35].

Oka et Komamura [36] ont appliqué deux GA pour optimiser la capacité des équipements et la planification opérationnelle du système HVAC sur 24 heures, démontrant la capacité des GA à concevoir des designs optimaux pour des systèmes complexes.

Wong et al. [37] ont utilisé un ANN pour prédire la consommation énergétique d'immeubles de bureaux en climat subtropical, intégrant variables climatiques, caractéristiques de l'enveloppe et type de jour. Leur modèle prédit efficacement la consommation quotidienne liée au refroidissement, chauffage, éclairage et total bâtiment.

Li et al. [38] ont utilisé des SVM en régression pour prédire la demande horaire de climatisation à Guangzhou (Chine), comparant leur méthode à trois algorithmes de réseaux neuronaux. Les SVM et GRNN ont surpassé RBFNN et BPNN en précision et généralisation.

Wang et al. [39] ont appliqué des modèles RF pour prévoir la consommation horaire de deux écoles en Floride, comparant différents paramètres. Le RF a montré supériorité face à l'arbre de régression (RT) et la régression par vecteurs de support (SVR), avec une robustesse aux variations des variables d'entrée.

2.3.3 Modèles hybrides *gray box*

Les modèles *gray box* ou hybrides constituent une approche intermédiaire entre les modèles purement physiques (*white box*) et entièrement statistiques (*black box*). Ils reposent sur une représentation physique simplifiée du bâtiment, avec des paramètres calibrés à partir de données mesurées historiques. Cette combinaison offre des modèles à la fois interprétables, adaptables et rapides à simuler.

Principe général

Le modèle *gray box* s'appuie sur une structure physique prédéfinie (souvent un réseau résistances-capacités, RC), tandis que les paramètres thermiques (résistances, capacités, gains internes) sont ajustés statistiquement à partir de données expérimentales ou opérationnelles. Contrairement aux modèles *black box*, ces paramètres conservent une signification physique claire, intégrant automatiquement les spécificités du bâtiment (inertie réelle, ponts thermiques, occupation).

La chaîne de modélisation typique (figure A.3) utilise les caractéristiques du bâtiment, conditions climatiques, données opérationnelles et paramètres techniques pour structurer un modèle d'ordre réduit. Ce dernier est résolu via un solveur d'équations différentielles ordinaires (ODE) afin d'estimer températures et charges thermiques [20].

Avantages et Inconvénients

- De part leur nature alliant *black box* et *white box*, ces modèles présentent plusieurs avantages [40] :
- Interprétabilité élevée : paramètres à signification physique explicite, facilitant l'analyse par les experts.
 - Besoin limité en données. Les paramètres d'entrée ne doivent pas être fixés au temps initial [34].
 - Calibration capturant des phénomènes difficiles à modéliser explicitement (inertie effective, usage, apports internes).
 - Modèles linéaires ou faiblement non linéaires, rapides à simuler, adaptés au contrôle et à la prévision sur horizons courts à moyens.

Cependant, l'identification correcte des paramètres nécessite des données présentant une variabilité temporelle suffisante. Sans cela, les paramètres peuvent devenir non identifiables ou fortement corrélés. La structure RC impose aussi des hypothèses (inertie homogène, capacité concentrée sur peu de nœuds), ne capturant pas les effets spatiaux fins. L'ajustement simultané des états et paramètres peut être instable ou sensible aux conditions initiales, surtout pour plus de 2–3 nœuds. Des techniques robustes (MCMC, filtrage stochastique) sont parfois nécessaires, au prix d'un temps de calcul plus important.

Régression linéaire

Parmi ces modèles, la régression linéaire est l'une des méthodes les plus répandues en machine learning, grâce à sa simplicité et ses bonnes performances. Appliquée à la gestion énergétique des bâtiments, elle présente des atouts mais aussi certaines limites. Fondamentalement, elle cherche à modéliser la relation entre une ou plusieurs variables indépendantes (climat, paramètres physiques ou thermiques, etc.) et une variable dépendante (souvent la consommation ou la température) sous la forme d'une combinaison linéaire des variables explicatives [32]. Ce modèle est formalisé par l'équation classique [41], [42] :

$$y_i = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p + e \quad (2.2)$$

où y_i est la variable dépendante (sortie) à la i -ème observation, x_j les variables indépendantes (entrées), b_0 l'ordonnée à l'origine, b_j les coefficients de régression indiquant l'influence de chaque variable explicative, et e l'erreur aléatoire. La fonction objectif consiste à minimiser la somme des carrés des erreurs (moindres

carrés) entre valeurs prédites et observées :

$$\min \sum_{i=1}^n \left(y_i - \sum_{j=1}^p x_{ij} \beta_j - \beta_0 \right)^2 \quad (2.3)$$

Contrairement à un modèle purement boîte noire, la régression linéaire est une approche de ****boîte grise**** dans la mesure où elle propose une forme explicite et interprétable de la relation entre variables. Chaque coefficient peut être suivi et compris, facilitant l’analyse des comportements modélisés. Toutefois, elle ne repose pas directement sur des principes physiques, et les relations modélisées restent uniquement statistiques. Cette nature interprétable permet aux acteurs du secteur énergétique de comprendre l’impact relatif des variables et de prendre des décisions pragmatiques, éclairées par les données, sans nécessiter la compréhension détaillée des processus physiques sous-jacents [27]. Cependant, les limites de la régression linéaire apparaissent notamment dans la prise en compte des interactions complexes et non linéaires caractéristiques des systèmes énergétiques modernes. Cela souligne la nécessité d’une palette diversifiée d’outils analytiques pour s’adapter aux différentes situations. Malgré cela, pour des bâtiments simples ou des problématiques de prévision basiques, la régression linéaire reste une solution robuste et souvent suffisante [41].

Exemple : RC ajusté

Parmi les modèles *gray box*, on retrouve notamment le réseau thermique R–C avec un nombre réduit de nœuds, représentant à un niveau abstrait les transferts conductifs, convectifs et radiatifs d’un bâtiment. Contrairement à un modèle *white-box* classique — dont les paramètres proviennent directement des propriétés physiques du bâtiment — les paramètres physiques (résistances thermiques, capacités, coefficients convectifs, gains internes) sont estimés et ajustés à partir des données : mesures de température intérieure, données météo, mesures d’apports internes, consommation HVAC, etc [43].

La dynamique du modèle est alors exprimée par un système d’équations différentielles ordinaires (ODE), typiquement sous la forme :

$$C_n \frac{dT_n}{dt} = AT + Bu + w \quad (2.4)$$

où T représente les températures (nœuds RC), u les excitations externes (température extérieure, ensoleillement, consigne HVAC), C et A sont des matrices physiques mais inconnues, et w un terme d’erreur ou de bruit. Ces paramètres sont ajustés via des méthodes d’estimation d’état et de paramètres, souvent en temps discret via des algorithmes comme l’Extended Kalman Filter (EKF), l’Unscented Kalman Filter (UKF), les méthodes de maximum de vraisemblance, ou l’estimation bayésienne (MCMC). Lecocq et al. [44] montre le développement d’un modèle R2C2 ajusté et l’a comparé au RC physique.

Applications

L’étude de Vera-Piazzini et al. [18] montre que 27 % de la littérature récente utilisent l’approche boîte grise (basé sur 200 papiers de 2017 à 2022).

Une technique hybride fréquemment utilisée consiste à coupler un modèle thermique de bâtiment avec des algorithmes génétiques pour l’identification des paramètres. Plus précisément, un nombre donné d’ensembles de paramètres est produit par l’algorithme génétique et chacun d’entre eux est testé sur le modèle thermique. La valeur d’aptitude est ensuite évaluée comme l’erreur de la sortie du modèle. L’ensemble de paramètres donnant la plus petite valeur d’aptitude est alors la meilleure solution [34].

Znouda et al. [45] ont étudié la consommation énergétique d’un bâtiment méditerranéen en Tunisie en considérant l’efficacité énergétique et l’aspect économique. Ils ont associé un outil simplifié d’évaluation thermique des bâtiments spécifique aux pays méditerranéens, appelé CHEOPS, à un algorithme génétique permettant d’identifier les paramètres architecturaux. Ils ont étudié les problèmes énergétiques et économiques de manière indépendante. Ils ont montré qu’il est difficile de résoudre ce type de problème multi-objectifs composé de deux problèmes indépendants.

Une deuxième technique a été introduite dans les années 1990 par Lam et al. [46], consistant à générer une base de données à partir d’un logiciel de simulation thermodynamique. Celles-ci sont ensuite

utilisées comme paramètres d'entrée dans un outil de régression (régression multivariée, ANN et SVM). L'avantage est qu'il est possible de prédire les résultats à partir des équations de régression sans avoir recours au logiciel de simulation.

Xu et al. [47] ont établi un modèle couplant le logiciel nodal EnergyPlus à un réseau neuronal artificiel pour prédire la consommation d'énergie. Plus précisément, ils ont généré une base de données à partir du modèle thermique qu'ils ont utilisé comme paramètres d'entrée du ANN. Après avoir été entraîné, le ANN a été capable de déduire la prédiction de la consommation d'énergie.

Wang et al. [22] ont créé un modèle RC physique d'une maison avant de le simplifier en un modèle réduit. il est ensuite couplé avec un GA pour montrer que le modèle reste valable et ne présente pas de diminution évidente de précision.

Aydinalp-Koksal et Ugursal [48] ont utilisé la régression linéaire multiple [34], pour modéliser la consommation énergétique finale résidentielle au Canada à l'échelle nationale, avec des régressions distinctes pour chaque usage (appareils électroménagers, éclairage, HVAC, eau chaude sanitaire).

2.4 Synthèse comparative

Dans la modélisation de la dynamique thermique des bâtiments, plusieurs types de modèles sont couramment utilisés. Chacun présente des avantages, des limites et des usages différents. Ces modèles sont généralement classés en trois catégories : white box, gray box et black box, comme résumé dans tableau 2.1.

White box – Ces modèles sont construits sur la physique complète des bâtiments et utilisent des équations décrivant la conduction, la convection, le rayonnement, etc. Ils sont très interprétables et précis, mais nécessitent des données détaillées et des ressources computationnelles importantes.

Gray box – Ces modèles hybrides combinent une structure physique simplifiée avec une calibration de leurs paramètres à partir de données mesurées. Ils offrent un bon compromis entre précision, rapidité de simulation et interprétabilité. Ils sont souvent utilisés pour le contrôle prédictif ou la prévision de charge.

Black box – Ces modèles se basent uniquement sur des données historiques et des méthodes d'apprentissage automatique/statistiques pour établir leurs relations entre entrées et sorties. Ils sont rapides à déployer et efficaces si de grandes quantités de données sont disponibles, mais leur interprétabilité est faible et leur extrapolation hors du domaine connu est limitée.

Le tableau 2.2 complète cette vue d'ensemble en présentant des exemples concrets de modèles utilisés pour chaque famille, leur structure, complexité, interprétabilité et usage typique. On peut citer par exemple :

Pour les modèles white box, des modèles à équations différentielles partielles ou des réseaux RC détaillés, utilisés dans des simulateurs comme EnergyPlus.

Pour les modèles gray box, des modèles RC à paramètres ajustés ou des modèles à ordres réduits (ROM), adaptés au contrôle optimal et à la calibration sur données. La complexité des modèles RC gray-box réside moins dans leur structure que dans l'identification et la calibration des paramètres. Les ROM, quant à eux, sont très légers à simuler et déplacent la complexité en amont (réduction). Nous retrouvons aussi la régression linéaire, l'une des méthodes de machine learning la simple.

Pour les modèles black box, des modèles statistiques ou d'apprentissage automatique tels que les SVM, les random forests ou les réseaux neuronaux.

Ce tableau permet de comparer les approches selon leur base théorique, besoins en données, complexité et degré d'interprétation, et éclaire les choix de méthodes adaptés aux objectifs visés.

2.5 Transition vers la régression symbolique

Les tableaux 2.1 et 2.2 permettent de comparer les différentes familles de modèles sous plusieurs aspects. Si les modèles white box offrent une grande précision et une interprétation directe des phénomènes physiques, ils restent coûteux à construire et à simuler, surtout pour des systèmes complexes. Les modèles black box, en revanche, permettent des prédictions rapides à partir de grandes quantités de données,

TABLE 2.1 – Comparaison des approches de modélisation thermique des bâtiments.

	Base	Données requises	Interprétabilité	Avantages	Inconvénients	Références
White box	Lois physiques complètes (PDE, bilans d'énergie, multi-zones)	Géométrie, matériaux, systèmes HVAC, infiltration, usages	Très élevée (chaque paramètre a une signification physique)	Extrapolation fiable, précision, robustesse aux variations	Données nombreuses, calibration lourde, temps de calcul important	[19], [20], [21], [22], [34]
Gray box	Physique simplifiée + identification paramétrique (RC, systèmes d'état, SDE, régression linéaire)	Variables d'état (T° , flux, consommation)	Moyenne à élevée (paramètres liés à inertie et résistances)	Bon compromis précision / complexité, rapide, adapté au contrôle	Structure imposée a priori, dépend de la qualité des données, simplifications fortes	[20], [40], [34], [44]
Black box	Apprentissage statistique pur ou ML (régression, SVM, NN, symbolic regression)	Données entrées/sorties : météo, usage, températures, puissance	Faible (sauf symbolic regression)	Flexible, performant avec beaucoup de données, simple à entraîner	Mauvaise extrapolation, non causal, dépend fortement des données	[29], [27], [30], [31], [34]

mais leur opacité limite la compréhension des dynamiques sous-jacentes et la confiance dans leurs extrapolations. Les modèles gray box offrent un compromis, mais leur structure doit être prédéfinie et les paramètres calibrés à partir des données, ce qui peut s'avérer restrictif lorsque les dynamiques exactes du système sont inconnues ou changent.

C'est dans ce contexte que prend place le sujet de notre travail de fin d'études, la régression symbolique. Au-delà des modèles classiques, les utilisateurs doivent prendre des décisions concernant le contrôle de leurs systèmes HVAC. L'interprétabilité d'un modèle est donc un aspect essentiel à considérer.

Nous allons étudier la régression symbolique et ses performances. Elle combine les avantages des approches gray box et black box :

interprétabilité élevée – La régression symbolique (SR) génère des équations mathématiques explicites représentant la dynamique thermique, offrant aux ingénieurs et décideurs la possibilité de comprendre et justifier les relations identifiées entre variables.

Découverte de structure automatique – Contrairement aux modèles gray box classiques, la SR ne requiert pas de pré-définir la structure du modèle. Elle explore l'espace des équations possibles pour identifier celles qui décrivent le mieux le système à partir des données.

Adaptabilité et extrapolation – En produisant des modèles basés sur des lois fonctionnelles explicites, la SR offre une meilleure capacité d'extrapolation que les modèles black box, utile notamment pour la prévision day-ahead sur des bâtiments et réseaux énergétiques évolutifs.

Compatibilité avec les données disponibles – La SR fonctionne à partir de séries temporelles et mesures classiques (températures, flux thermiques, données météo, apports HVAC), sans nécessiter la connaissance complète et détaillée de la géométrie ou des matériaux.

Cette approche mérite pleinement l'attention qui lui est portée ici et justifie sa comparaison avec les modèles classiques RC et régression linéaire présentés précédemment. À notre connaissance, peu d'études scientifiques explorent l'application de la régression symbolique à la modélisation thermique des bâtiments, ce que ce travail vise à enrichir.

TABLE 2.2 – Exemples de modèles utilisés pour la modélisation thermique des bâtiments avec leur interprétabilité, complexité et références.

	Modèle	Nature/ Structure	Interpré- tabilité	Complexi- té	Usage typique
White box	CFD	Équations de Navier-Stokes	+++	+++	Simulation fine [25], [24]
	PDE 3D + bilans thermiques	Équations de conduction, convection, rayonnement	+++	+++	Outils de Simulation (EnergyPlus [26], Modella, TRNSYS)
	Modèles RC multi-nœuds détaillés	Réseau thermique complexe (multi-parois)	++	++	[21], [22]
Gray box	RC ajusté (2R1C, 3R2C...)	Équations d'état + estimation paramètres	++	+ à ++	MPC, estimation inertie, calibration sur données [44]
	ROM (Reduced Order Model)	PDE → modèle réduit faible dimension	+	-	Contrôle optimal, prévision rapide [43]
	Régression linéaire multivariée	Modèle statistique simple	+	-	Baseline, comparaison simple, [48]
Black box	SVM / Random Forest	ML discriminant / ensembles	-	+	Prédiction brute non-interprétable, [38], [39]
	Réseaux neuronaux (MLP, LSTM)	Apprentissage profond	- -	+ à ++	Séries temporelles complexes, [37]

2.6 Outils existants et applications à la thermique du bâtiment

La diversité des approches de régression symbolique a conduit au développement de nombreux outils logiciels, systématiquement comparés par Cranmer [49]. Parmi ces frameworks, la bibliothèque PySR se distingue par plusieurs atouts :

Optimisation multi-objectif et front de Pareto : Au lieu de fournir un modèle unique, PySR génère un ensemble d'équations non dominées selon le compromis précision-complexité, donnant à l'ingénieur la liberté de choisir la structure la plus robuste ou interprétable.

Intégration de connaissances a priori : Le code permet d'imposer des formes fonctionnelles admissibles, de contraindre l'imbrication des opérateurs et de pénaliser spécifiquement la complexité, garantissant une extrapolation physiquement cohérente.

Architecture hybride haute performance : PySR combine la flexibilité d'une interface Python avec la puissance d'exécution de son backend en Julia, facilitant son intégration dans les pipelines d'apprentissage modernes sans sacrifier la vitesse.

L'intérêt d'exploiter la régression symbolique pour la modélisation thermique et la gestion énergétique est confirmé par plusieurs travaux récents :

Potentiel de flexibilité et MPC : Des études montrent qu'un contrôle prédictif basé sur des modèles issus de SR peut réduire jusqu'à 16,1% la demande de puissance de pointe d'un bâtiment sans nuire au confort ni augmenter la consommation totale [50].

Découverte d'enveloppes sur de grands parcs : Sur un échantillon de 241 bâtiments, des familles d'expressions analytiques ont été découvertes automatiquement, surpassant la précision de modèles de référence comme XGBoost, tout en offrant une interprétabilité totale [51].

Ce double constat — robustesse informatique de PySR et pertinence des équations générées pour le contrôle prédictif HVAC — justifie l'intégration de cette méthodologie dans notre étude.

Dans les chapitres suivants, nous allons entrer en détail dans la méthodologie avec l'optimisation qui sera utilisée ainsi que la régression symbolique.

Chapitre 3

Optimisation

La commande classique de type Tout-ou-Rien (On-Off), fréquemment intégrée dans les thermostats, présente une limitation fondamentale : sa nature purement réactive. En effet, le système HVAC ne s'enclenche que lorsque la température dépasse des seuils prédéfinis, ignorant les sollicitations futures de l'enveloppe du bâtiment. Cette approche provoque souvent des oscillations énergivores et une optimisation insuffisante des coûts.

Pour dépasser cette limite, nous mettons en œuvre une commande prédictive formulée comme un problème d'optimisation à horizon glissant. En s'appuyant sur un modèle mathématique dynamique du bâtiment, des prévisions météorologiques et un signal de prix électrique détaillé, ce problème anticipe l'inertie thermique pour déplacer les pointes de consommation vers les heures les moins coûteuses, tout en garantissant le confort thermique des occupants.

3.1 Modélisation thermique et formulation dynamique

Nous partons du modèle thermique classique résistance-capacité (RC) continu, décrit par l'équation différentielle de bilan d'énergie [22] :

$$C \frac{dT_{\text{zone}}(t)}{dt} = \frac{T_{\text{out}}(t) - T_{\text{zone}}(t)}{R} + Q_{\text{int}}(t) + Q_{\text{hvac}}(t) \quad (3.1)$$

avec $T(t)$ la température intérieure, $T_{\text{out}}(t)$ la température extérieure, R la résistance thermique, C la capacité thermique du bâtiment, Q_{int} les apports internes, et Q_{hvac} la puissance thermique HVAC injectée.

Pour rendre ce modèle exploitable en optimisation numérique, nous le discrétisons dans le temps via la méthode d'Euler explicite à un pas $\Delta t = 15 \text{ minutes} = 0.25 \text{ h}$. Q_{int} est négligé (considéré faible devant Q_{hvac} :

$$T_{\text{zone},t+1} = T_{\text{zone},t} + \frac{\Delta t}{C} \left(\frac{T_{\text{out},t} - T_{\text{zone},t}}{R} + Q_{\text{hvac},t} \right) \quad (3.2)$$

Elle peut être réécrite sous la forme :

$$T_{\text{zone},t+1} = aT_{\text{zone},t} + bT_{\text{out},t} + cQ_{\text{hvac},t} \quad (3.3)$$

avec : $a = 1 - \frac{\Delta t}{RC}$, $b = \frac{\Delta t}{RC}$, et $c = \frac{\Delta t}{C}$. En prenant en compte les différents modèles thermiques étudiés (linéaires, quadratiques, symboliques), nous nous retrouvons avec une fonction discrète générale qui peut être linéaire ou non linéaire :

$$T_{\text{zone},t+1} = f(T_{\text{zone},t}, T_{\text{out},t}, Q_{\text{hvac},t}) \quad (3.4)$$

Cette fonction f capture la dynamique thermique globale et constitue la contrainte d'égalité principale dans notre formulation d'optimisation.

3.2 Formulation mathématique du problème d'optimisation

3.2.1 Variables et indices

Le problème est discrétisé sur 24 heures, avec un pas de temps constant $\Delta t = 15$ minutes, totalisant $N = 96$ pas de temps pour la commande. Dans la formulation, nous définissons deux ensembles d'indices :

- $i \in \mathbf{I} = \{0, \dots, 95\}$ indexant les les intervalles pour la puissance HVAC $P_{\text{heating},i}$, $P_{\text{cooling},i}$.
- $t \in \mathbf{T} = \{0, \dots, 96\}$ indexant les instants pour la température intérieure $T_{\text{zone},t}$ et les variables slack $\lambda_{1,t}$, $\lambda_{2,t}$. Ainsi, le dernier point de la journée à 24 heures est inclus, pour garantir la cohérence temporelle et permettre la formulation correcte des contraintes dynamiques.

Ainsi, les variables du modèle sont définies comme suit :

- $P_{\text{heating},i} \geq 0$, $P_{\text{cooling},i} \geq 0$, $i \in \mathbf{I}$, encadrées par leurs puissances maximales.
- $T_{\text{zone},t}$ pour $t \in \mathbf{T}$, représentant la température intérieure prédite à chaque instant, y compris le point final à minuit.
- Variables slack $\lambda_{1,t}$ et $\lambda_{2,t}$ définies sur $t \in \mathbf{T}$ pour gérer les violations de confort.
- Variable binaire z : variable binaire empêchant la simultanéité chauffage/refroidissement.




FIGURE 3.1 – Droite représentant les points de températures et intervalles de décision sur les puissances.

La figure 3.1 offre une représentation des variables de décision $P_{\text{heating},i}$, $P_{\text{cooling},i}$, $T_{\text{zone},t}$ et des données $T_{\text{out},t}$ pour une visualisation plus aisée des indices avec nos 97 points et 96 intervalles.

3.2.2 Fonction objectif

La fonction objectif à minimiser combine le coût d'énergie par période de 15 minutes et la pénalité liée aux violations de confort thermique :

$$\min J = \sum_{i=0}^{95} \text{Prix}_i \cdot \frac{\Delta t}{1000} (P_{\text{heating},i} + P_{\text{cooling},i}) + \gamma \sum_{t=0}^{96} (\lambda_{1,t} + \lambda_{2,t})$$

où Prix_i est le tarif au pas i (€/kWh) et γ est un facteur important pour limiter les écarts de température sur les bornes de confort (fixé à 1000 €/°C).

3.3 Contraintes du système

3.3.1 Dynamique thermique de l'enveloppe

La **contrainte centrale** porte sur l'équation (3.4). Celle-ci est légèrement modifiée et relie la température t à $t - 1$ et aux actions HVAC, suivant un modèle discrétisé :

$$T_{\text{zone},0} = T_{\text{initial}}$$

avec T_{initial} la température (venant des données) du début de la journée optimisée.

$$T_{\text{zone},t} = f(T_{\text{zone},t-1}, T_{\text{out},t-1}, Q_{\text{hvac},t-1}), \quad t = 1, \dots, 96$$

avec

$$Q_{\text{hvac},i} = \eta_h P_{\text{heating},i} - \eta_c P_{\text{cooling},i}, \quad i = 0, \dots, 95$$

où η_h et η_c sont les coefficients d'efficacité chauffage ($= 1.86$) et refroidissement ($= 3.73$). Ceux-ci sont calculés comme des moyennes annuelles du ratio $\frac{Q}{P}$, reflétant la performance réelle des systèmes HVAC. Ces paramètres garantissent un réalisme opérationnel des contraintes, assurant que les puissances contrôlées restent dans les limites physiques du système.

Cette équation d'état f provient de l'identification préalable de modèles thermiques basés sur les données (modèles linéaires, quadratiques, symboliques). Elle est traduite en restriction d'égalité dans le modèle d'optimisation Pyomo, imposant une évolution cohérente des températures simulées. La mise en équation découle donc :

- d'une calibration statistique ou symbolique sur des jeux de données réels et/ou simulés (EnergyPlus),
- et d'une transposition fonctionnelle au format compatible avec le solveur d'optimisation via Pyomo.

3.3.2 Limites technologiques

Les puissances sont plafonnées à une valeur définie à partir des caractéristiques techniques du bâtiment extraites du fichier de modélisation EnergyPlus (fichier IDF). Cette valeur est la puissance thermique nominale $P_{\text{therm,nom}} = 7120.17W$.

$$0 \leq P_{\text{heating},i} \leq \frac{P_{\text{therm,nom}}}{\eta_h} \cdot z, \quad 0 \leq P_{\text{cooling},i} \leq \frac{P_{\text{therm,nom}}}{\eta_c} \cdot (1 - z) \quad (3.5)$$

$$0 \leq P_{\text{heating},i} \leq 3828.04 \cdot z, \quad 0 \leq P_{\text{cooling},i} \leq 1908.9W \cdot (1 - z), i \in \mathbf{I} \quad (3.6)$$

avec l'exclusion mutuelle assurée par z , évitant des consommations contradictoires, notamment en contexte de prix d'électricité négatifs.

3.3.3 Bornes de confort souples

Pour pallier les imprécisions ou conditions extrêmes, des variables slack permettent un assouplissement contrôlé des contraintes de température confortable (entre $T_{\min} 20$ et $T_{\max} 24$ °C), avec une pénalisation dans la fonction objectif pour limiter ces écarts. Mathématiquement, les contraintes s'écrivent comme :

$$T_{\text{zone},t} + \lambda_{1,t} \geq T_{\min}, \quad (3.7)$$

$$T_{\text{zone},t} - \lambda_{2,t} \leq T_{\max}, \quad (3.8)$$

$$\lambda_{1,t}, \lambda_{2,t} \geq 0 \quad (3.9)$$

$$t \in \mathbf{T} \quad (3.10)$$

3.4 Résolution et validation

Cette optimisation sera faite sur 12 jours de l'année, 1 par mois. La résolution est effectuée via le solveur Gurobi pour les modèles linéaires et mixtes, et via Ipopt pour les modèles non linéaires ou symboliques. Les trajectoires optimales de puissance et température sont extraites à l'issue. Pour valider la robustesse, les consignes de température sont injectées en temps réel dans EnergyPlus par co-simulation via API Python, assurant la conformité du contrôle avec la physique complète du bâtiment. Cette étape critique valide que les contraintes dynamiques et opérationnelles formalisées conduisent à des comportements stabilisés, conformes aux prédictions.

Chapitre 4

Régression symbolique

La modélisation de la dynamique thermique des bâtiments constitue un enjeu central pour la mise en œuvre de stratégies de contrôle avancées telles que la commande prédictive. Comme détaillé dans l'état de l'art (chapitre 2), les approches conventionnelles se divisent en modèles physiques (*white box*), purement statistiques (*black box*) ou hybrides (*gray box*). La régression symbolique se positionne comme une approche intermédiaire prometteuse, capable de concilier la flexibilité structurelle des modèles *black box* et la lisibilité mathématique analytique des structures *gray box*.

Cependant, cette liberté structurelle s'accompagne d'un espace de recherche combinatoire infini. En l'absence de restrictions, une infinité d'expressions mathématiques peuvent ajuster parfaitement un ensemble de données fini, menant au phénomène de sur-apprentissage. En pratique, ce verrou méthodologique est levé par deux mécanismes complémentaires :

Le contrôle de la complexité : L'application d'une pénalité (parsimonie) qui rejette les expressions inutilement denses.

La restriction de l'espace de recherche : La sélection rigoureuse d'opérateurs mathématiques sous forme de fonctions guidées par la connaissance physique préalable du système étudié (températures et flux CVC).

Les algorithmes évolutifs, et plus particulièrement la programmation génétique, permettent d'explorer efficacement cet espace de recherche en favorisant la diversité des structures candidates afin d'isoler le meilleur compromis entre précision statistique et complexité mathématique.

Ce chapitre est consacré à la présentation des fondements théoriques de la régression symbolique et de ses principes algorithmiques. Nous détaillerons le fonctionnement de la programmation génétique, les mécanismes de sélection naturelle des expressions mathématiques, ainsi que la configuration spécifique de l'algorithme PySR retenu dans le cadre de ce travail de commande prédictive.

4.1 Principe général de la régression symbolique

La régression symbolique (SR) est une méthode d'apprentissage supervisé où l'espace du modèle est couvert par des expressions analytiques. Contrairement aux régressions conventionnelles, la SR construit des relations explicites entre les variables d'entrée et de sortie sans imposer de structure a priori. Le problème est formulé comme une optimisation multi-objectif combinant la minimisation de l'erreur de prédiction et de la complexité mathématique pour garantir l'interprétabilité du modèle [49].

Formellement, le cadre de la SR s'inscrit dans la minimisation du risque empirique [52].

Data : étant donné un ensemble de données $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, où $x_i = \{x_{1,i}, x_{2,i}, \dots, x_{d,i}\} \in R^d$ est le vecteur d'entrée et $y_i \in R$ est une sortie scalaire pour $i = 1, 2, \dots, n$ [53].

Classe de fonctions : Soit $\mathcal{F}$ une classe de fonctions composée de fonctions $f : R^d \rightarrow R$.

Loss Function : Définissons la Loss Function pour chaque candidat $f \in \mathcal{F}$:

$$l(f) := \sum_{i=1}^n l(f(x_i), y_i) \quad (4.1)$$

Un choix courant est la différence au carré entre la sortie et la prédiction, c'est-à-dire $l(f) = \sum_i (y_i - f(x_i))^2$.

Optimisation : La tâche d'optimisation consiste à trouver la fonction f parmi l'ensemble des fonctions $\mathcal{F}$ qui minimise la Loss Function [54] :

$$f^* = \arg \min_{f \in \mathcal{F}} l(f) \quad (4.2)$$

La spécificité de la SR réside dans la nature discrète et combinatoire de l'espace $\mathcal{F}$. Pour définir cet espace, l'utilisateur spécifie une bibliothèque d'opérations arithmétiques élémentaires (ex : +, ×, exp, etc), de variables et de constantes. L'ensemble $\mathcal{F}$ est alors constitué de toutes les compositions mathématiques possibles issues de cette bibliothèque [53].

4.2 Différentes catégories de régression symbolique

Les méthodes de régression symbolique peuvent être classées en plusieurs grandes familles selon la représentation de leurs expressions mathématiques et leur stratégie de résolution figure 4.1 [54].

Méthodes basées sur la Régression : Ces approches reposent sur une structure de modèle partiellement fixée (ex : formes linéaires ou quadratiques contraintes). L'apprentissage se limite à estimer les coefficients associés à une combinaison prédéfinie de fonctions issues d'une bibliothèque. Si ces méthodes sont déterministes et faciles à optimiser, leur capacité de découverte est bridée par les choix initiaux de l'utilisateur. Les extensions non linéaires basées sur des réseaux de neurones offrent plus de flexibilité, mais l'expression symbolique finale reste difficile à extraire et à interpréter.




FIGURE 4.1 – Taxonomie des méthodes de régression symbolique. [54].

Arbres d'expression : Cette catégorie représente les expressions mathématiques sous forme d'arbres syntaxiques dynamiques. Les nœuds internes portent les opérateurs (arithmétiques, unaires ou binaires) et les feuilles portent les variables ou les constantes. Cette structure flexible est optimisée par des algorithmes évolutionnistes, permettant des modifications structurelles libres au cours de l'apprentissage. C'est cette approche, couplée à la programmation génétique, qui est retenue dans ce travail via l'outil PySR.

Approches inspirées de la physique : Ces méthodes intègrent des lois physiques fondamentales (comme l'analyse dimensionnelle ou les principes de conservation) directement dans le processus de recherche pour restreindre l'espace combinatoire et forcer la cohérence des expressions générées.

En conclusion, ces méthodes offrent des compromis variés, mais les arbres d'expression (programmation génétique) restent optimaux pour la modélisation thermique du bâtiment. Elles offrent le meilleur compromis entre flexibilité, intégration de connaissances a priori, et capacité à découvrir automatiquement des équations analytiques interprétables sans imposer de structure physique rigide.

4.3 La régression symbolique pour la découverte d'équations en science

Découvrir des expressions applicables aux sciences physiques impose des exigences strictes qui éliminent la majorité des algorithmes de SR conçus pour des benchmarks synthétiques ou génériques. Voici les exigences spécifiques de la découverte d'équations en contexte scientifique [49] :

1. Une équation empirique en science contient souvent des constantes réelles inconnues. L'ensemble des expressions possibles prises en compte par certains algorithmes SR (opérateurs, entiers et variables) est discret et fini jusqu'à une taille maximale donnée. Cet ensemble peut même être recherché par force brute, en combinaison avec un module d'analyse de symétrie et de dimension. Cependant, avec des constantes réelles arbitraires, l'ensemble des équations à rechercher est infini. La difficulté de rechercher cet ensemble est encore aggravée par plusieurs facteurs :
2. Compromis précision-simplicité : L'expression découverte doit privilégier l'intelligibilité physique et la parcimonie plutôt qu'un lissage statistique aveugle et sur-paramétré.
3. Equation découverte à partir de données bruitées, potentiellement hétéroscédastiques¹.
4. Expressions non différentiables : Prise en charge de fonctions définies par morceaux ou discontinues. (ex : $\exp(x)$ pour $x < 0$ et $x^2 + 1$ pour $x \geq 0$).
5. Satisfaire à des contraintes connues (ex : conservation de la masse).
6. Opérateurs personnalisés : Flexibilité pour intégrer des fonctions spécifiques au domaine d'étude.
7. Aptitude à gérer un grand nombre d'entrées (données) via des mécanismes de sélection.
8. Capacité de l'outil à extraire des relations depuis des structures complexes (grilles, graphes, etc).
9. Accessibilité logicielle : Outils SR open-source, multiplateformes et facilement interfaçables.

Face à ces exigences, seules les approches basées sur les algorithmes évolutifs enrichis d'une optimisation locale s'avèrent pleinement adaptées pour isoler des équations scientifiques interprétables. Ces considérations motivent l'étude détaillée, dans les sections suivantes, des méthodes basées sur la programmation génétique et des différentes améliorations conçues spécifiquement pour répondre à ces exigences.

4.4 Algorithme génétique

Parmi les approches de régression symbolique, la programmation génétique (PG) constitue la méthode historique et la plus largement éprouvée [49]. C'est celle que nous implémenterons dans ce TFE.

4.4.1 Représentation et opérateurs évolutifs

En PG, les expressions mathématiques sont modélisées sous forme d'arbres syntaxiques : les nœuds internes représentent les opérateurs (ex : $+$, $\times$, $\exp$) et les feuilles correspondent aux variables d'entrée ou constantes [55]. L'évolution de la population d'expressions repose sur trois opérations principales :

Sélection par tournoi : Un sous-ensemble de k individus est échantillonné aléatoirement dans la population. L'expression présentant la meilleure aptitude (la perte minimale) est sélectionnée pour subir les opérateurs évolutifs de reproduction.

Crossover : des sous-arbres sont échangés entre deux expressions afin de créer de nouvelles expressions, illustré sur la figure 4.2a.

Mutation : des modifications aléatoires sont appliquées à une partie de l'arbre pour introduire de la diversité, illustré sur la figure 4.2b.

Ce mécanisme itératif permet d'équilibrer l'exploitation des structures performantes déjà découvertes et l'exploration de nouvelles configurations mathématiques.

1. Phénomène statistique où la variance des erreurs d'un modèle de régression n'est pas constante pour toutes les observations, mais varie en fonction des valeurs de la variable indépendante.




FIGURE 4.2 – Opérations entre deux arbres d'expressions [49].

4.4.2 Démarche basique d'un algorithme génétique

Le déroulement standard d'un algorithme génétique appliqué à SR suit une logique cyclique :

1. **Initialisation** : Génération d'une population initiale aléatoire d'arbres syntaxiques respectant les opérateurs autorisés.
2. **Évaluation** : Calcul de la fonction de perte (*loss function*) de chaque individu sur le jeu de données d'entraînement.
3. **Sélection et Reproduction** : Application de la sélection par tournoi pour choisir les parents, puis exécution des opérations de croisement et de mutation.
4. **Remplacement et Migration** : Remplacement des individus les moins aptes par les nouveaux descendants mutés. Pour maximiser l'efficacité computationnelle, la population est souvent segmentée en sous-groupes indépendants évoluant en parallèle, avec des mécanismes de « migration » asynchrone de gènes entre les îles. Ce cycle est répété jusqu'à convergence vers un niveau de précision prédéterminé ou épuisement du nombre maximal de générations.

4.4.3 Fonction objectif et compromis précision-complexité

Un défi majeur de la programmation génétique réside dans le contrôle de la taille des arbres afin d'éviter le sur-apprentissage (*overfitting*) et la croissance incontrôlée des expressions (phénomène de *bloat*). Pour isoler des modèles robustes, la fonction de coût globale intègre une pénalité liée à la complexité de l'équation :

$$\text{Score}(f) = \text{Loss}(f) + a \cdot \text{Complexité}(f) \quad (4.3)$$

où la complexité est évaluée selon la taille de l'arbre (nombre de nœuds, d'opérateurs et de variables) et a représente le coefficient de parsimonie. Cette formulation permet d'identifier le front de Pareto, c'est-à-dire l'ensemble des meilleures solutions optimales pour chaque niveau de complexité donné. Ce compromis précision-simplicité est fondamental dans les applications physiques, où des modèles plus simples sont généralement préférables pour l'interprétation et l'analyse [55].

4.5 Améliorations

L'algorithme standard sous forme PG peut être considérablement enrichi pour améliorer la précision des modèles scientifiques.

4.5.1 Boucle intégrée « évoluer-simplifier-optimiser »

Pour maximiser l'efficacité de la sélection des tournois, la PG est encapsulée au sein d'une boucle itérative tripartite : *évoluer*, *simplifier* et *optimiser* [49].

Évoluer : Application répétée des opérateurs de tournoi, croisement et mutation sur la population entière d'arbres syntaxiques pour générer de nouvelles structures mathématiques candidates.

Simplifier : Intervient périodiquement pour réduire la taille des arbres, à l'aide d'un ensemble de règles d'équivalences algébriques (ex : $x \times y - x \times y$ en 0). Cette étape rationalise l'arbre sans brider l'exploration, car l'évitement d'une simplification instantanée à chaque mutation permet parfois de conserver des états intermédiaires nécessaires à l'apparition de structures complexes futures (ex : mutation d'un symbole menant à $x \times x - x \times y$).

Optimiser : Cette phase est cruciale pour l'application de la SR aux sciences physiques. Au lieu de s'en remettre uniquement aux mutations aléatoires pour ajuster les coefficients numériques continus, un algorithme d'optimisation locale basé sur le gradient intervient pour calibrer explicitement et de manière déterministe les constantes de chaque équation prometteuse. Il a été démontré que la recherche locale de gradients sur les constantes numériques dans les expressions peut améliorer considérablement les performances de la SR [56]. Nous intégrons étroitement une version optimisée et stochastique de celle-ci.

Cette hybridation entre recherche structurelle stochastique (génétique) et ajustement paramétrique déterministe (gradient) accélère massivement la découverte d'équations physiques précises et stables.

4.5.2 Métrique de parsimonie adaptative

Un mécanisme traditionnel pénalise la complexité de manière statique via un score linéaire : $l(f) = l_{\text{pred}}(f) + c \cdot C(f)$, où $C(f)$ est la complexité de l'expression (nombre de noeuds) et c une constante de parsimonie. Pour éviter qu'une forme fonctionnelle erronée ne monopolise prématurément la population, une pénalité adaptative est introduite. La fonction de coût s'ajuste dynamiquement selon la formule suivante :

$$l(f) = l_{\text{pred}}(f) \cdot \exp(\text{freq}(C(f))) \quad (4.4)$$

où $\text{freq}(C(f))$ évalue la fréquence et la récence des expressions de complexité similaire dans la population au sein d'une fenêtre mobile. Ce mécanisme pénalise les complexités surreprésentées pour forcer l'algorithme à explorer de nouveaux fronts de Pareto, garantissant une diversité structurelle tout au long de la recherche.

4.5.3 Autres fonctionnalités avancées pour l'identification scientifique

Pour s'adapter aux contraintes de la modélisation thermique, l'algorithme intègre plusieurs briques technologiques avancées, nativement implémentées au sein de l'outil PySR retenu pour ce travail :

Custom losses : En science, l'erreur quadratique brute calculée point par point (*elementwise*) s'avère souvent insuffisante. L'algorithme permet l'injection de fonctions de perte personnalisées complexes. Dans le cadre de ce TFE, pour surmonter le verrou de l'explosion de l'erreur cumulative en simulation libre, la fonction de perte native de PySR a été remplacée par une fonction objectif de trajectoire récurrente. Codée en Julia, elle évalue l'erreur sur un horizon glissant de 48 pas (12 heures), échantillonné par sauts asynchrones de 1000 lignes sur l'ensemble de l'année. Cette contrainte force l'algorithme génétique à rejeter les structures instables au profit d'équations robustes à long terme.

$$\min \text{Loss}_{\text{trajectory}} = \frac{1}{M} \sum_{i=1}^M \sum_{h=0}^{47} (T_{\text{sim},i+h} - T_{\text{real},i+h})^2 \quad (4.5)$$

Contraintes : Application de filtres stricts lors des mutations (ex : limiter la profondeur maximale de l'arbre ou interdire l'imbrication d'opérateurs identiques comme `square(square(x))`), restreignant efficacement l'espace de recherche combinatoire.

Gestion du bruit et sélection de caractéristiques : Intégration de pré-traitements par processus gaussiens pour filtrer le bruit des données, combinés à des algorithmes d'arbres à gradient de boosting (*Gradient Boosting*) pour réduire la dimensionnalité en sélectionnant en amont les descripteurs les plus influents.

Chapitre 5

Cas d'étude

Ce chapitre détaille la méthodologie de construction et de structuration des bases de données utilisées pour l'entraînement et la validation de nos modèles thermiques. Il présente, d'une part, les jeux de données météorologiques sélectionnés pour retranscrire le climat considéré, et d'autre part, le modèle du bâtiment résidentielle uni-familiale servant de support physique aux simulations sur EnergyPlus. Il établit aussi le scénario Année classique VS Année Dynamique. Il présente les modèles benchmark utilisés au cours de mon projet et les résultats obtenus en termes de métriques de performances des modèles linéaires et non-linéaires ainsi que leurs résultats ex-post sur EnergyPlus. Le code associé à ce travail est accessible publiquement sur GitHub : https://github.com/Rom12trait/TFE_symbolic_regression_building.git.

5.1 Données

5.1.1 Données météorologiques

L'objectif de cette étude étant d'évaluer la commande prédictive sous un climat tempéré maritime représentatif de la Belgique, la zone géographique de Bruxelles a été sélectionnée. Trois jeux de données distincts ont été extraits de la plateforme *CBE Clima Tool* [57] :

Données d'entraînement : Profil climatique de l'aéroport de Bruxelles (Zaventem) ;

Données de test et validation : Profil de la périphérie proche de l'aéroport (Zaventem-périphérie) et profil de la station d'Uccle (sud de Bruxelles).

Ces jeux de données se présentent sous la forme de fichiers de type *Typical Meteorological Year* (TMY) au format EPW (*EnergyPlus Weather*). Contrairement à un relevé historique continu sur une seule année civile, un fichier TMY synthétise une année thermique théorique représentative sur le long terme. Pour ce faire, l'année est construite en combinant des mois caractéristiques sélectionnés sur plusieurs décennies (allant de 1941 à 2016). Cette structure permet de s'affranchir des anomalies climatiques ponctuelles pour fiabiliser les simulations de performance énergétique des bâtiments. Les données enregistrées sont de nature horaire, fournissant 24 points de mesure par jour pour l'ensemble des variables climatiques.

L'annexe figure A.5 illustre l'évolution temporelle de trois variables clés de ce fichier pour la station de Zaventem : la température moyenne journalière, l'ensoleillement global total journalier et les précipitations cumulées¹. Les profils retranscrivent fidèlement la saisonnalité classique de la région bruxelloise, alternant entre des hivers frais à faible ensoleillement et des périodes estivales présentant les amplitudes thermiques et radiatives les plus soutenues.

Détermination de la zone climatique (IECC / ASHRAE) : Ne disposant pas de fichiers géométriques standards natifs pour la ville de Bruxelles, une approche alternative par équivalence climatique a été adoptée. Cette démarche consiste à exploiter des modèles de bâtiments de référence développés par le Département de l'Énergie américain (DOE), conçus pour des régions réglementaires possédant des contraintes météo analogues à celles de la Belgique.

1. Bien que l'index temporel affiche l'année fictive 2025 pour des raisons de fluidité de visualisation, les données correspondent intrinsèquement aux assemblages de mois caractéristiques décrits précédemment.

Pour identifier les modèles compatibles, il est nécessaire de classer le climat de Bruxelles selon la nomenclature de l'*International Energy Conservation Code* (IECC). Cette classification segmente les climats mondiaux en 8 zones thermiques (de 1 pour les zones torrides à 8 pour les zones subarctiques) croisées avec 3 indices d'humidité : A (humide), B (sec) et C (marine).

En croisant les définitions mathématiques de l'IECC [58] avec les données de design de l'ASHRAE pour la station de Bruxelles-National [59], les critères suivants ont été validés :

Indice Thermique : La sévérité des hivers et la douceur des étés classent Bruxelles en **zone 4** (zone tempérée). **Indice d'Humidité** : Le régime pluviométrique et la proximité côtière identifient la région comme **marine C**.

5.1.2 Modèle d'habitation

La source sélectionnée pour l'acquisition de nos prototypes géométriques et thermiques est le Département de l'Énergie des États-Unis (DOE). Dans le cadre de son programme *Building Energy Codes Program*, pour assurer la transparence de ses recherches et permettre l'évaluation publique, l'organisme met à disposition une base de données exhaustive de bâtiments prototypes normalisés [60].

Parmi les grandes catégories disponibles (bâtiments commerciaux, résidentiels et préfabriqués), cette étude se concentre exclusivement sur les habitations résidentielles. Ce choix est motivé par la forte prévalence de ce secteur sur le réseau électrique et par sa propension croissante à être équipé de technologies à haute efficacité énergétique, telles que les pompes à chaleur.

Le prototype retenu pour nos simulations est une maison individuelle (Single-Family Residential Building). Ce modèle de base intègre des caractéristiques d'isolation thermique conformes aux exigences réglementaires de la zone 4C (normes IECC 2024). Il est configuré avec une fondation sur dalle béton (*slab*) et utilise une pompe à chaleur air-eau (PAC) comme système unique de chauffage et de refroidissement. La PAC s'impose comme le choix logique au vu des objectifs d'optimisation de charge flexible visés par ce travail.

La figure 5.1 présente la géométrie du modèle sous forme tridimensionnelle, générée à partir de l'application OpenStudio. Le bâtiment est structurellement composé de deux étages habitables, d'un grenier non chauffé (*attic*) et d'un garage attenant.




FIGURE 5.1 – Modélisation géométrique 3D de la maison individuelle de référence sous l'interface OpenStudio.

5.1.3 Séries temporelles

À partir du modèle géométrique de la maison individuelle et des fichiers météorologiques EPW, des simulations thermiques dynamiques annuelles ont été exécutées sous le logiciel *EnergyPlus*. Cette étape permet de générer les séries temporelles continues indispensables à l'entraînement de nos modèles de régression et à l'évaluation ex-post de la commande prédictive.

Pour assurer l'identification robuste de l'enveloppe par les algorithmes de régression (Linéaire, Quadratique et Symbolique) et garantir sa compatibilité avec le pipeline d'optimisation sous Pyomo, la base de données temporelle a été restreinte à trois variables physiques clés, extraites au **pas de temps de 15 min pour se synchroniser avec le marché Day-Ahead** :

- **La variable d'état cible (T_{zone}) [°C]** : retranscrivant la température de l'air intérieur de la zone habitable (« LIVING_UNIT1 »), mesurée par la variable EnergyPlus Zone Air Temperature.
- **La variable exogène climatique (T_{out}) [°C]** : correspondant à la température bulbe sec extérieure issue des fichiers EPW de Bruxelles (Site Outdoor Air Drybulb Temperature).
- **La variable de commande énergétique (Q_{hvac}) [W]** : représentant la puissance thermique nette instantanée injectée ou extraite de la zone par la pompe à chaleur. Elle est reconstruite algébriquement par la différence entre le chauffage sensible et le refroidissement sensible via la formule : $Q_{hvac} = Q_{heating} - Q_{cooling}$.

Ces trois variables seront utilisées comme variables d'entrée pour nos modèles, et comme variable de sortie, nous utiliserons la température de zone T_{zone} décalée d'un pas de temps de 15 min (1 step).

L'assemblage final de ces flux forme la base de données temporelle unifiée. Ce format condensé à trois descripteurs écarte volontairement les variables secondaires (apports internes, irradiation solaire directe) afin d'assurer l'équilibre entre la concision statistique requise par PySR et la vitesse de convergence des solveurs de commande non linéaire.

La figure 5.2 illustre l'évolution de la consommation électrique journalière globale du bâtiment ainsi que la part absorbée par le système CVC pour une année typique.




FIGURE 5.2 – Consommation électrique journalière de l'habitation individuelle et part absorbée par les systèmes CVC (HVAC) sur une année météorologique typique à Bruxelles.

L'analyse de ces profils de charge montre sans surprise que les pointes de demande électrique majeures se concentrent durant la période hivernale. En saison froide, les besoins de chauffage de l'enveloppe sollicitent intensément la pompe à chaleur, au point que la consommation du système CVC représente fréquemment plus de la moitié de la demande énergétique journalière totale de l'habitation. En comparaison, la période estivale présente des appels de puissance électrique nettement plus faibles et lissés, le climat marin bruxellois limitant les charges de refroidissement extrêmes.

5.1.4 Scénarios année classique et année dynamique

Pour évaluer la robustesse de l'identification et l'adaptabilité de l'optimiseur, les simulations ont été déclinées selon deux scénarios de régulation distincts, se différenciant par la dynamique de leurs bandes mortes de confort.

Le scénario de l'Année Classique : Ce profil applique une régulation par thermostat standard et statique issue des configurations par défaut du fichier IDF du Département de l'Énergie (DOE). Les températures de consigne de chauffage ($T_{heating_sch}$) et de refroidissement ($T_{cooling_sch}$) sont fixées de

manière rigide, imposant la contrainte permanente :

$$22.22 \text{ }^{\circ}\text{C} < T_{\text{zone}} < 23.88 \text{ }^{\circ}\text{C} \quad (5.1)$$

Si la température de zone descend sous le seuil bas, le mode chauffage s'enclenche, tandis qu'un dépassement du seuil haut active le mode refroidissement. Ce comportement retranscrit le fonctionnement thermique passif et conventionnel d'une habitation.

Le scénario de l'Année Dynamique : Afin d'enrichir la base de données et de forcer l'excitation des signaux pour permettre à PySR d'extraire précisément les constantes de temps de l'enveloppe, un profil de consigne hautement variable a été construit. Ce scénario applique des sollicitations thermiques diversifiées au cours de la semaine, formalisées par des variations cycliques de la bande morte.

La figure 5.3 détaille la structure de cette semaine dynamique, mettant en scène l'évolution de la température de zone (courbe noire) face aux consignes de refroidissement (pointillé bleu) et de chauffage (pointillé rouge) :

Lundi : Élargissement maximal des bornes pour observer la dérive passive naturelle du bâtiment ;

Mardi et Mercredi : Application successive d'un échelon montant, puis d'un échelon descendant ;

Jeudi : Excitation forcée par un pic de chauffage de courte durée ;

Vendredi : Plage fixe avec une dérive passive sur courte durée ;

Samedi et Dimanche : Sollicitations par un profil sinusoïdal simplifié, suivi d'un échelon de week-end.




FIGURE 5.3 – Profils hebdomadaires des températures de consigne (Chauffage et Refroidissement) et évolution de la température de zone pour le scénario de l'Année Dynamique.

5.2 Benchmarks

Cette section décrit les modèles établis dans la littérature et utilisés comme points de comparaison pour les modèles issus de la RS.

5.2.1 Modèle 1R1C

Afin de représenter le comportement thermique du bâtiment de manière simplifiée, un modèle résistance-capacité a été développé. Ce modèle simplifié peut être représenté par l'équation suivante :

$$C \frac{dT_{zone}}{dt} = \frac{T_{out} - T_{zone}}{R} + Q_{int} + Q_{hvac} \quad (5.2)$$

où T_{out} représente la température extérieure, T_{zone} la température de la zone considérée. Dans notre cas, il s'agit de la "LIVING_UNIT" du bâtiment. Q_{int} représente les apports internes et Q_{hvac} les apports du système HVAC dans la zone. Enfin R et C sont la résistance thermique et la capacité thermique comme mentionné à la section 2.2.1.

En plus des hypothèses déjà établies par ce modèle et explicitées dans la section 2.2.1, des hypothèses supplémentaires sont prises dans le cas modèle 1R1C. La zone est isotherme (température uniforme dans tout le volume). L'ensemble des parois peut être représenté par une résistance thermique équivalente unique. Toute la masse thermique du bâtiment est concentrée en un seul nœud. Les propriétés thermiques sont constantes (modèle linéaire). Les infiltrations d'air sont intégrées dans la résistance globale. Les échanges radiatifs sont inclus implicitement dans les coefficients globaux. Les apports internes Q_{int} (occupants, éclairage) sont négligés ou considérés faibles devant Q_{hvac} . Ces hypothèses simplifient fortement la physique réelle du bâtiment. L'équation considérée est donc la suivante :

$$C \frac{dT_{zone}}{dt} = \frac{T_{out} - T_{zone}}{R} + Q_{hvac} \quad (5.3)$$

Cette équation est ensuite discrétisée en appliquant la méthode d'Euler :

$$T_{zone}[k+1] = T_{zone}[k] + \frac{dt}{C} \left(\frac{T_{out}[k] - T_{zone}[k]}{R} + Q_{hvac}[k] \right) \quad (5.4)$$

Ce qui peut être réécrit sous forme linéaire :

$$T_{zone}[k+1] = aT_{zone}[k] + bT_{out}[k] + cQ_{hvac}[k] \quad (5.5)$$

avec : $a = 1 - \frac{dt}{RC}$, $b = \frac{dt}{RC}$, et $c = \frac{dt}{C}$

Ce modèle utilise donc comme entrées : la température extérieure, provenant du fichier climatique utilisé par EnergyPlus. La température de la zone à l'instant k . La puissance thermique HVAC, déterminée à partir des variables EnergyPlus : Zone Air System Sensible Heating Rate [W] et Zone Air System Sensible Cooling Rate [W]. La puissance nette injectée dans la zone est : $Q_{hvac} = Q_{heating} - Q_{cooling}$. Cette grandeur représente la puissance thermique réellement transmise à l'air de la zone, et non la puissance électrique consommée par le système.

Enfin comme sortie, nous avons la température de la zone à l'instant $k+1$. Celle-ci sera comparée à la température de zone simulée par EnergyPlus.

Calcul de la résistance thermique équivalente

Pour une paroi composé de plusieurs couches,

$$R_{paroi} = R_{si} + \sum_i \frac{e_i}{\lambda_i} + R_{se} \quad (5.6)$$

avec e_i : épaisseur [m], λ_i : conductivité thermique [W/mK], R_{si} et R_{se} : résistances superficielles [m^2K/W].

La transmittance thermique est :

$$U = \frac{1}{R_{paroi}} \quad (5.7)$$

Pour l'ensemble des parois, on calcule la conductance globale :

$$UA = \sum_j U_j A_j \quad (5.8)$$

avec A_j , la surface de la paroi j [m^2].

La résistance thermique globale est :

$$R = \frac{1}{UA} \quad (5.9)$$

Cette résistance représente l'ensemble des pertes thermiques stationnaires du bâtiment.

Les éléments intervenant dans le calcul de R et considéré ici sont les parois/murs de la zone LIVING_UNIT1, le plafond de cette zone ainsi que les fenêtres. Toute les propriétés physiques du bâtiment proviennent du fichier idf de celui-ci.

Nous calculons donc pour les éléments suivants :

	R_j	U_j	A_j
Murs	3.705	0.27	172.16
Plafond	6.564	0.152	110.41
Fenêtre	NaN	1.59	33.015

TABLE 5.1 – Calculs des parois.

Nous déterminons ensuite un $UA = 115.79W/K$. Cela nous amène a une résistance thermique équivalente $R = 0.00863K/W$

Calcul de la capacité thermique

La capacité thermique totale est obtenue en sommant les capacités des éléments constitutifs.

$$C = \sum_i \rho_i c_{p,i} e_i A \quad (5.10)$$

où : - ρ_i : masse volumique [kg/m^3] - $c_{p,i}$: chaleur spécifique [J/kgK] - e_i : épaisseur [m] - A : surface [m^2] On peut définir la capacité surfacique $C_{si} = \rho_i c_{p,i} e_i$ ce qui nous donne $C = \sum_i C_{si} A$

Les masses considérées pour le calcul de C sont les murs, le plafond et le plancher ainsi que la dalle de fondation. Nous déterminons au moyen des propriétés physiques de l'idf.

	C_{si}	A	C_i
Murs	37890	187.9	$7.121 * 10^6$
Plafond	24091	110.47	$2.66 * 10^6$
Plancher	7680.13	110.47	$8.48 * 10^5$
Dalle	149500	110.47	$16.515 * 10^6$

TABLE 5.2 – Capacités surfaciques C_{si} , aire A et capacités C_i

La somme de ces capacités nous amène à une capacité thermique équivalente $C = 2.714 * 10^7$.

5.2.2 Benchmark : modèle persistant

Afin d'évaluer la valeur ajoutée des modèles développés, un modèle de référence simple, appelé modèle persistant, est introduit. Ce modèle repose sur l'hypothèse triviale que la température future sera identique à la température actuelle :

$$T_{pred}[k+1] = T_{zone}[k] \quad (5.11)$$

Pour des systèmes dotés d'une forte inertie thermique comme le bâtiment, ce modèle constitue une ligne de base robuste à très court terme (15 minutes).

5.2.3 Régression linéaire

La régression linéaire estime, par une résolution analytique du problème de moindres carrés : $\min_{\beta} \sum_{i=1}^n (T_i^{sim} - T_i^{pred})^2$, les coefficients d'une équation identique à la structure physique 1R1C, complétée par une ordonnée (intercept) d :

$$T_{zone}[k+1] = aT_{zone}[k] + bT_{out}[k] + cQ_{hvac}[k] + d \quad (5.12)$$

Ce modèle a été implémenté à l'aide de la classe `LinearRegression` du module `scikit-learn`.

5.2.4 Régression quadratique brute et restreinte

Afin d'introduire des effets d'ordre supérieur et de capter d'éventuelles non-linéarités physiques, une extension polynomiale de la régression au degré 2 a été explorée. Sous sa forme complète brute, l'équation d'état quadratique s'exprime de la manière suivante :

$$\begin{aligned} T_{\text{zone}}[k+1] = & \alpha_1 T_{\text{zone}}[k] + \alpha_2 T_{\text{out}}[k] + \alpha_3 Q_{\text{hvac}}[k] \\ & + \beta_1 T_{\text{zone}}^2[k] + \beta_2 T_{\text{out}}^2[k] + \beta_3 Q_{\text{hvac}}^2[k] \\ & + \gamma_1 (T_{\text{zone}}[k] \cdot T_{\text{out}}[k]) + \gamma_2 (T_{\text{zone}}[k] \cdot Q_{\text{hvac}}[k]) + \gamma_3 (T_{\text{out}}[k] \cdot Q_{\text{hvac}}[k]) + \delta \end{aligned} \quad (5.13)$$

Cependant, l'utilisation de cette formulation lors des premières phases d'identification a conduit à de sévères régressions statistiques et à des aberrations thermodynamiques. L'algorithme des moindres carrés, recherchant un lissage mathématique global, a attribué des poids aberrants à certains descripteurs. Une analyse critique de la physique des transferts a mis en évidence la nécessité d'alléger cette structure.

- **Le terme de puissance quadratique (Q_{hvac}^2)** : Ce paramètre forçait le modèle à corrélérer l'élévation de température au carré de l'énergie injectée, ce qui n'a aucun fondement thermodynamique pour un volume d'air intérieur et provoquait une dégradation majeure des métriques d'erreur.
- **Le carré de l'état (T_{zone}^2)** : L'introduction d'une puissance parabolique sur la température interne de la zone déstabilisait la boucle de rétroaction récursive, amplifiant le bruit numérique d'un pas sur l'autre.
- **Les couplages variables de la puissance ($T \cdot Q$)** : Les interactions croisées entre la commande CVC et les températures n'apportaient aucune information pertinente et surchargeaient inutilement l'espace d'état.

Pour y remédier et garantir la stabilité du pipeline, un modèle quadratique restreint manuellement a été développé. Seuls les termes conservant une signification physique stricte ont été retenus : le carré de la température extérieure T_{out}^2 (traduisant la dépendance non linéaire des performances de la pompe à chaleur vis-à-vis du climat) et le terme croisé de conduction $T_{\text{zone}} \times T_{\text{out}}$ (retranscrivant le gradient dynamique de la loi de Fourier à travers l'enveloppe).

L'équation structurelle neutre simplifiée se formule ainsi :

$$T_{\text{zone}}[k+1] = aT_{\text{zone}}[k] + b(T_{\text{zone}}[k] \cdot T_{\text{out}}[k]) + cT_{\text{out}}^2[k] + dT_{\text{out}}[k] + eQ_{\text{hvac}}[k] + f \quad (5.14)$$

avec a, b, c, d, e et f les coefficients réels identifiés par le modèle, dont l'évaluation numérique finale est présentée et discutée dans la section des résultats.

5.2.5 Régression symbolique (PySR)

Pour l'identification par régression symbolique, nous utilisons la bibliothèque de haute performance PySR [49]. PySR sera d'abord utilisé pour trouver une équation linéaire que nous comparerons avec les autres modèles linéaires.

$$T_{\text{zone}}[k+1] = f(T_{\text{zone}}[k], T_{\text{out}}[k], Q_{\text{hvac}}[k]) \quad (5.15)$$

Ensuite, nous rechercherons des équations non-linéaires utilisant des opérateurs comme exponentielle, square, cube, etc. Initialement configuré avec sa fonction objectif par défaut, qui compare sa prédiction faite par l'équation créée avec la sortie fournie (1 step - 15 min), L'algorithme génétique s'est heurté à un défaut : la recherche privilégie une structure linéaire trop simplifiée, minimisant l'erreur instantanée en s'appuyant uniquement sur le poids massif de T_{zone} (prédiction paresseuse) sans retenir l'influence des variables explicatives faibles comme Q_{hvac} ou T_{out} . Soumise à une simulation récursive libre, l'équation s'effondrait rapidement par accumulation d'erreurs.

Pour résoudre ce problème, nous avons implémenté la fonction objectif personnalisée de trajectoire multi-pas décrite dans la sous-section 4.5.3. L'évaluation s'effectue en conservant l'ordre chronologique des données (`shuffle = False`). Cette fonction force PySR à converger vers des expressions stables et physiquement robustes.

Dans le tableau 5.3, est repris un exemple du hall of fame que PySR crée. Pour chaque niveau de complexité (nombre d'opérateurs et variables/constantes), PySR sort la meilleure équation avec la loss la plus faible. Ces équations sont normalisées.

TABLE 5.3 – Exemple Hall of Fame PySR , équations normalisées : $x_0 = T_{\text{zone}}$, $x_1 = T_{\text{out}}$, $x_2 = Q_{\text{hvac}}$.

Complexity	Loss	Equation
1	0.7146	x_1
3	0.4350	$x_2 + x_1$
6	0.4272	$x_1 + (x_2 - 0.0933)$
7	0.4259	$(x_2 + x_1) - \text{square}(-0.2970)$
9	0.4259	$0.0419 + ((-0.1421 + x_2) + x_1)$
10	0.3917	$x_1 + (\text{square}(x_2) - \text{square}(x_2 - 0.3322))$
12	0.3608	$\text{square}((x_1 + 0.3198) + x_2) - \text{square}(x_2 + x_1)$
15	0.3607	$\text{square}(x_2 + (x_1 + 0.3666)) - \text{square}(x_1 + (x_2 + 0.0394))$
18	0.3604	$\text{square}((x_2 + x_1) + 0.3666) - (\text{square}((x_1 + x_2) + 0.0394) + 0.0120)$
19	0.3601	$\text{square}(((x_1 + 0.7571) + x_2) - 0.4254) + ((x_1 - \text{square}(x_1 + x_2)) - x_1)$

Dans l'annexe A.2 est repris les paramètres et hyperparamètres importants de PySR.

5.3 Résultats statistiques

L'évaluation des performances des différents modèles développés repose sur une double approche temporelle : une analyse instantanée à un pas de temps (*1-step-ahead* de 15 minutes) et une simulation récursive libre sur un horizon de 24H (la prédiction faite est utilisée pour la prédiction suivante et ainsi de suite), appliquée sur les 365 jours du jeu de données. L'utilisation de deux jeux de données distincts — l'Année Classique et l'Année Dynamique — répond à un besoin méthodologique précis. Bien que l'Année Classique soit plus représentative du comportement thermique standard et stabilisé d'une habitation réelle, sa passivité ne fournit pas une excitation suffisante du système. À l'inverse, l'Année Dynamique, en imposant de fortes variations de consignes, offre une grande variété de données indispensables pour extraire les constantes de temps réelles de l'enveloppe. C'est pourquoi l'exploration des modèles non linéaires a été menée directement sur ce second jeu de données.

TABLE 5.4 – Comparaison des modèles linéaires (pas de temps 15 min) : régression symbolique (RS) et régression linéaire (RL).

Modèles	Année classique				Année dynamique			
	Benchmark	RS	RL	RC	Benchmark	RS	RL	RC
MSE ($^{\circ}\text{C}^2$)	0.002	0.000	0.000	0.001	0.688	0.818	0.683	0.705
RMSE ($^{\circ}\text{C}$)	0.043	0.022	0.022	0.032	0.830	0.905	0.826	0.839
MAE ($^{\circ}\text{C}$)	0.018	0.008	0.008	0.023	0.173	0.328	0.253	0.178
Max Error ($^{\circ}\text{C}$)	0.320	0.274	0.274	0.308	10.631	9.849	9.564	9.730
R^2 (-)	0.996	0.991	0.991	0.981	0.932	0.910	0.9247	0.922
CV(RMSE) (%)	0.189	0.099	0.099	0.144	3.867	4.371	3.992	4.056
Error Std Dev ($^{\circ}\text{C}$)	0.043	0.022	0.022	0.027	0.827	0.902	0.683	0.704

Analyse de la configuration instantanée (1-step) : Sur l'Année classique, les conditions thermiques stabilisées et les consignes thermostatiques serrées limitent fortement la variabilité de la température intérieure. Le système est dominé par l'inertie thermique naturelle du bâtiment, ce qui permet au modèle persistant d'afficher d'emblée une précision excellente, caractérisée par un RMSE de 0.043°C et un coefficient de détermination $R^2 = 0.996$, voir Tableau 5.4. Les modèles statistiques linéaires (RL et RS) s'alignent parfaitement sur cette performance avec un RMSE réduit à 0.022°C . Le modèle physique direct RC s'avère lui aussi performant à ce pas de temps condensé (RMSE = 0.032°C), confirmant

que sur un horizon aussi court, la passivité du signal masque l'apport des structures mathématiques complexes.

L'introduction de l'Année Dynamique bouscule cette dynamique en accentuant les variations du système, ce qui se traduit logiquement par une dégradation des métriques de tous les modèles, y compris du modèle persistant dont le RMSE grimpe à 0.830°C (avec une erreur maximale atteignant 10.631°C). Malgré cette variabilité, le modèle persistant reste robuste grâce à l'amortissement physique de la structure du bâtiment.

En concentrant l'analyse sur les modèles entraînés pas à pas sur l'Année Dynamique, la Régression Linéaire (RL) affiche une performance instantanée supérieure à la Régression Symbolique (RS) linéaire, avec un R^2 de 0.9247 contre 0.910 pour la RS. Ce résultat est mathématiquement logique : par définition, la régression linéaire classique identifie analytiquement la droite des moindres carrés qui minimise strictement l'erreur résiduelle point par point. De son côté, le modèle quadratique restreint du premier pas bénéficie de l'augmentation de son degré polynomial pour capter localement les courbures climatiques, s'établissant comme le plus précis de sa catégorie avec un $R^2 = 0.9248$ et un RMSE de 0.8259°C . Enfin, le modèle RC affiche également un comportement instantané honorable (RMSE = 0.839°C , $R^2 = 0.922$). En règle générale, les indicateurs d'erreur brute (MSE, RMSE, MAE et Max Error) affichent des valeurs minimales sous cette configuration découpée, car aucun effet cumulatif ne vient perturber les entrées du système.

TABLE 5.5 – Comparaison des modèles linéaires (déroulement 24h) : régression symbolique (RS) et régression linéaire (RL).

Modèles	Année classique			Année dynamique		
	RS	RL	RC	RS	RL	RC
MSE ($^{\circ}\text{C}^2$)	0.248	0.249	3.517	3.38	6.854	17.658
RMSE ($^{\circ}\text{C}$)	0.498	0.499	1.875	1.838	2.618	4.202
MAE ($^{\circ}\text{C}$)	0.291	0.307	1.342	1.389	2.095	2.973
Max Error ($^{\circ}\text{C}$)	1.643	1.673	5.682	14.2	10.205	13.069
R^2 (-)	0.517	0.515	-5.845	0.675	0.342	-0.696
CV(RMSE) (%)	2.186	2.191	8.232	8.541	12.163	19.522
Error Std Dev ($^{\circ}\text{C}$)	0.488	0.493	1.397	1.838	2.617	3.719

Analyse de la configuration récursive (Déroulement 24h) : Le basculement vers une simulation récursive libre sur 24 heures détruit cette illusion de précision instantanée et met en évidence le phénomène d'accumulation progressive des erreurs. Le modèle physique RC en est la première illustration : bien qu'acceptable à un pas de temps, il s'écroule totalement lors de la projection libre sur 24 heures, que ce soit sur l'Année Classique (RMSE = 1.875°C , $R^2 = -5.845$) ou sur l'Année Dynamique (RMSE = 4.202°C , $R^2 = -0.696$), voir Tableau 5.5. Cet effondrement valide l'hypothèse selon laquelle les simplifications géométriques d'Euler biaisent la constante de temps, entraînant une dérive thermique rapide en l'absence de recalage.

Cependant, la rupture la plus fondamentale concerne l'inversion des performances entre les modèles statistiques classiques et la régression symbolique de PySR. Alors que la Régression Linéaire dominait la RS sur un pas de temps, elle montre de graves faiblesses en simulation libre 24h sur l'Année Dynamique, son R^2 chutant de 0.9247 à 0.342 avec un RMSE s'élevant à 2.618°C . À l'inverse, la Régression Symbolique linéaire maintient une tenue de trajectoire bien supérieure, isolant un R^2 de 0.675 et un RMSE limité à 1.838°C .

Ce croisement de performance s'explique par la nature de la fonction objectif utilisée. La Régression Linéaire et le modèle quadratique restreint effectuent leur entraînement de manière découpée sur un seul pas de temps, ajustant leurs poids uniquement entre l'état actuel k et l'état suivant $k + 1$. Ils développent un biais paresseux face aux dérives cumulées. Au contraire, PySR tire profit de la fonction objectif personnalisée de trajectoire, qui minimise explicitement l'erreur quadratique sur un horizon glissant récursif. Bien qu'elle affiche une erreur maximale ponctuelle légèrement plus élevée

(Max Error = 14.200 °C), cette contrainte de dérive force le modèle symbolique à privilégier la stabilité de la signature thermique à long terme puisqu'elle va faire de l'a prédiction sur 12 heures avec l'équation sélectionné et cherche à trouver la meilleure équation qui minimise les erreurs sur ces 12 heures.

Le modèle quadratique restreint se positionne légèrement au-dessus de la Régression Linéaire lors du déroulement 24h (RMSE = 2.581 °C, $R^2 = 0.3603$), confirmant l'apport local du second degré, mais reste lourdement distancé par l'approche de trajectoire de PySR.

TABLE 5.6 – Comparaison globale des métriques d'entraînement des modèles non linéaires—Régression Quadratique restreinte (RQ), Régression symbolique (RS) exponentiel et Régression symbolique (RS) cubique—sous les configurations 15 minutes (1 step) et 24h (96 steps) entraînés avec l'année dynamique (A.D.).

Métrique Thermique	RQ restreinte A.D.		RS_exp A.D.		RS_cube A.D.	
	15 min.	24h	15 min.	24h	15 min.	24h
MSE (°C ²)	0,6821	6,661	5,337	4,859	1,582	3,082
RMSE (°C)	0,8259	2,581	2,310	2,204	1,258	1,756
MAE (°C)	0,2429	2,060	1,762	1,765	0,690	1,309
Max Error (°C)	9,5766	9,893	8,802	15,265	9,187	10,045
MBE / Bias (°C)	0,0053	0,067	0,027	-0,107	0,453	0,362
R^2 (-)	0,9248	0,3603	0,411	0,533	0,826	0,704
CV(RMSE) (%)	3,99	11,99	11,162	10,241	6,077	8,156
Error Variance (°C ²)	0,6821	6,656	5,336	4,848	1,377	2,951
Error Std Dev (°C)	0,8259	2,580	2,310	2,202	1,173	1,718

Confrontation des modèles régression symbolique non linéaires (Cubique vs Exponentiel) :

L'intégration d'opérateurs complexes au sein de PySR met en évidence un mécanisme de compromis statistique majeur. Pour maximiser leur robustesse sur l'horizon long, les modèles RS_exp et RS_cube font le choix de « sacrifier » leur précision instantanée à un pas de temps afin de maximiser leur cohérence récursive sur 24 heures, voir Tableau 5.6. Ce phénomène est particulièrement visible pour le modèle cubique : en mode 1-step, son R^2 recule à 0.826 et son RMSE s'établit à 1.258 °C, signant des erreurs brutes plus élevées que les régressions classiques. Le modèle exponentiel accentue ce sacrifice avec un R^2 instantané s'effondrant à 0.411 pour un RMSE de 2.310 °C.

C'est lors de l'évaluation récursive sur 24 heures que la supériorité de cette stratégie se concrétise. Le modèle RS_cube surclasse l'intégralité des architectures de cette étude en atteignant un coefficient de détermination $R^2 = 0.704$ associé au RMSE le plus faible du jeu dynamique (RMSE = 1.756 °C) et à une erreur maximale contenue (Max Error = 10.045 °C). Il se positionne comme l'évolution logique et l'aboutissement technique au-dessus du modèle PySR linéaire. En revanche, le modèle exponentiel RS_exp affiche des performances en deçà, se situant à mi-chemin entre le PySR linéaire et la régression linéaire classique, avec un R^2 de 0.533, un RMSE de 2.204 °C et une erreur maximale importante (Max Error = 15.265 °C). A priori, la structure cubique s'établit donc comme la formulation non linéaire la plus adaptée à l'enveloppe.

Analyse critique des expressions identifiées : Les formulations linéaires des différents modèles sont synthétisées au sein du tableau 5.7, tandis que le tableau 5.8 reprend les équations créées pour la régression quadratique restreinte ainsi que la régression symbolique avec opérateur exponentiel et avec opérateur cubique. Les modèles linéaires obtenus sont proches d'un modèle persistant, surtout dans le cas de l'année classique. C'est surtout avec l'année dynamique qu'on commence à s'éloigner du modèle persistant et qu'on tient plus en compte des variables T_{out} , Q_{hvac} avec $2.88 * 10^{-2}$ et $1.36 * 10^{-4}$ respectivement. Un commentaire important doit être formulé à l'égard de ces équations symboliques, en particulier celles issues de PySR. Bien que hautement performantes en ce qui concerne la réduction des erreurs statistiques de trajectoire, ces expressions revêtent un caractère purement phénoménologique et statistique.

L'algorithme génétique assemble des monômes de puissance (T_{zone}^3, T_{zone}^2) ou des combinaisons transnumériques ($\exp(-Q_{hvac}^2)$) afin de lisser mathématiquement le comportement thermique global de

la pièce. Par conséquent, on ne retrouve pas dans l'agencement de leurs termes la structure caractéristique et identifiable des lois de la thermodynamique ou des circuits moulés de la physique du bâtiment (tels que des gradients explicites de conduction de Fourier ou des constantes de temps $\tau = RC$). Ces modèles agissent comme des boîtes grises hautement calibrées, dont l'interprétabilité physique directe, bien que constatable via les termes utilisés et leurs coefficients, reste limitée malgré leur excellente robustesse calculatoire.

Modèle	Année classique	Année dynamique
1R1C	$T_{zone,t+1} = 0.996 * T_{zone,t} + 3.84 * 10^{-3} * T_{out,t} + 3.31 * 10^{-5} * Q_{hvac,t}$	
Régression linéaire	$T_{zone,t+1} = 0.994 * T_{zone,t} + 7.6 * 10^{-4} * T_{out,t} + 1.39 * 10^{-6} * Q_{hvac,t} + 0.119$	$T_{zone,t+1} = 0.958 * T_{zone,t} + 8.3 * 10^{-3} * T_{out,t} + 3.6 * 10^{-6} * Q_{hvac,t} + 0.81$
Régression symbolique linéaire	$T_{zone,t+1} = 0.994 * T_{zone,t} + 5.6 * 10^{-4} * T_{out,t} + 1.5 * 10^{-8} * Q_{hvac,t} + 0.121$	$T_{zone,t+1} = 0.952 * T_{zone,t} + 2.88 * 10^{-2} * T_{out,t} + 1.36 * 10^{-4} * Q_{hvac,t} + 0.71$

TABLE 5.7 – Equations dénormalisées des modèles linéaires pour les 2 années classiques et dynamiques.

Modèle	Année dynamique
RQ res-treinte	$T_{zone,t+1} = 0.965 \cdot T_{zone,t} - 8.88 * 10^{-4} \cdot (T_{zone,t} \cdot T_{out,t}) + 3.83 * 10^{-4} \cdot T_{out,t}^2 + 2.04 * 10^{-2} \cdot T_{out,t} + 6.52 * 10^{-6} \cdot Q_{hvac,t} + 0.676$
RS cubique	$T_{zone,t+1} = -1.54 \times 10^{-2} \cdot T_{zone,t}^3 + 1.00055 \cdot T_{zone,t}^2 - 20.74 \cdot T_{zone,t} + 1.73 \times 10^{-8} \cdot Q_{hvac,t}^2 + 3.68 \times 10^{-4} \cdot Q_{hvac,t} + 7.54 \times 10^{-2} \cdot T_{out,t} + 156.66$
RS exponentielle	$T_{zone,t+1} = 0.285 \cdot \exp \left(0.144 \cdot T_{out,t} - (5.17 \times 10^{-4} \cdot Q_{hvac,t} + 1.42 \times 10^{-2})^2 \right) + 21.73 - 3.63 \cdot \exp \left(- (5.2 \times 10^{-4} \cdot Q_{hvac,t} + 0.31 \cdot T_{zone,t} - 5.84)^2 \right)$

TABLE 5.8 – Equations dénormalisées des modèles non linéaires pour l'année dynamique : régression quadratique (RQ) et régression symbolique (RS).

Absence de régression symbolique de degré 2 : Une observation remarquable concerne la recherche algorithmique de PySR : il s'est avéré impossible d'obtenir une équation stable du second degré (quadratique) via l'algorithme génétique. Face aux données de l'Année Dynamique, la recherche symbolique convergait systématiquement soit vers des structures simplifiées purement linéaires, soit basculait directement vers des polynômes de degré 3, validant l'idée que le second degré pur constitue une transition mathématique instable pour décrire la physique de cette zone thermique ou il aurait fallu grandement augmenter le nombre d'itérations et de temps de calcul pour qu'il finisse par trouver un résultat.

5.4 Résultats d'optimisation et ex-post

Cette section évalue les performances macroscopiques et financières de l'ensemble des contrôles prédictifs développés, qu'ils soient linéaires ou non linéaires. L'évaluation s'appuie sur une validation ex-post menée au travers du simulateur physique de référence EnergyPlus sur un échantillon de 12 journées types représentatives (1 jour par mois). Les résultats détaillés jour par jour pour chaque modèle sont consignés en Annexes (voir Annexes tableau A.1 à tableau A.7). Le tableau 5.9 condense ces indicateurs en affichant les coûts et énergies cumulés, ainsi que la moyenne des erreurs statistiques, permettant de quantifier précisément le *Reality Gap* et la pertinence physique de chaque approche.

5.4.1 Impact de l'historique d'entraînement : supériorité de l'année dynamique

L'analyse croisée des modèles linéaires les plus simples met en lumière l'influence déterminante du jeu de données d'entraînement sur la viabilité de la commande. Les modèles entraînés sur l'Année

TABLE 5.9 – Synthèse comparative des performances entre Ex-Post et optimisation (Cumulés pour coûts et énergies, Moyennes pour les erreurs sur les 12 jours tests) des modèles. $RMSE_{Temp} = f(T_{zone,opti}, T_{zone,ex-post})$. MAPE désigne l’erreur moyenne absolue exprimée en pourcents (Mean Absolute Pourcentage Error). A.C. = Année classique. A.D. = Année dynamique. RL = régression linéaire et RS = Régression symbolique.

Métrique	RL A.C.	RL A.D.	RS Lin. A.C.	RS Lin. A.D.	Régression quadratique A.D.	RS-cubique A.D.	RS A.D.	Exp.
Cost Opti (€)	-0.64	12.23	-1.39	5.93	8.23	8.26	6.18	
Cost Ex-post (€)	14.91	14.55	15.08	13.73	14.67	15.70	16.57	
Diff (€)	15.55	2.32	16.47	7.80	6.44	7.44	10.40	
RMSE Temp (°C)	0.04	0.04	0.04	0.13	0.04	0.20	0.30	
RMSE Power (W)	921.39	1033.8	1119.5	478.4	907.7	460.9	718.7	
MAPE Power (%)	184.9	184.5	200.6	78.9	189.1	60.8	130.1	
Energie Opti (kWh)	99.1	197.0	130.2	89.2	190.7	109.4	165.9	
Energie Ex-post (kWh)	164.0	163.1	164.8	168.6	164.0	182.8	184.9	

Classique développent un biais d’inaction thermique sévère, induit par le manque de persistance d’excitation du signal d’origine. Au sein de l’environnement Pyomo, l’optimiseur minimise artificiellement la facture d’électricité en planifiant un coût cumulé dérisoire pour la Régression Linéaire classique ($Cost_{Opti} = -0.64$ €) et irréaliste pour le modèle PySR linéaire classique ($Cost_{Opti} = -1.39$ €), ce dernier exploitant de manière opportuniste et non bridée les plages de prix négatifs.

Dès que ces profils de puissance quasi-nuls sont injectés dans EnergyPlus, la réalité thermodynamique prévaut. Pour préserver les limites de confort, le simulateur physique déclenche des cycles de chauffage d’urgence ex-post. La facture réelle s’élève ainsi à 14.91 € pour la RL classique et 15.08 € pour PySR linéaire classique, engendrant des écarts financiers massifs (Total Diff = 15.55 € et 16.47 €). Ce découplage se répercute sur les métriques de commande, avec un MAPE moyen de puissance qui s’établit à 184.90 % et 200.60 %, invalidant la pertinence de l’enveloppe identifiée sur ce jeu de données (voir tableaux détaillés en Annexe).

L’utilisation de l’Année Dynamique résout ce biais structurel. En forçant des variations de consignes lors de l’apprentissage, les modèles assimilent les véritables déperditions de l’enveloppe. L’optimiseur formule ainsi des décisions énergétiques beaucoup plus réalistes. La Régression Linéaire dynamique anticipe une dépense de 12.23 € pour un coût réel ex-post de 14.55 €, resserrant le *Reality Gap* à seulement 2.32 €. De plus, avec la **régression symbolique linéaire A.D.**, nous atteignons le **coût en ex-post le plus faible du projet : 13.73 euros**. Nous obtenons aussi de bien meilleurs erreurs en puissances (478.4 en $rmse_{power}$ et 78.9% en $MAPE_{power}$). Le passage d’un historique passif à un historique dynamiquement excité est donc indispensable pour extraire une dynamique thermique exploitable par un outil de gestion énergétique.

5.4.2 Analyse de la régression quadratique restreinte

Le modèle quadratique restreint manuellement (Équation 5.14), bien qu’introduisant des termes d’ordre supérieur, ne parvient pas à se détacher du comportement des architectures linéaires classiques. Il planifie un coût cumulé de 8.23 € pour une dépense ex-post de 14.67 €, soit un écart de 6.44 €.

Bien que sa consommation énergétique réelle ($E_{Ex\ post} = 164.00$ kWh) soit équivalente à celle des autres modèles, sa gestion fine de la puissance demeure défailante. Son erreur de puissance moyenne reste élevée ($RMSE_{Power} = 907.65$ W) et son MAPE culmine à 189.10 %. Ce modèle reste tributaire

d'un entraînement statique au pas à pas (*1-step-ahead*), ce qui empêche Pyomo de lisser les appels de puissance et induit des oscillations ou des arrêts CVC brutaux lourdement pénalisés lors du passage sur EnergyPlus, comme en atteste son profil détaillé consigné en Annexe A.5.

Comparaison des modèles par coupes thermiques bidimensionnelles

Pour isoler visuellement les divergences comportementales entre l'enveloppe linéaire et la formulation quadratique restreinte, des coupes bidimensionnelles (2D) ont été tracées en fixant certaines variables à des valeurs clés réglementaires (voir figure 5.4). Cette approche permet de valider la cohérence thermodynamique locale des modèles hors du pipeline d'optimisation complexe de Pyomo. L'analyse de ces trois projections physiques permet de tirer des conclusions fondamentales :




FIGURE 5.4 – Coupes thermiques comparatives 2D entre le modèle Linéaire (RL) en rouge et le modèle de régression quadratique restreinte (RQ) en bleu. A.D. = Année dynamique

- **Sensibilité à la puissance HVAC (Q) et manifestation du biais d'intercept (figure 5.4a) :** En conditions hivernales ($T_{out} = -5^{\circ}\text{C}$, $T_{zone} = 20^{\circ}\text{C}$), la figure 5.4a met en scène une divergence de pente nette. La ligne bleue (Quadratique) présente une pente plus inclinée que la ligne rouge (Linéaire), corroborée par les coefficients dénormalisés devant Q (6.52×10^{-6} contre 3.6×10^{-6}). Ainsi, pour un même apport énergétique, le modèle non linéaire anticipe une élévation de température plus rapide. Cependant, l'observation la plus critique réside à l'origine ($Q = 0\text{W}$) : la courbe quadratique se situe nettement au-dessus de la droite linéaire (19.98°C contre 19.91°C).

Ce décalage graphique est la preuve visuelle directe du biais de l'intercept (+0.81), qui injecte une puissance fictive permanente et pousse l'optimiseur à l'inaction.

- **Dérive passive et instabilité aux limites de l'enveloppe (T_{out}) (figure 5.4b) :** L'analyse d'un bâtiment passif ($Q = 0 \text{ W}$, $T_{\text{zone}} = 21 \text{ °C}$) illustrée par la figure 5.4b valide la non-linéarité polynomiale gérée par le terme $+3.83 \times 10^{-4} T_{\text{out}}^2$. Néanmoins, la visualisation graphique révèle un défaut thermodynamique majeur : la courbe bleue adopte un comportement parabolique convexe qui remonte de manière aberrante aux extrêmes froids ($T_{\text{out}} < -5 \text{ °C}$). Le modèle postule ainsi qu'une baisse extrême de la température extérieure réchauffe le bâtiment. Cela démontre graphiquement le phénomène de sur-apprentissage aux limites, où la régression polynomiale sacrifie la cohérence physique aux bornes du domaine pour maximiser le lissage statistique au centre.
- **Sensibilité à l'état initial (T_{zone}) et point de croisement (figure 5.4c) :** En mi-saison sous un chauffage constant ($Q = 3000 \text{ W}$, $T_{\text{out}} = 5 \text{ °C}$), la figure 5.4c met en évidence une superposition graphique quasi-parfaite des deux modèles. Cette fusion s'explique par l'existence d'un point de croisement thermodynamique. En introduisant $T_{\text{out}} = 5 \text{ °C}$ dans le terme croisé, la pente apparente du modèle quadratique par rapport à T_{zone} se linéarise à $0.965 - (0.000888 \times 5) = 0.961$, une valeur extrêmement proche de la pente native linéaire (0.958). Les constantes globales s'équilibrent également autour de 0.83, les droites se confondent, expliquant pourquoi la MPC linéaire et la MPC quadratique partagent des performances et des coûts réels ex-post identiques au printemps et à l'automne.

En conclusion, la sélection manuelle de termes de degré 2 s'avère insuffisante. Forcer des monômes quadratiques au sein d'une structure polynomiale contraint le solveur à équilibrer des coefficients qui luttent les uns contre les autres, détruisant la pertinence physique locale au profit du lissage statistique global du dataset. Ce constat ferme définitivement le chapitre des régressions présumées et justifie le basculement vers la régression symbolique non linéaire (PySR) guidée par une perte de trajectoire.

5.4.3 Performances de la régression symbolique non-linéaire

Le point d'orgue de cette étude réside dans l'analyse des modèles non linéaires identifiés par régression symbolique sous PySR, optimisés via la fonction de perte personnalisée de trajectoire. Le tableau 5.9 démontre une tendance claire : l'association de la non-linéarité symbolique et d'un apprentissage sur horizon glissant surpasse structurellement toutes les méthodes de régression classiques.

"Échec" de la formulation exponentielle (RS_exp) : Le modèle exponentiel affiche les moins bonnes performances de la catégorie non linéaire. Son erreur thermique de planification ex-post est la plus élevée ($\text{RMSE}_{\text{Temp}} = 0.30 \text{ °C}$), son erreur de puissance remonte à 718.69 W (avec un MAPE de 130.10 %) et sa facture financière ex-post s'établit à 16,57 € (le *Reality Gap* s'élevant à +10.40 €). Ces indicateurs confirment que l'intégration de fonctions exponentielles imbriquées au sein d'Ipopt génère des instabilités numériques locales hors de son domaine nominal d'entraînement, poussant l'optimiseur à sur-corriger ses décisions au détriment de la réalité physique.

Le modèle régression symbolique cubique : Le modèle RS_cube, voir tableau 5.8, s'impose comme l'architecture optimale de ce travail de recherche, confirmant la pertinence physique de sa formulation mathématique. Il présente une amélioration notable de la capture des flux énergétiques réels :

- **Précision inégalée de la puissance :** Il réduit l'erreur moyenne de puissance au seuil le plus bas de toute l'étude avec un $\text{RMSE}_{\text{Power}}$ de seulement **460.88 W** (contre 1033.81 W pour la RL dynamique) et isole le MAPE de puissance le plus faible du tableau, s'établissant à 60.80 % (contre 184.50 % pour la RL dynamique).
- **Lissage thermique et réalité physique :** En intégrant un couplage cubique de l'état (T_{zone}^3) et une réponse quadratique de la commande (Q_{hvac}^2), le modèle PySR parvient à capturer des comportements non linéaires complexes, traduisant potentiellement la signature partielle de la charge du compresseur et les effets des pertes radiatives de l'enveloppe simulées par EnergyPlus. Bien que ces termes ne correspondent pas directement à des relations physiques explicites, ils fournissent une approximation robuste qui permet à l'optimiseur de planifier un profil de puissance lissé, évitant les à-coups brutaux ou les extinctions massives, et assurant une meilleure stabilité

dans la gestion thermique de la zone.

Cependant, il présente un **coût ex-post** total **plus élevé** (15.7 euros) > RS linéaire A.D. (13.73). Il est donc inférieur à RS lin. A.D. dans cet aspect.

Ce gain de fidélité sur les flux de puissance implique un compromis d'ingénierie tout à fait rationnel, visible à travers le suivi de la température de zone. Il convient de préciser une nuance fondamentale : le $RMSE_{Temp}$ est mesuré ici entre la trajectoire de température planifiée en amont par l'optimiseur (T_{zone_opt}) et celle réellement atteinte ex-post au sein du simulateur (T_{zone_real}). Cette métrique quantifie donc la capacité intrinsèque du modèle à anticiper sa propre dérive d'état sans intervention corrective extérieure.

Le modèle cubique affiche un $RMSE_{Temp}$ moyen de 0.20 °C (contre 0.04 °C pour les modèles linéaires). Ce phénomène constitue un sacrifice mathématique vertueux et nécessaire : pour éviter le sur-apprentissage (*overfitting*) inhérent aux droites des moindres carrés (qui affichent un RMSE de température parfait de 0.04 °C mais s'avèrent incapables de piloter proprement la PAC en simulation libre, comme le prouve leur MAPE de puissance de 184.50 %) le modèle cubique privilégie la robustesse physique globale. L'optimiseur accepte un écart de prédiction thermique infime et totalement imperceptible pour le confort des occupants (deux dixièmes de degré seulement) en échange d'une réduction drastique des erreurs sur la puissance HVAC appelée.

L'examen des annexes associées confirme que le modèle régression symbolique cubique non linéaire offre le comportement le plus stable, le plus prédictif et le plus proche de la signature thermique réelle du bâtiment d'EnergyPlus, validant ainsi la méthodologie.

5.4.4 Analyse dynamique des profils thermiques, électriques et financiers du modèle régression symbolique cubique

Pour comprendre l'origine de la supériorité structurelle du modèle **RS_cube** (qui affiche le meilleur compromis avec un $RMSE_{Power}$ réduit à 460.88 W et un $MAPE_{Power}$ minimal de 60.80 % selon le tableau 5.9), il convient d'analyser l'évolution temporelle de ses trajectoires. L'intégration d'un terme cubique lié à l'état (T_{zone}^3) et d'une réponse parabolique de la commande (Q_{hvac}^2) modifie profondément la planification de l'optimiseur par rapport aux architectures linéaires.




FIGURE 5.5 – Profils de température de Zone pour le 24 avril - modèle régression symbolique cubique. Courbe de température d'optimisation en tiret rouge, courbe de température ex-post d'EnergyPlus en bleue et courbe baseline d'EnergyPlus en gris.

Suivi des trajectoires d'état et respect du confort : L'examen du profil des températures de zone pour la journée du 24 avril, voir figure 5.5, confirme la remarquable fidélité du modèle symbolique. La trajectoire réelle de la température de zone simulée par EnergyPlus (courbe bleue

continue) épouse avec précision la courbe planifiée par l’optimiseur Pyomo (courbe rouge pointillée). le même résultat se constatait pour le PySR linéaire (année dyn.), voir Annexe figure A.6. Contrairement au modèle quadratique restreint qui laissait dériver le bâtiment en raison d’un intercept biaisé (Annexe tableau A.5), le couplage cubique anticipe et prend des décisions d’optimisation. La régulation maintient fermement l’état à l’intérieur des bornes de confort dynamiques ($20^{\circ}\text{C} - 24^{\circ}\text{C}$), prouvant la stabilité de l’identification récursive sur horizon glissant.

Reality Gap de puissance : La rupture technologique apportée par la régression symbolique non linéaire se manifeste sur le profil des puissances électriques appelé en période hivernale, le 22 novembre, voir figure 5.6. Alors que l’optimiseur PySR linéaire (année dynamique), voir Annexe figure A.7, formulait des décisions erronées sous forme de brèves impulsions découpées à pleine puissance (forçant EnergyPlus à sur-consommer en urgence), le modèle RS_cube engendre un lissage thermique. L’optimiseur Pyomo planifie une courbe de chauffage ($P_{\text{heat Opti}}$, courbe rouge) continue et progressive, qui sous-estime cependant la réalité physique d’EnergyPlus ($P_{\text{heat E+}}$ (Réal), courbe bleue) durant la journée et présente le même ordre de grandeur en soirée. Les appels hachés agressifs ont disparu, validant la baisse drastique du RMSE de puissance.





FIGURE 5.6 – Puissances électriques pour le 22 novembre - modèle régression symbolique cubique. Courbe de P_{heating} d’optimisation en tiret rouge, courbe de P_{heating} ex-post d’EnergyPlus en bleue et courbe de P_{heating} baseline d’EnergyPlus en gris. En tiret sont les P_{cooling} (< 0 pour une meilleure visualisation).


Régulation des comportements opportunistes lors des prix négatifs : La figure 5.7 illustre comment le modèle cubique, associé au post-traitement, corrige l’aberration de commande constatée lors des prix négatifs. Entre 2h et 8h du matin, face à un coût négatif, l’optimiseur PySR linéaire saturait artificiellement la PAC avec des pics de 3800 W, voir Annexe figure A.8. Le modèle cubique régule cette tricherie : la puissance planifiée ($P_{\text{heat Opti}}$) reste modérée (autour de 500 W) et est plus représentative du comportement réel (courbe bleue) même si l’opti sous-estime la puissance à mettre. Par conséquent, la courbe de coût réel ex-post ne subit plus de dérive majeure et reste cohérente avec le coût prédit (courbe rouge).

Stabilité du mode refroidissement : En période estivale, voir figure 5.8, le comportement ex-post (courbe bleue) en climatisation du modèle cubique suit de manière assez fidèle la trajectoire de l’optimiseur (courbe rouge) même s’il n’atteint pas les mêmes valeurs. Cette journée est d’ailleurs l’une des mieux identifiées du dataset avec un MAPE de puissance réduit à 31.54 %, voir Tableau A.7.

Analyse du bilan financier cumulé des 12 jours : L’analyse macroscopique des histogrammes 5.11 et 5.9 des coûts totaux journaliers simulés sur 12 journées représentatives par le modèle de régression




(a) Profil des puissances électriques appelées. Courbe de P_{heating} d'optimisation en tiret rouge, courbe de P_{heating} ex-post d'EnergyPlus en bleu et courbe de P_{heating} baseline d'EnergyPlus en gris. En tiret, sont les P_{cooling} (< 0 pour une meilleure visualisation).




(b) Analyse des coûts financiers par quart d'heure. En rouge, les coûts d'optimisation. En bleu, les coûts ex-post EnergyPlus et en gris, les coûts baseline EnergyPlus.

FIGURE 5.7 – Validation ex-post des flux de puissance et impacts économiques lors du 04 octobre - modèle régression symbolique cubique.



(a) Profil des puissances électriques appelées. Courbe de P_{heating} d'optimisation en tiret rouge, courbe de P_{heating} ex-post d'EnergyPlus en bleu et courbe de P_{heating} baseline d'EnergyPlus en gris. En tiret, sont les P_{cooling} (< 0 pour une meilleure visualisation).



(b) Analyse des coûts financiers par quart d'heure. En rouge, les coûts d'optimisation. En bleu, les coûts ex-post EnergyPlus et en gris, les coûts baseline EnergyPlus.

FIGURE 5.8 – Validation ex-post des flux de puissance et impacts économiques lors de la journée du 05 août - modèle régression symbolique cubique.




FIGURE 5.9 – Histogramme des coûts totaux journaliers pour les 12 jours pour le modèle régression symbolique linéaire entraîné sur l’année dynamique. En rouge, les coûts d’optimisation. En bleue, les coûts d’expost d’EnergyPlus. En gris, les coûts baseline d’EnergyPlus.

symbolique cubique et linéaire année dynamique met en lumière plusieurs aspects clés de sa performance économique et de sa robustesse opérationnelle.

Premièrement, nous renouvelons l’observation récurrente que le coût théorique optimisé (barres rouges) est systématiquement inférieur aux coûts ex-post d’EnergyPlus (barres bleues). Cette différence est attendue et typique d’un Reality Gap entre modèles simplifiés et simulateur physique de référence, du fait notamment des hypothèses réduites du modèle PySR. En raison des simplifications inhérentes à la structure du modèle (nombre restreint de variables d’état, absence de modélisation détaillée des apports internes variables et de la dynamique solaire), l’optimiseur calcule donc une dépense énergétique sous-estimée pour atteindre ses prévisions de température.

Les coûts ex-post d’EnergyPlus sont presque toujours supérieurs aux coûts d’optimisation, mais restent en cohérence avec les coûts baseline classiques (barres grises), qui simulent des comportements de régulation réactive standards avec des bandes mortes. Cette cohérence renforce la confiance dans la capacité du modèle PySR cubique à générer des plans d’action proches du comportement réel du bâtiment.


Sur certains jours présentant des prix négatifs sur le marché (par exemple, en juin ou octobre), le modèle optimise les consommations pour tirer parti de ces opportunités, aboutissant à des coûts optimisés négatifs ou très faibles. La réponse ex-post suit généralement cette logique, bien que la consommation réelle soit ajustée par les contraintes physiques du simulateur.

Par rapport au modèle PySR linéaire entraîné sur l’année dynamique, le modèle cubique présente une plus grande variabilité des coûts ex-post, avec des valeurs parfois légèrement supérieures ou fortement supérieures (dans le cas du jour de février) à celles de la baseline. Cette différence s’explique par la plus grande complexité et flexibilité du modèle non linéaire qui, tout en améliorant la fidélité physique et les erreurs sur la puissance HVAC, produit des trajectoires plus riches pouvant entraîner des décalages de consommation liés à la complexité accrue. Comme on peut le constater sur la figure 5.10, l’optimiseur force des alternances rapides de températures avec de fortes puissances. Cela mène donc au prix surélevé du 4 février, vu qu’il cherche à suivre la variation de température et qu’il consomme plus en conséquence.


Le tableau des métriques ex-post (Tableau A.7) corrobore cette analyse : le RMSE sur la température et la puissance sont très compétitifs, avec un MAPE puissance souvent nettement meilleur que le modèle RS linéaire A.D. (tableau A.3), témoignant d’un suivi plus précis des charges réelles. Cependant, il obtient un coût ex-post de 15.7 euros, le rendant inférieur dans cet aspect au modèle RS linéaire A.D.. La souplesse accrue du modèle cubique favorise une légère diminution des écarts financiers cumulés de 7.44 euros contre 7.80 euros pour la régression symbolique linéaire (A.D.), voir tableau 5.9. Cependant, la Régression symbolique linéaire présente le coût ex-post le plus faible.

En conclusion, l'histogramme et les données associées démontrent que le modèle **PySR cubique** réussit à fournir une meilleure **efficacité énergétique, précision de modélisation et capacité à gérer les complexités thermodynamiques réelles du bâtiment** (voir RMSE et MAPE tableau 5.9) **MAIS**, d'un point de vue économique (**coûts ex-post**), c'est le **modèle RS linéaire A.D.** qui nous a donné de **meilleurs résultats économiques** (13.73 euros contre 15.7).

Cette complémentarité souligne l'intérêt d'adopter une démarche multi-modèles selon les priorités opérationnelles, et invite à poursuivre l'exploration des modèles non linéaires tout en affinant leur calibration et leur intégration dans un cadre décisionnel opérationnel.



(a) Profils de température de Zone pour le 4 février - modèle pysr cubique année dynamique. En rouge, l'optimisation. En bleu, l'ex-post d'EnergyPlus. En gris, le baseline d'EnergyPlus.



(b) Puissances électriques pour le 4 février - modèles pysr cubique. Courbe de P_heating d'optimisation en tiret rouge, courbe de P_heating ex-post d'EnergyPlus en bleu et courbe de P_heating baseline d'EnergyPlus en gris. En tiret, sont les P_cooling (< 0 pour une meilleure visualisation).

FIGURE 5.10 – graphique ex-post des flux de puissance et température de zone lors de la journée du 4 février - modèle régression symbolique cubique.




FIGURE 5.11 – Histogramme des coûts totaux journaliers pour les 12 jours pour le modèle régression symbolique cubique. En rouge, les coûts d'optimisation. En bleu, les coûts d'expost d'EnergyPlus. En gris, les coûts baseline d'EnergyPlus.

Conclusion

Ce travail de fin d'études s'inscrit dans un contexte énergétique et environnemental majeur, celui d'une transition rapide et nécessaire vers une réduction des émissions carbone, portée notamment par l'électrification croissante des usages domestiques et tertiaires. La croissance continue de la superficie des bâtiments à l'échelle mondiale, conjuguée à une adoption massive des systèmes HVAC – chauffage, ventilation, climatisation –, fait de ces installations des consommateurs d'énergie électrique de premier plan. Selon les projections récentes, la demande électrique des bâtiments continuera d'augmenter fortement, intensifiant les charge réseaux et modifiant profondément les schémas énergétiques nationaux.

Cette dynamique s'accompagne d'enjeux multiples : au-delà des impacts physiques sur les réseaux (congestion, chutes de tension, pic de demande locale), elle soulève aussi de nouvelles opportunités économiques via les interactions entre technologies renouvelables (ex : photovoltaïque) et systèmes HVAC ainsi que la participation des bâtiments aux marchés de l'électricité, notamment grâce aux signaux tarifaires du marché day-ahead avec granularité de 15 minutes. La flexibilité intrinsèque des bâtiments, permise par l'inertie thermique des enveloppes et pilotée via les systèmes HVAC, constitue désormais un levier stratégique pour optimiser à la fois la consommation énergétique (ex : déplacer la demande) et le coût économique.

Dans ce cadre, le besoin crucial d'outils décisionnels performants, robustes et interprétables apparaît nettement, notamment pour garantir la qualité et l'acceptabilité des stratégies de contrôle prédictif appliquées. Ces outils de décision nécessitent donc des modèles interprétables pour comprendre ce qui se passe. Ce travail ambitionne précisément d'adresser ce défi en développant et évaluant des modèles dynamiques capables de représenter la dynamique thermique réelle du bâtiment tout en conservant une forme interprétable. La régression symbolique est apparue comme une approche particulièrement prometteuse, combinant la rigueur mathématique à la flexibilité d'apprentissage automatique, sans prérequis fort sur la structure du modèle. Cette méthode présente peu d'applications sur les bâtiments dans la littérature scientifique. Nous allons donc chercher à explorer ses possibilités.

L'état de l'art des approches de modélisation thermique des bâtiments distingue trois grandes familles : les modèles white box, gray box et black box, chacune avec ses forces et faiblesses.

Les modèles white box sont fondés sur la physique complète (équations différentielles, bilans énergétiques précis), offrant une forte interprétabilité et une grande cohérence physique. Ils nécessitent cependant une connaissance détaillée du bâtiment, sont coûteux à paramétrer et lourds à simuler, ce qui limite leur déploiement à grande échelle.

Les modèles black box reposent uniquement sur l'apprentissage statistique ou machine learning, exploitant abondamment les données mesurées et offrant rapidité et flexibilité. Leur opacité, le manque d'interprétabilité et la difficulté à extrapoler hors du domaine connu constituent leurs limites majeures. Entre les deux se situent les modèles gray box, hybrides combinant une structure physique simplifiée avec une calibration à partir de données. Ils offrent un compromis intéressant en termes d'interprétabilité, complexité simulatoire et précision sur horizons courts, mais restent dépendants d'une structure a priori fixée et parfois limités pour de nouvelles configurations.

La régression symbolique affirme sa place à la croisée de ces familles, associant découverte automatique de modèles analytiques interprétables à une grande adaptabilité aux données variées, permettant ainsi de dépasser certaines limitations classiques.

L'analyse porte ici sur un bâtiment résidentiel unifamilial à deux étages, considéré comme une seule zone thermique principale (T_{zone}), avec un garage et des combles (attic) non chauffés, et sans sous-sol. La dalle (slab) constitue la base thermique du bâtiment. Ce choix est fait car les résidences sont prévalentes sur les réseaux électriques.

Plusieurs modèles de la dynamique thermique de ce bâtiment—régression symbolique, régression linéaire, modèle persistant, régression quadratique et physiques 1R1C—linéaires et non linéaires ont été calibrés. Les variables d’entrée incluent la température extérieure T_{out} , la température intérieure de la zone T_{zone} , ainsi que la puissance thermique du système HVAC Q_{HVAC} à l’instant k , tandis que la sortie cible est T_{zone} à l’instant $k+1$ (quinze minutes après = 1 step) pour se calibrer avec le marché d’électricité. Ensuite, ils ont été injectés dans un problème d’optimisation de coût ciblant le marché single day-ahead (15 minutes), étendu à un jeu de données couvrant 12 journées types réparties sur l’année. Finalement, ils ont été validés en ex-post au moyen d’EnergyPlus.

Deux jeux de données d’entraînement ont été exploités : (i) l’Année Classique correspond à un comportement stable et peu variable des consignes, représentatif d’un vrai bâtiment mais n’excitant peu la dynamique thermique réelle de l’enveloppe ; (ii) l’Année Dynamique présente des variations importantes des consignes HVAC, permettant d’exciter plus efficacement le système thermique et d’extraire des paramètres dynamiques représentatifs.

Les analyses quantitatives ont montré que, bien que les modèles classiques linéaires et symboliques soient proches en validation instantanée, seule la régression symbolique équipée d’une fonction de perte sur trajectoire glissante assurait une stabilité et une précision robustes en simulation libre à 24h, notamment sur l’année dynamique. Celle-ci, grâce à son excitation riche, a permis de réduire sensiblement le biais structurel et de mieux extraire la dynamique thermique réelle.

L’examen des coûts optimisés et ex-post confirme un rôle crucial du jeu de données dynamique : le modèle PySR linéaire entraîné sur l’année dynamique obtient le coût ex-post le plus faible (13,73€), tandis que la régression symbolique cubique, bien qu’elle présente un coût plus élevé (15.7€), offre les erreurs moyennes les plus faibles en MAPE et RMSE du projet démontrant une meilleure représentation du bâtiment.

Ces résultats confirment que la régression symbolique, au-delà de sa capacité à produire des équations explicites et interprétables, se révèle un outil efficace pour modéliser la dynamique thermique complexe des bâtiments résidentiels, combinant robustesse, adaptabilité et simplicité d’interprétation. Cette méthode dépasse ainsi certains compromis classiques entre black box et gray box, ouvrant la voie à des modèles thermiques fiables et économiquement pertinents pour la gestion prédictive HVAC intégrée aux marchés d’électricité.

La modélisation précise du comportement thermique d’un bâtiment reste une tâche complexe, mêlant interactions physiques multiples, inertie, apports variables et hétérogénéités. Ce travail démontre que la régression symbolique offre une réponse innovante, exploitable dans un cadre concret de commande prédictive day-ahead, participant activement à la transition énergétique durable. Il est important de souligner que, bien que les équations issues de la régression symbolique soient explicitement interprétables en tant qu’expressions mathématiques, elles restent fondamentalement des modèles phénoménologiques et statistiques. Elles ne reproduisent pas nécessairement de manière identifiable les lois physiques classiques ou les termes thermiques connus, tels que les constantes de temps ou les gradients de conduction. Cette limitation reflète la nature exploratoire de la recherche, qui n’a pas encore permis d’examiner exhaustivement toutes les possibilités de structures d’équations plus rigoureusement physiques. Par ailleurs, faute de temps, l’étude n’a pas inclus la mise en œuvre de véritables modèles black box comme les SVM ou Random Forest pour comparaison directe, ce qui constitue un axe important pour de futures investigations.

Enfin, cette étude ouvre des perspectives prometteuses pour généraliser l’approche à d’autres typologies de bâtiments, affiner les formulations non linéaires, et enrichir l’intégration des modèles dans des chaînes de décision opérationnelles afin de maximiser les gains énergétiques et économiques sur les réseaux électrifiés.

Le code associé à ce travail est accessible publiquement sur GitHub : https://github.com/Rom12trait/TFE_symbolic_regression_building.git

Bibliographie

- [1] IEA. *Global floor area and buildings energy intensity in the Net Zero Scenario, 2010-2030*. en-GB. Licence : CC BY 4.0. 2023. URL : <https://www.iea.org/data-and-statistics/charts/global-floor-area-and-buildings-energy-intensity-in-the-net-zero-scenario-2010-2030> (visité le 14/11/2025).
- [2] IEA. *Energy consumption in buildings by fuel in the Net Zero Scenario*. en-GB. Licence : CC BY 4.0. 2022. URL : <https://www.iea.org/data-and-statistics/charts/energy-consumption-in-buildings-by-fuel-in-the-net-zero-scenario-2010-2030-2> (visité le 14/11/2025).
- [3] INTERNATIONAL ENERGY AGENCY. *Net Zero Roadmap : A Global Pathway to Keep the 1.5 °C Goal in Reach (2023 Update)*. Report. Paris : IEA, 2023. URL : <https://www.iea.org/news/the-path-to-limiting-global-warming-to-15-c-has-narrowed-but-clean-energy-growth-is-keeping-it-open>.
- [4] Iain STAFFELL et al. « A review of domestic heat pumps ». en. In : *Energy & Environmental Science* 5.11 (2012), p. 9291. ISSN : 1754-5692, 1754-5706. DOI : 10.1039/c2ee22653g. URL : <https://xlink.rsc.org/?DOI=c2ee22653g> (visité le 21/11/2025).
- [5] Dimitrios GYALISTRAS et al. « Analysis of Energy Savings Potentials for Integrated Room Automation ». en. In : ().
- [6] EUROPEAN UNION. « Directive (EU) 2024/1275 of the European Parliament and of the Council of 24 April 2024 on the energy performance of buildings (recast) ». en. In : *Official Journal of the European Union* L 2024/1275 (2024), p. 1-101. URL : <http://data.europa.eu/eli/dir/2024/1275/oj>.
- [7] Michael BLONSKY et al. « Potential Impacts of Transportation and Building Electrification on the Grid : A Review of Electrification Projections and Their Effects on Grid Infrastructure, Operation, and Planning ». en. In : *Current Sustainable/Renewable Energy Reports* 6.4 (déc. 2019), p. 169-176. ISSN : 2196-3010. DOI : 10.1007/s40518-019-00140-5. URL : <http://link.springer.com/10.1007/s40518-019-00140-5> (visité le 24/11/2025).
- [8] Georg KERBER. *Aufnahmefähigkeit von Niederspannungsnetzen für die Einspeisung aus Photovoltaikanlagen (Capacité d'accueil des réseaux basse tension pour l'injection des installations photovoltaïques)*. Note : Détaille les caractéristiques typiques des réseaux de distribution BT où $R/X > 1$, s'établissant généralement entre 1 et 3. TU München, 2011.
- [9] Nikolaos DAMIANAKIS, Gautham Ram Chandra MOULI et Pavol BAUER. « Grid impact of photovoltaics, electric vehicles and heat pumps on distribution grids — An overview ». en. In : *Applied Energy* 380 (fév. 2025), p. 125000. ISSN : 03062619. DOI : 10.1016/j.apenergy.2024.125000. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0306261924023845> (visité le 16/08/2026).
- [10] Christina PROTOPAPADAKI et Dirk SAELENS. « Heat pump and PV impact on residential low-voltage distribution grids as a function of building and district properties ». en. In : *Applied Energy* 192 (avr. 2017), p. 268-281. ISSN : 03062619. DOI : 10.1016/j.apenergy.2016.11.103. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0306261916317329> (visité le 24/11/2025).

- [11] Shubham BARASKAR et al. « Analysis of the performance and operation of a photovoltaic-battery heat pump system based on field measurement data ». en. In : *Solar Energy Advances* 4 (2024), p. 100047. ISSN : 26671131. DOI : 10.1016/j.seja.2023.100047. URL : <https://linkinghub.elsevier.com/retrieve/pii/S2667113123000153> (visité le 24/11/2025).
- [12] COMMISSION DE RÉGULATION DE L'ÉLECTRICITÉ ET DU GAZ (CREG). *Comment est composé le prix de l'énergie ?* <https://www.creg.be/fr/consommateurs/le-marche-de-lenergie/comment-est-compose-le-prix-de-lenergie>. Consulté le 16 août 2026. 2023.
- [13] Johann KRANZ et Arnold PICOT. « Toward an End-to-End Smart Grid : Overcoming Bottlenecks to Facilitate Competition and Innovation in Smart Grids ». In : (jan. 2011).
- [14] ELIA GROUP. *20251001_Press release SDAC_FR*. Oct. 2025. URL : https://www.elia.be/fr/presse/2025/09/20251001_press-release-sdac.
- [15] Chris WARWICK, Irene ANGELA et Laurence ROBINSON. « Assessment of consumer risks and benefits of heat pumps with and without dynamic price contracts ». en. In : (2023).
- [16] Evelyn SPERBER et al. « Aligning heat pump operation with market signals : A win-win scenario for the electricity market and its actors ? » en. In : *Energy Reports* 13 (juin 2025), p. 491-513. ISSN : 23524847. DOI : 10.1016/j.egyr.2024.12.028. URL : <https://linkinghub.elsevier.com/retrieve/pii/S2352484724008370> (visité le 25/11/2025).
- [17] ORES. *Comprendre le tarif Impact*. <https://www.ores.be/comprendre-ma-facture/impact>. Consulté le 16 août 2026. 2023.
- [18] Ofelia VERA-PIAZZINI et Massimiliano SCARPA. « Building energy model calibration : A review of the state of the art in approaches, methods, and tools ». en. In : *Journal of Building Engineering* 86 (juin 2024), p. 108287. ISSN : 23527102. DOI : 10.1016/j.jobee.2023.108287. URL : <https://linkinghub.elsevier.com/retrieve/pii/S2352710223024701> (visité le 12/12/2025).
- [19] Zakia AFROZ et al. « Modeling techniques used in building HVAC control systems : A review ». en. In : *Renewable and Sustainable Energy Reviews* 83 (mars 2018), p. 64-84. ISSN : 13640321. DOI : 10.1016/j.rser.2017.10.044. URL : <https://linkinghub.elsevier.com/retrieve/pii/S1364032117314193> (visité le 03/12/2025).
- [20] Shima Norouzi KANDELAN et al. « Geometric data in urban building energy modeling : Current practices and the case for automation ». en. In : *Journal of Building Engineering* 97 (nov. 2024), p. 110836. ISSN : 23527102. DOI : 10.1016/j.jobee.2024.110836. URL : <https://linkinghub.elsevier.com/retrieve/pii/S2352710224024045> (visité le 03/12/2025).
- [21] Hakan İbrahim TOL et Habtamu Bayera MADESSA. « Development of a white-box dynamic building thermal model integrated with a heating system ». en. In : *Journal of Building Engineering* 68 (juin 2023), p. 106038. ISSN : 23527102. DOI : 10.1016/j.jobee.2023.106038. URL : <https://linkinghub.elsevier.com/retrieve/pii/S2352710223002176> (visité le 04/12/2025).
- [22] Zequn WANG, Yuxiang CHEN et Yong LI. « Development of RC model for thermal dynamic analysis of buildings through model structure simplification ». en. In : *Energy and Buildings* 195 (juill. 2019), p. 51-67. ISSN : 03787788. DOI : 10.1016/j.enbuild.2019.04.042. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778818337654> (visité le 02/12/2025).
- [23] Kevin J. KIRCHER et K. MAX ZHANG. « On the lumped capacitance approximation accuracy in RC network building models ». en. In : *Energy and Buildings* 108 (déc. 2015), p. 454-462. ISSN : 03787788. DOI : 10.1016/j.enbuild.2015.09.053. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778815302930> (visité le 05/12/2025).
- [24] Julien BERGER et al. « On the comparison of three numerical methods applied to building simulation : finite-differences, RC circuit approximation and a spectral method ». In : (2019). Publisher : arXiv Version Number : 1. DOI : 10.48550/ARXIV.1905.13035. URL : <https://arxiv.org/abs/1905.13035> (visité le 05/12/2025).

- [25] Yasaman BALALI et al. « Energy modelling and control of building heating and cooling systems with data-driven and hybrid models—A review ». en. In : *Renewable and Sustainable Energy Reviews* 183 (sept. 2023), p. 113496. ISSN : 13640321. DOI : 10.1016/j.rser.2023.113496. URL : <https://linkinghub.elsevier.com/retrieve/pii/S1364032123003532> (visité le 04/11/2025).
- [26] Drury B. CRAWLEY et al. « EnergyPlus : creating a new-generation building energy simulation program ». en. In : *Energy and Buildings* 33.4 (avr. 2001), p. 319-331. ISSN : 03787788. DOI : 10.1016/S0378-7788(00)00114-6. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778800001146> (visité le 10/12/2025).
- [27] Amir SHAHCHERAGHIAN, Hatem MADANI et Adrian ILINCA. « From White to Black-Box Models : A Review of Simulation Tools for Building Energy Management and Their Application in Consulting Practices ». en. In : *Energies* 17.2 (jan. 2024), p. 376. ISSN : 1996-1073. DOI : 10.3390/en17020376. URL : <https://www.mdpi.com/1996-1073/17/2/376> (visité le 05/12/2025).
- [28] Nikolaos KAMPELIS et al. « An Integrated Energy Simulation Model for Buildings ». en. In : *Energies* 13.5 (mars 2020), p. 1170. ISSN : 1996-1073. DOI : 10.3390/en13051170. URL : <https://www.mdpi.com/1996-1073/13/5/1170> (visité le 10/12/2025).
- [29] Jason BROWNLEE. *Machine learning mastery with Python : understand your data, create accurate models, and work projects end-to-end*. Machine Learning Mastery, 2016.
- [30] Tomas EKSTRÖM et al. « Evaluating the impact of data quality on the accuracy of the predicted energy performance for a fixed building design using probabilistic energy performance simulations and uncertainty analysis ». en. In : *Energy and Buildings* 249 (oct. 2021), p. 111205. ISSN : 03787788. DOI : 10.1016/j.enbuild.2021.111205. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778821004898> (visité le 12/12/2025).
- [31] Soheil FATHI et al. « Machine learning applications in urban building energy performance forecasting : A systematic review ». en. In : *Renewable and Sustainable Energy Reviews* 133 (nov. 2020), p. 110287. ISSN : 13640321. DOI : 10.1016/j.rser.2020.110287. URL : <https://linkinghub.elsevier.com/retrieve/pii/S136403212030575X> (visité le 08/12/2025).
- [32] Hengfang DENG, David FANNON et Matthew J. ECKELMAN. « Predictive modeling for US commercial building energy use : A comparison of existing statistical and machine learning algorithms using CBECS microdata ». en. In : *Energy and Buildings* 163 (mars 2018), p. 34-43. ISSN : 03787788. DOI : 10.1016/j.enbuild.2017.12.031. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778817327834> (visité le 08/12/2025).
- [33] Hai-xiang ZHAO et Frédéric MAGOULÈS. « A review on the prediction of building energy consumption ». en. In : *Renewable and Sustainable Energy Reviews* 16.6 (août 2012), p. 3586-3592. ISSN : 13640321. DOI : 10.1016/j.rser.2012.02.049. URL : <https://linkinghub.elsevier.com/retrieve/pii/S1364032112001438> (visité le 08/12/2025).
- [34] Aurélie FOUCQUIER et al. « State of the art in building modelling and energy performances prediction : A review ». en. In : *Renewable and Sustainable Energy Reviews* 23 (juill. 2013), p. 272-288. ISSN : 13640321. DOI : 10.1016/j.rser.2013.03.004. URL : <https://linkinghub.elsevier.com/retrieve/pii/S1364032113001536> (visité le 08/12/2025).
- [35] Zhengwei LI, Yanmin HAN et Peng XU. « Methods for benchmarking building energy consumption against its past or intended performance : An overview ». en. In : *Applied Energy* 124 (juill. 2014), p. 325-334. ISSN : 03062619. DOI : 10.1016/j.apenergy.2014.03.020. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0306261914002505> (visité le 08/12/2025).
- [36] Ryoza OOKA et Kazuhiko KOMAMURA. « Optimal design method for building energy systems using genetic algorithms ». en. In : *Building and Environment* 44.7 (juill. 2009), p. 1538-1544. ISSN : 03601323. DOI : 10.1016/j.buildenv.2008.07.006. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0360132308001820> (visité le 15/12/2025).

- [37] S.L. WONG, Kevin K.W. WAN et Tony N.T. LAM. « Artificial neural networks for energy analysis of office buildings with daylighting ». en. In : *Applied Energy* 87.2 (fév. 2010), p. 551-557. ISSN : 03062619. DOI : 10.1016/j.apenergy.2009.06.028. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0306261909002669> (visité le 15/12/2025).
- [38] Qiong LI et al. « Predicting hourly cooling load in the building : A comparison of support vector machine and different artificial neural networks ». en. In : *Energy Conversion and Management* 50.1 (jan. 2009), p. 90-96. ISSN : 01968904. DOI : 10.1016/j.enconman.2008.08.033. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0196890408003154> (visité le 15/12/2025).
- [39] Zeyu WANG et al. « Random Forest based hourly building energy prediction ». en. In : *Energy and Buildings* 171 (juill. 2018), p. 11-25. ISSN : 03787788. DOI : 10.1016/j.enbuild.2018.04.008. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778818311290> (visité le 15/12/2025).
- [40] Abdul AFRAM et Farrokh JANABI-SHARIFI. « Review of modeling methods for HVAC systems ». en. In : *Applied Thermal Engineering* 67.1-2 (juin 2014), p. 507-519. ISSN : 13594311. DOI : 10.1016/j.applthermaleng.2014.03.055. URL : <https://linkinghub.elsevier.com/retrieve/pii/S1359431114002348> (visité le 09/12/2025).
- [41] G. CIULLA et A. D'AMICO. « Building energy performance forecasting : A multiple linear regression approach ». en. In : *Applied Energy* 253 (nov. 2019), p. 113500. ISSN : 03062619. DOI : 10.1016/j.apenergy.2019.113500. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0306261919311742> (visité le 08/12/2025).
- [42] Ludwig FAHRMEIR et al. « Regression Models ». en. In : *Regression*. 978-3-662-63882-8. Berlin, Heidelberg : Springer Berlin Heidelberg, 2021, p. 23-84. ISBN : 978-3-662-63881-1. DOI : 10.1007/978-3-662-63882-8_2. URL : https://link.springer.com/10.1007/978-3-662-63882-8_2 (visité le 09/12/2025).
- [43] Yessenia OLAZO-GÓMEZ et al. « Data-Based RC Dynamic Modelling to Assessing the In-Situ Thermal Performance of Buildings. Analysis of Several Key Aspects in a Simplified Reference Case toward the Application at On-Board Monitoring Level ». en. In : *Energies* 13.18 (sept. 2020), p. 4800. ISSN : 1996-1073. DOI : 10.3390/en13184800. URL : <https://www.mdpi.com/1996-1073/13/18/4800> (visité le 16/12/2025).
- [44] Enric Mont LECOCQ, Jordi PASCUAL et Jaume SALOM. « Development of physically coherent grey-box models for residential buildings using a simplified adjustment method ». en. In : *Energy and Buildings* 328 (fév. 2025), p. 115215. ISSN : 03787788. DOI : 10.1016/j.enbuild.2024.115215. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778824013318> (visité le 16/12/2025).
- [45] Essia ZNOUDA, Nadia GHRAB-MORCOS et Atidel HADJ-ALOUANE. « Optimization of Mediterranean building design using genetic algorithms ». en. In : *Energy and Buildings* 39.2 (fév. 2007), p. 148-153. ISSN : 03787788. DOI : 10.1016/j.enbuild.2005.11.015. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0378778806001599> (visité le 15/12/2025).
- [46] Joseph C. LAM et Sam C.M. HUI. « Sensitivity analysis of energy performance of office buildings ». en. In : *Building and Environment* 31.1 (jan. 1996), p. 27-39. ISSN : 03601323. DOI : 10.1016/0360-1323(95)00031-3. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0360132395000313> (visité le 15/12/2025).
- [47] Xiaoqi XU et al. « The impact of place-based affiliation networks on energy conservation : An holistic model that integrates the influence of buildings, residents and the neighborhood context ». en. In : *Energy and Buildings* 55 (déc. 2012), p. 637-646. ISSN : 03787788. DOI : 10.1016/j.enbuild.2012.09.013. URL : <https://linkinghub.elsevier.com/retrieve/pii/S037877881200463X> (visité le 15/12/2025).

- [48] Merih AYDINALP-KOKSAL et V. Ismet UGURSAL. « Comparison of neural network, conditional demand analysis, and engineering approaches for modeling end-use energy consumption in the residential sector ». en. In : *Applied Energy* 85.4 (avr. 2008), p. 271-296. ISSN : 03062619. DOI : 10.1016/j.apenergy.2006.09.012. URL : <https://linkinghub.elsevier.com/retrieve/pii/S030626190600136X> (visité le 15/12/2025).
- [49] Miles CRANMER. *Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl*. Version Number : 3. 2023. DOI : 10.48550/ARXIV.2305.01582. URL : <https://arxiv.org/abs/2305.01582> (visité le 16/12/2025).
- [50] Yuki OZAWA et al. *Data-driven HVAC Control Using Symbolic Regression : Design and Implementation*. Version Number : 1. 2023. DOI : 10.48550/ARXIV.2304.03078. URL : <https://arxiv.org/abs/2304.03078> (visité le 18/12/2025).
- [51] Julien LEPRINCE et al. « Fifty shades of black : uncovering physical models from symbolic regressions for scalable building heat dynamics identification ». en. In : *Proceedings of the 8th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation*. Coimbra Portugal : ACM, nov. 2021, p. 345-348. ISBN : 978-1-4503-9114-6. DOI : 10.1145/3486611.3491120. URL : <https://dl.acm.org/doi/10.1145/3486611.3491120> (visité le 18/12/2025).
- [52] V. VAPNIK. « Principles of Risk Minimization for Learning Theory ». In : *Advances in Neural Information Processing Systems*. Sous la dir. de J. MOODY, S. HANSON et R. P. LIPPMANN. T. 4. Morgan-Kaufmann, 1991. URL : https://proceedings.neurips.cc/paper_files/paper/1991/file/ff4d5fbbafdf976cfdc032e3bde78de5-Paper.pdf.
- [53] Marco VIRGOLIN et Solon P. PISSIS. *Symbolic Regression is NP-hard*. Version Number : 3. 2022. DOI : 10.48550/ARXIV.2207.01018. URL : <https://arxiv.org/abs/2207.01018> (visité le 22/12/2025).
- [54] Nour MAKKE et Sanjay CHAWLA. « Interpretable Scientific Discovery with Symbolic Regression : A Review ». In : (2022). Publisher : arXiv Version Number : 2. DOI : 10.48550/ARXIV.2211.10873. URL : <https://arxiv.org/abs/2211.10873> (visité le 18/12/2025).
- [55] Riccardo POLI et al. *A field guide to genetic programming*. eng. [Morrisville, NC : Lulu Press], 2008. ISBN : 978-1-4092-0073-4.
- [56] Alexander TOPCHY et William PUNCH. « Faster Genetic Programming based on Local Gradient Search of Numeric Leaf Values ». en. In : ().
- [57] Giovanni BETTI et al. « CBE Clima Tool : A free and open-source web application for climate analysis tailored to sustainable building design ». en. In : *Building Simulation* 17.3 (mars 2024), p. 493-508. ISSN : 1996-3599, 1996-8744. DOI : 10.1007/s12273-023-1090-5. URL : <https://link.springer.com/10.1007/s12273-023-1090-5> (visité le 17/11/2025).
- [58] *CHAPTER 3 CE GENERAL REQUIREMENTS - 2021 INTERNATIONAL ENERGY CONSERVATION CODE (IECC)*. URL : https://codes.iccsafe.org/content/IECC2021V3.0/chapter-3-ce-general-requirements#IECC2021V3.0_CE_Ch03_SecC301.3 (visité le 04/11/2025).
- [59] *ASHRAE climatic design conditions 2009/2013/2017/2021/2025*. URL : <https://ashrae-meteo.info/v2.0/> (visité le 10/11/2025).
- [60] DOE. *Prototype Building Models | Building Energy Codes Program*. URL : <https://www.energycodes.gov/prototype-building-models#Residential> (visité le 04/11/2025).

Annexe A

Annexe

A.1 Etat de l'art

Model Structure	
Differential Equations	$C_1 \frac{dT_1}{dt} = \frac{T_2 - T_1}{R_{1,2}} + w_1 Q_1 + w_2 Q_2$ $C_2 \frac{dT_2}{dt} = \frac{T_3 - T_2}{R_{2,3}} + \frac{T_1 - T_2}{R_{1,2}}$
State-Space Representation	$\frac{d}{dt} \begin{bmatrix} T_1 \\ T_2 \end{bmatrix} = \begin{bmatrix} -\frac{1}{C_1 R_{1,2}} & \frac{1}{C_1 R_{1,2}} \\ \frac{1}{C_2 R_{1,2}} & -\frac{1}{C_2 R_{2,3}} - \frac{1}{C_2 R_{1,2}} \end{bmatrix} \begin{bmatrix} T_1 \\ T_2 \end{bmatrix} + \begin{bmatrix} 0 & \frac{w_1}{C_1} & \frac{w_2}{C_1} \\ \frac{1}{C_2 R_{2,3}} & 0 & 0 \end{bmatrix} \begin{bmatrix} T_3 \\ Q_1 \\ Q_2 \end{bmatrix}$ $T_1 = [1 \quad 0] \begin{bmatrix} T_1 \\ T_2 \end{bmatrix}$
Variables	Input: $\mathbf{u} = [T_3 \quad Q_1 \quad Q_2]'$; Output: $\mathbf{y} = T_1$; State: $\mathbf{x} = [T_1 \quad T_2]'$; Parameter: $\boldsymbol{\theta} = [R_{1,2} \quad R_{2,3} \quad C_1 \quad C_2 \quad w_1 \quad w_2]'$

FIGURE A.1 – Exemple d'un modèle RC avec ses équations différentielles [22].




FIGURE A.2 – Méthodologie boîte noire [27].




FIGURE A.3 – méthode généralisée d'une boîte grise [20].

A.2 Hyperparamètres de la régression symbolique avec PySR

La qualité, l'interprétabilité et la cohérence physique des expressions générées par PySR dépendent du paramétrage de son espace de recherche et du contrôle de sa complexité. Les hyperparamètres critiques retenus dans le cadre de ce travail de modélisation thermique sont structurés selon trois catégories opérationnelles :

A.2.1 Définition de l'espace de recherche structurel

Ces paramètres fixent les briques mathématiques autorisées pour la construction des arbres syntaxiques :

- **binary_operators** : Définit la bibliothèque d'opérateurs à deux entrées. Pour préserver la linéarité ou introduire des couplages de conduction, la liste a été restreinte aux opérateurs élémentaires `["+", "-", "*"]`.
- **unary_operators** : Spécifie les fonctions à entrée unique applicables aux nœuds. Les fonctions non linéaires sélectionnées pour retranscrire les dérivées radiatives ou les comportements de charge partielle de la PAC sont `["square", "cube", "exp", "log"]`.
- **constraints** et **nested_constraints** : Imposent des restrictions strictes d'imbrication pour empêcher l'explosion combinatoire et le non-sens physique. Par exemple, elles interdisent à PySR de multiplier des blocs complexes entre eux via la règle `'*'` : `(1, 1)`, ou d'appliquer des puissances successives aberrantes telles que `square(square(x))`.

A.2.2 Pilotage de la complexité et de la parcimonie

Ces indicateurs contrôlent la taille des expressions afin de prévenir le phénomène de sur-apprentissage (*overfitting*) :

- **maxsize** : Fixe le nombre maximal de nœuds (opérateurs, variables et constantes) autorisés au sein d'un même arbre syntaxique. Ce plafond a été réduit à 12 (au lieu de 20) pour forcer la découverte d'équations hautement compactes et stables en simulation récursive libre.
- **parsimony** : Représente le coefficient de pénalité appliqué à chaque nœud supplémentaire. Configuré entre 0.0005 et 0.002, il dicte la raideur du front de Pareto en éliminant les arbres longs qui n'apportent pas un gain de précision significatif.
- **complexity_of_constants** et **complexity_of_variables** : Permettent de pondérer le coût d'introduction des éléments. Dans ce TFE, la complexité des constantes a été abaissée à 0.8 (vis-à-vis des variables fixées à 1) afin de faciliter l'émergence d'ordonnées à l'origine (intercepts) indispensables à la stabilisation de la dérive thermique.

A.2.3 Paramètres d'exécution de l'algorithme génétique

Ces variables pilotent la puissance de calcul et la convergence stochastique du solveur :

- **niterations** : Détermine le nombre total de cycles d'évolution appliqués à la population. Les tests ont été menés sur des plages allant de 80 à 150 itérations pour assurer la convergence des gènes.
- **populations** et **population_size** : Pilotent le nombre d'îles indépendantes évoluant en parallèle (10 à 20) et le nombre d'expressions candidates par île (30 à 40), régulant la diversité génétique.
- **batching** et **batch_size** : Activés pour optimiser le temps de calcul lors de l'évaluation de la fonction de perte sur de grands volumes de données en mode *elementwise*, en segmentant le jeu d'entraînement par sous-ensembles de 1024 lignes.

Sélection du modèle – Le paramètre `model_selection` définit le critère de sélection des équations finales, généralement basé sur un compromis entre précision et complexité. PySR privilégie typiquement des solutions Pareto-optimales, assurant un équilibre entre performance prédictive et simplicité du modèle.

A.2.4 Paramètres de la recherche évolutionnaire

Les paramètres suivants influencent principalement l'efficacité et la robustesse de la recherche : `niterations`, le nombre total d'itérations de l'algorithme évolutionnaire. `Population_size`, le nombre d'expressions candidates par génération. `Mutation_weights`, les probabilités associées aux différents types de mutation. `Crossover_probability`, la probabilité de recombinaison entre expressions.

Ces hyperparamètres affectent principalement la vitesse de convergence et la diversité des solutions explorées, sans modifier fondamentalement la structure mathématique accessible.

Contraintes sur les variables – Les contraintes spécifiques aux variables (`variable_constraints`) permettent d'imposer des bornes physiques, renforçant la plausibilité des équations identifiées.

A.3 Dataset




FIGURE A.4 – Consommation électrique journalière des systèmes HVAC de l’habitation individuelle pour une année typique.




FIGURE A.5 – Température moyenne journalière, ensoleillement total journalier et précipitation totale journalière pour une année météorologique typique (Aéroport de Zaventem, Bruxelles).

A.4 Résultats

TABLE A.1 – Métriques globales - Modèle Linear (année classique)

Day	Cost Opti	Cost ex-post	Diff. €	RMSE Temp	RMSE Power W	MAPE P (%)	Energ Opti kWh	Energ ex-post kWh
2025-01-21	0.00	2.24	2.24	0.04	594.41	100.00	0.00	13.88
2025-02-04	0.00	5.41	5.41	0.03	1603.79	100.00	0.00	37.94
2025-03-01	0.00	1.75	1.75	0.04	645.56	100.00	0.00	14.91
2025-04-24	0.00	0.76	0.76	0.05	371.00	100.00	0.00	8.28
2025-05-09	-0.00	0.36	0.36	0.05	1158.19	164.00	10.53	6.85
2025-06-08	-0.42	0.06	0.47	0.05	920.96	184.61	19.09	8.77
2025-07-08	0.12	1.28	1.16	0.04	736.51	97.81	2.96	16.04
2025-08-05	-0.22	0.16	0.38	0.05	771.28	123.87	15.75	11.58
2025-09-24	0.00	0.34	0.34	0.05	225.86	100.00	0.00	5.18
2025-10-04	-0.12	0.00	0.12	0.04	2636.13	948.62	50.72	7.94
2025-11-22	0.00	1.73	1.73	0.03	806.37	100.00	0.00	18.93
2025-12-24	0.00	0.83	0.83	0.04	586.66	100.00	0.00	13.72

TABLE A.2 – Métriques globales - Modèle Linear (année dyn)

Day	Cost Opti	Cost ex-post	Diff. €	RMSE Temp	RMSE Power W	MAPE P (%)	Energ Opti kWh	Energ ex-post kWh
2025-01-21	0.00	2.35	2.35	0.04	623.27	100.00	0.00	14.58
2025-02-04	12.83	4.91	-7.91	0.02	2414.52	182.88	90.92	34.44
2025-03-01	0.00	1.74	1.74	0.04	639.65	100.00	0.00	14.82
2025-04-24	0.00	0.73	0.73	0.05	349.05	100.00	0.00	7.94
2025-05-09	-0.00	0.34	0.34	0.05	1151.55	159.16	10.53	7.03
2025-06-08	-0.75	0.08	0.83	0.05	1549.16	202.64	20.58	8.86
2025-07-08	0.49	1.34	0.85	0.05	685.35	93.28	8.49	16.52
2025-08-05	-0.22	0.17	0.39	0.05	769.12	120.81	15.75	12.25
2025-09-24	0.00	0.29	0.29	0.05	207.67	100.00	0.00	4.69
2025-10-04	-0.12	-0.00	0.12	0.04	2603.67	854.73	50.72	8.64
2025-11-22	0.00	1.74	1.74	0.03	805.47	100.00	0.00	19.09
2025-12-24	0.00	0.86	0.86	0.03	607.23	100.00	0.00	14.22

TABLE A.3 – Métriques globales - Modèle PySR (année classique)

Day	Cost Opti	Cost ex-post	Diff. €	RMSE Temp	RMSE Power W	MAPE P (%)	Energ Opti kWh	Energ ex-post kWh
2025-01-21	0.00	2.26	2.26	0.04	598.88	100.00	0.00	13.99
2025-02-04	0.00	5.52	5.52	0.03	1634.05	100.00	0.00	38.71
2025-03-01	0.00	1.77	1.77	0.04	651.57	100.00	0.00	15.05
2025-04-24	0.00	0.76	0.76	0.05	371.31	100.00	0.00	8.28
2025-05-09	-0.00	0.36	0.36	0.05	1153.96	161.04	10.53	7.01
2025-06-08	-0.83	0.05	0.89	0.05	2126.76	356.06	37.32	8.36
2025-07-08	0.00	1.29	1.29	0.04	768.74	100.00	0.00	16.10
2025-08-05	-0.44	0.15	0.59	0.05	1864.28	221.94	31.58	11.35
2025-09-24	0.00	0.34	0.34	0.05	226.21	100.00	0.00	5.19
2025-10-04	-0.12	0.00	0.12	0.05	2633.10	868.55	50.72	7.76
2025-11-22	0.00	1.74	1.74	0.03	814.06	100.00	0.00	19.09
2025-12-24	0.00	0.84	0.84	0.04	591.50	100.00	0.00	13.84

TABLE A.4 – Métriques globales - Modèle PySR (année dyn)

Day	Cost Opti	Cost ex-post	Diff. €	RMSE Temp	RMSE Power W	MAPE P (%)	Energ Opti kWh	Energ ex-post kWh
2025-01-21	0.16	2.04	1.87	0.05	527.36	96.51	1.04	12.61
2025-02-04	4.55	5.27	0.71	0.06	468.80	18.36	32.33	36.91
2025-03-01	0.22	1.49	1.27	0.05	484.62	83.97	1.87	12.70
2025-04-24	0.04	0.65	0.61	0.08	301.95	88.79	0.43	6.96
2025-05-09	0.21	0.39	0.18	0.12	396.57	67.06	7.59	9.74
2025-06-08	-0.21	-0.10	0.12	0.13	298.12	57.82	7.74	11.05
2025-07-08	0.56	1.28	0.72	0.57	536.00	68.48	8.58	16.48
2025-08-05	-0.07	0.07	0.14	0.22	407.01	60.95	12.55	15.35
2025-09-24	0.00	0.32	0.32	0.05	203.76	100.00	0.00	4.77
2025-10-04	-0.04	-0.01	0.03	0.17	993.26	134.22	10.50	12.22
2025-11-22	0.37	1.56	1.19	0.04	593.78	80.87	4.02	17.15
2025-12-24	0.13	0.76	0.63	0.06	529.92	90.29	2.57	12.67

TABLE A.5 – Métriques globales ex-post de validation API et Reality Gap pour le modèle Quadratique Restreint

Journée Test	Cost Opti	Cost ex-post	Diff.	RMSE Temp	RMSE Power	MAPE P	Energ ex-post
	[€]	[€]	[€]	[°C]	[W]	[%]	[kWh]
2025-01-21	0.00	2.27	2.27	0.04	601.28	100.00	14.03
2025-02-04	4.79	5.25	0.47	0.03	1082.00	48.84	36.82
2025-03-01	0.00	1.67	1.67	0.04	616.40	100.00	14.27
2025-04-24	0.00	0.71	0.71	0.06	341.83	100.00	7.78
2025-05-09	-0.00	0.33	0.33	0.05	745.34	123.48	6.70
2025-06-08	-0.42	0.06	0.48	0.05	894.24	160.66	9.48
2025-07-08	3.46	1.39	-2.06	0.05	1179.14	264.15	16.96
2025-08-05	0.52	0.19	-0.33	0.05	1264.26	256.37	12.42
2025-09-24	0.00	0.28	0.28	0.05	203.30	100.00	4.54
2025-10-04	-0.12	-0.00	0.12	0.05	2595.72	815.78	8.73
2025-11-22	0.00	1.69	1.69	0.04	782.19	100.00	18.53
2025-12-24	0.00	0.83	0.83	0.04	586.09	100.00	13.70

TABLE A.6 – Métriques globales ex-post de validation API et Reality Gap pour le modèle PySR avec opérateur exponentielle.

Journée Test	Cost Opti	Cost ex-post	Diff.	RMSE Temp	RMSE Power	MAPE P	Energ Opti	Energ ex-post
	[€]	[€]	[€]	[°C]	[W]	[%]	[kWh]	[kWh]
2025-01-21	1.01	2.04	1.03	0.05	297.42	48.14	6.20	12.64
2025-02-04	1.67	7.50	5.83	0.80	1731.06	78.75	11.86	52.81
2025-03-01	0.79	1.49	0.70	0.06	297.00	42.34	6.73	12.68
2025-04-24	0.30	0.64	0.34	0.11	218.06	52.95	3.25	6.75
2025-05-09	0.37	0.84	0.48	0.96	429.36	49.76	6.12	12.93
2025-06-08	-0.35	0.01	0.36	0.29	885.67	98.00	19.59	11.01
2025-07-08	1.31	1.29	-0.02	0.28	302.60	55.91	17.01	16.14
2025-08-05	0.12	0.13	0.01	0.34	960.29	113.80	28.78	14.74
2025-09-24	0.01	0.32	0.31	0.25	242.31	96.60	0.29	5.39
2025-10-04	-0.12	-0.00	0.12	0.27	2539.83	823.96	52.10	10.10
2025-11-22	0.66	1.57	0.91	0.10	442.68	57.49	7.16	17.18
2025-12-24	0.41	0.75	0.35	0.05	277.98	43.14	6.78	12.59

TABLE A.7 – Métriques globales ex-post de validation API et Reality Gap pour le modèle PySR avec opérateur cubique.

Journée Test	Cost Opti [€]	Cost ex-post [€]	Diff. [€]	RMSE Temp [°C]	RMSE Power [W]	MAPE P [%]	Energ Opti [kWh]	Energ ex-post [kWh]
2025-01-21	0.72	2.15	1.43	0.30	672.56	77.12	4.88	13.61
2025-02-04	4.24	6.61	2.38	0.69	1336.17	40.20	30.52	46.02
2025-03-01	0.68	1.51	0.83	0.25	534.96	61.85	5.81	12.79
2025-04-24	0.21	0.62	0.41	0.09	255.59	77.64	2.20	6.49
2025-05-09	0.45	0.49	0.04	0.10	191.54	39.44	9.28	10.14
2025-06-08	0.01	0.11	0.11	0.15	250.14	31.54	10.29	12.14
2025-07-08	0.81	1.27	0.46	0.05	248.38	41.99	10.52	15.98
2025-08-05	0.13	0.12	-0.00	0.18	282.68	58.92	15.10	16.56
2025-09-24	0.01	0.43	0.42	0.07	267.54	91.46	0.74	6.03
2025-10-04	-0.01	-0.01	0.01	0.15	348.33	66.07	6.42	12.12
2025-11-22	0.69	1.57	0.88	0.06	453.90	59.28	7.44	17.19
2025-12-24	0.33	0.81	0.48	0.34	688.84	83.66	6.18	13.74




FIGURE A.6 – Profils de température de Zone pour le 24 avril - modèle pysr linéaire année dynamique. En rouge, l'optimisation. En bleue, l'ex-post d'EnergyPlus. En gris, le baseline d'EnergyPlus.






FIGURE A.7 – Puissances électriques pour le 22 novembre - modèles pysr linéaire. Courbe de P_heating d'optimisation en tiret rouge, courbe de P_heating ex-post d'EnergyPlus en bleue et courbe de P_heating baseline d'EnergyPlus en gris. En tiret, sont les P_cooling (< 0 pour une meilleure visualisation).




(a) Profil des puissances électriques appelées. Courbe de P_{heating} d'optimisation en tiret rouge, courbe de P_{heating} ex-post d'EnergyPlus en bleu et courbe de P_{heating} baseline d'EnergyPlus en gris. En tiret, sont les P_{cooling} (< 0 pour une meilleure visualisation).




(b) Analyse des coûts financiers par quart d'heure. En rouge, les coûts d'optimisation. En bleu, les coûts ex-post EnergyPlus et en gris, les coûts baseline EnergyPlus.

FIGURE A.8 – Validation ex-post des flux de puissance et impacts économiques lors du 04 octobre - modèle pysr linéaire année dynamique.



(a) Profil des puissances électriques appelées. Courbe de P_{heating} d'optimisation en tiret rouge, courbe de P_{heating} ex-post d'EnergyPlus en bleu et courbe de P_{heating} baseline d'EnergyPlus en gris. En tiret, sont les P_{cooling} (< 0 pour une meilleure visualisation).



(b) Analyse des coûts financiers par quart d'heure. En rouge, les coûts d'optimisation. En bleu, les coûts ex-post EnergyPlus et en gris, les coûts baseline EnergyPlus.

FIGURE A.9 – Validation ex-post des flux de puissance et impacts économiques lors de la journée du 05 août - modèle pysr linéaire année dynamique.

A.5 Autorisation de diffusion

Université de Mons
Faculté Polytechnique
Département Administration Académique
9, rue de Houtain - B-7000 MONS (Belgique)

CFAC 20 11 10/3

UMONS

AUTORISATION DE DIFFUSION

I- VOLET À REMPLIR PAR L'ETUDIANT

Je soussigné(e) Romain Detrait

Agissant en l'absence de toute contrainte, certifie conformément à la législation relative au droit d'auteur et aux droits voisins, être l'auteur du mémoire/TFE/thèse, (ci-après "l'œuvre"), intitulé :

..... Symbolic regression for interpretable modeling of
..... building thermal dynamics

Autorisation (1 seul choix)

☐ Je n'autorise aucune diffusion de l'œuvre.
J'autorise la diffusion de l'œuvre:

☒ A des fins de consultation exclusivement (*Pas de photocopies*)

☐ A des fins de consultation avec possibilité d'en faire des copies

Fait à Mons, le 13/08/16

Signature (précédée de la mention "lu et approuvé"):

lu et approuvé Detrait

II- VOLET À REMPLIR PAR LE PROMOTEUR (Uniquement en cas d'autorisation de diffusion donnée par L'ETUDIANT)

Autorisation (1 seul choix)

☐ Je n'autorise aucune diffusion de l'œuvre.
Je peux autoriser la consultation ou la diffusion de l'œuvre:

☒ À la condition d'être personnellement contacté pour accord

☐ J'autorise une diffusion de l'œuvre sans aucune autre condition

Lu et approuvé par Mme/M. le Professeur F VALLÉE

En sa qualité de Promoteur.

Fait à Mons, le 26/8/16

Signature



Acronymes

AIE Agence Internationale de l'Énergie. 1

GRD Gestionnaire du réseau de distribution. 7

HVAC Heating, Ventilation and Air Conditioning. 20, 59

PG programmation génétique. 27–29

SR symbolic regression. 27–29

SVM support vector machine. 16

TFE travail de fin d'étude. 10, 27